# UTILIZAÇÃO DE REDES NEURAIS ARTIFICIAIS PARA A PREVISÃO DO TEMPO DE DURAÇÃO DE AUDIÊNCIAS TRABALHISTAS

#### ALESSANDRA MEMARI PAVANELLI

# UTILIZAÇÃO DE REDES NEURAIS ARTIFICIAIS PARA A PREVISÃO DO TEMPO DE DURAÇÃO DE AUDIÊNCIAS TRABALHISTAS

Dissertação apresentada como requisito parcial à obtenção do grau de Mestre em Ciências, do Programa de Pós-Graduação em Métodos Numéricos em Engenharia, na Área de Concentração em Programação Matemática, dos setores de Ciências Exatas e de Tecnologia da Universidade Federal do Paraná.

Orientadora: Profa. Dra. Maria Teresinha

Arns Steiner

Co-orientadores: Profa. Dra. Deise Maria

Bertholdi Costa Prof. MSc. Genival

Pavanelli

# TERMO DE APROVAÇÃO

# ALESSANDRA MEMARI PAVANELLI

# UTILIZAÇÃO DE REDES NEURAIS ARTIFICIAIS PARA A PREVISÃO DO TEMPO DE DURAÇÃO DE AUDIÊNCIAS TRABALHISTAS

Dissertação aprovada como requisito parcial à obtenção do grau de Mestre em Ciências, do Programa de Pós-Graduação em Métodos Numéricos em Engenharia, na Área de Concentração em Programação Matemática, dos setores de Ciências Exatas e de Tecnologia da Universidade Federal do Paraná, pela seguinte banca examinadora:

Orientadora:	Profa. Dra. Maria Teresinha Arns Steiner Departamento de Matemática/PPGMNE/UFPR
Co-orientadora	Profa. Dra. Deise Maria Bertholdi Costa Departamento de Desenho/PPGMNE/UFPR
	Prof. Dr. Julio César Nievola PPGIA/PUC-PR
	Profa. Dra. Ângela Olandoski Barboza Departamento de Matemática/UTFPR

Curitiba, 10 de março de 2008

Aos meus filhos Giovana e Alberto, ao meu marido Genival e a minha mãe Angelina com muito amor e carinho Dedico

#### **AGRADECIMENTOS**

Agradeço a Deus pelo dom da vida, da sabedoria e da perseverança, e por estar comigo em todos os momentos da minha vida.

Ao meu marido Genival, pelo apoio incondicional, por estar ao meu lado de forma especial e imprescindível, pelas palavras de carinho nos momentos difíceis dessa jornada.

A minha filha Giovana, e ao meu filho Alberto, que são minhas jóias preciosas, e iluminam com sua existência toda minha vida, fazendo com que eu entenda o verdadeiro sentido do amor.

A minha corajosa e perseverante mãe, Angelina, pessoa muito importante em minha vida, que na sua simplicidade e com seu amor, sempre apoiou meus projetos. À memória de meu pai, Alberto Memari Filho, cuja luz e amor continuam a brilhar em minha vida.

A minha irmã e amiga Sandra, por sempre atender minhas solicitações, e ser exemplo de determinação, e ao meu irmão Luíz Alberto, pela força do amor que sempre nos uniu em todos os momentos.

A todos os meus familiares, que de diversas maneiras, torceram e vibraram comigo durante todo esse tempo, em especial à minha querida cunhada Cibele.

A Profa. Dra. Maria Teresinha Arns Steiner, pessoa admirável, que com sua sabedoria proporcionou-me valiosas sugestões, e cujas orientações foram de fundamental importação para o desenvolvimento e conclusão de meu trabalho.

A Profa. Dra. Deise Maria Bertholdi Costa, pela co-orientação, pela motivação em todos os momentos, uma pessoa maravilhosa, sempre com palavras de apoio e incentivo.

A todos os professores do curso, pelos ensinamentos.

Ao MM. Juiz do Trabalho, Dr. Bráulio Gabriel Gusmão, Juiz do Fórum Trabalhista de São José dos Pinhais, Paraná, sempre prestativo e entusiasmado, visando sempre a melhoria em seu trabalho, e também por suas preciosas colaborações.

Aos funcionários do Fórum Trabalhista de São José dos Pinhais, Paraná, que sempre responderam prontamente minhas solicitações, em especial ao Sr. Renato pela atenção e prontidão.

A todos os amigos do PPGMNE, em especial ao Wyrllen, pela amizade e companheirismo.

À Maristela Bandil pela amizade, por sempre ter uma palavra de otimismo em todos os momentos difíceis dessa jornada.

Ao Colégio Militar de Curitiba, em especial a todos os meus chefes, que licenciando-me de minhas atividades, tornaram possível a realização desse trabalho.

À todos aqueles que, de uma forma ou de outra, colaboraram para realização deste "sonho".

# SUMÁRIO

LISTA DE FIGURAS	ix
LISTA DE QUADROS	xi
RESUMO	xiii
ABSTRACT	xiv
CAPÍTULO I	
1 INTRODUÇÃO	1
1.1 OBJETIVOS DO TRABALHO	2
1.2 JUSTIFICATIVA DO TRABALHO	3
1.3 ESTRUTURA DO TRABALHO	3
CAPÍTULO II	
2 DESCRIÇÃO DO PROBLEMA	5
2.1 HISTÓRICO DA JUSTIÇA DO TRABALHO	5
2.2 ESTRUTURA DA JUSTIÇA DO TRABALHO	6
2.3 ETAPAS DE UM PROCESSO TRABALHISTA	8
2.4 ESTUDO DE CASO	9
2.5 OBTENÇÃO DOS DADOS	10
2.6 TRATAMENTO DOS DADOS	11
CAPÍTULO III	
3 REFERENCIAL TEÓRICO	16
3.1 REDES NEURAIS ARTIFICIAIS (RNAs)	16
3.1.1 Definições de RNAs	17
3.1.2 Histórico	18
3.1.3 Neurônio Biológico	21
3.1.4 Neurônio Artificial	22
3.1.5 Funções de Ativação de uma RNA	23
3.1.6 Características Gerais das RNAs	25
3.1.7 Treinamento de uma RNA de Múltiplas Camadas	29
3.1.8 Aprendizado da RNA	20

3.1.9 Algoritmo Back-Propagation	30
3.2 ANÁLISE DE COMPONENTES PRINCIPAIS	35
3.2.1 Introdução	35
3.2.2 Método para Descarte de Variáveis Usando Componentes	
Principais	36
3.2.3 Componentes Principais Populacionais	37
3.2.4 Componentes Principais de Variáveis Padronizadas	40
3.2.5 Componentes Principais Amostrais	41
3.3 REGRESSÃO	43
3.3.1 Regressão Logística	43
3.3.2 Regressão Linear Múltipla	44
3.3.2.1 Definição	44
3.3.2.2 Linearidade do Modelo de Regressão	46
3.3.2.3 Valor Esperado do Vetor de Erro	46
3.3.2.4 Normalidade	47
3.3.2.5 Poder de Explicação do Modelo	47
3.3.2.6 Relação entre as Variáveis	48
3.4 REVISÃO DE LITERATURA – TRABALHOS RELACIONADOS	49
CAPÍTULO IV	
4 APLICAÇÃO DOS MÉTODOS PARA RESOLUÇÃO DO	
PROBLEMA E ANÁLISE DOS RESULTADOS	52
4.1 APLICAÇÃO DAS RNAs PARA RESOLUÇÃO DO PROBLEMA	52
4.1.1 Teste I	54
4.1.2 Teste II	58
4.1.3 Teste III	65
4.1.4 Teste IV	72
4.2 ANÁLISE DOS RESULTADOS OBTIDOS DAS RNAs	74
4.3 APLICAÇÃO DA ANÁLISE DE REGRESSÃO LINEAR MÚLTIPLA	
PARA RESOLUÇÃO DO PROBLEMA	74
4.3.1 Teste I com Regressão Linear Múltipla	75
4.3.2 Teste II com Regressão Linear Múltipla	81
4.3.3 Teste III com Regressão Linear Múltipla	87

4.4 ANÁLISE DOS RESULTADOS DE REGRESSÃO LINEAR MÚLTIPLA	92
CAPÍTULO V	
5 CONCLUSÕES E SUGESTÕES PARA FUTUROS TRABALHOS	94
5.1 CONCLUSÕES	94
5.2 SUGESTÕES PARA FUTUROS TRABALHOS	95
REFERÊNCIAS	96
APÊNDICES	100

# **LISTA DE FIGURAS**

FIGURA 3.1.	NEURÔNIO ARTIFICIAL PROJETADO POR MCCULLOCH	19
FIGURA 3.2.	REDE DE PERCEPTONS PROPOSTA POR ROSEMBLATT	20
FIGURA 3.3.	MODELO DE UM NEURÔNIO BIOLÓGICO	22
FIGURA 3.4.	MODELO DE UM NEURÔNIO ARTIFICIAL	23
FIGURA 3.5.	FUNÇÕES DE ATIVAÇÃO DE UMA RNA	24
FIGURA 3.6.	REDE NEURAL ARTIFICIAL	26
FIGURA 3.7.	MODELO DE REDE NEURAL COM UMA CAMADA	27
FIGURA 3.8.	MODELO DE REDE NEURAL COM DUAS CAMADAS	28
FIGURA 3.9.	MODELO DE REDE NEURAL RECORRENTE	28
FIGURA 3.10.	ILUSTRAÇÃO DAS PROPAGAÇÕES <i>FORWARD</i>	
	(PARA A FRENTE) E <i>BACKWARD</i> (PARA TRÁS) DO	
	ALGORITMO BACK-PROPAGATION	35
FIGURA 3.11.	REPRESENTAÇÃO GEOMÉTRICA DE COMPONENTES	
	PRINCIPAIS	38
FIGURA 4.1.	FLUXOGRANA DOS TESTES REALIZADOS	54
FIGURA 4.2.	TREINAMENTO VERSUS CAPACIDADE DE GENERALIZAÇÃO	
	DA RNA	57
FIGURA 4.3.	AUTOVALORES VERSUS COMPONENTES DA ACP-TESTE II	60
FIGURA 4.4.	AUTOVALORES VERSUS COMPONENTES DA ACP-TESTE III	67
FIGURA 4.5.	VALORES PREDITOS X VALORES OBSERVADOS – TESTE I.1	77
FIGURA 4.6.	VALORES PREDITOS X RESÍDUOS – TESTE I.1	78
FIGURA 4.7.	HISTOGRAMA DOS RESÍDUOS -TESTE I.1	78
FIGURA 4.8.	VALORES PREDITOS X VALORES OBSERVADOS – TESTE I.2	79
FIGURA 4.9.	VALORES PREDITOS X RESÍDUOS – TESTE I.2	80
FIGURA 4.10	HISTOGRAMA DOS RESÍDUOS -TESTE I.2	80
FIGURA 4.11.	VALORES PREDITOS X VALORES OBSERVADOS – TESTE II.1	83
FIGURA 4.12.	VALORES PREDITOS X RESÍDUOS – TESTE II.1	83
FIGURA 4.13.	HISTOGRAMA DOS RESÍDUOS -TESTE II.1	84
FIGURA 4.14.	VALORES PREDITOS X VALORES OBSERVADOS – TESTE II.2	85
FIGURA 4.15.	VALORES PREDITOS X RESÍDUOS – TESTE II.2	86
FIGURA 4.16.	HISTOGRAMA DOS RESÍDUOS -TESTE II.2	86

FIGURA 4.17.	VALORES PREDITOS X VALORES OBSERVADOS – TESTE III.1.8	38
FIGURA 4.18.	VALORES PREDITOS X RESÍDUOS – TESTE III.1	9
FIGURA 4.19.	HISTOGRAMA DOS RESÍDUOS -TESTE III.1	39
FIGURA 4.20.	VALORES PREDITOS X VALORES OBSERVADOS – TESTE III.2.9	<b>)</b> 1
FIGURA 4.21.	VALORES PREDITOS X RESÍDUOS – TESTE III.29	1
FIGURA 4.22.	HISTOGRAMA DOS RESÍDUOS -TESTE III.29	2

# **LISTA DE QUADROS**

QUADRO 2.1.	LOCALIZAÇÃO DOS TRT NO BRASIL	7
QUADRO 2.2.	CODIFICAÇÃO DO ATRIBUTO TEMPO DE SERVIÇO	12
QUADRO 2.3.	CODIFICAÇÃO DO ATRIBUTO SALÁRIO DO RECLAMANTE	.12
QUADRO 2.4.	CODIFICAÇÃO DO ATRIBUTO PROFISSÃO	12
QUADRO 2.5.	CODIFICAÇÃO DO ATRIBUTO JUÍZ	13
	ATRIBUTOS E CODIFICAÇÕES	
QUADRO 3.1.	CORRELAÇÃO ENTRE AS VARIÁVEIS	48
QUADRO 4.1.	TOPOLOGIA DO PRIMEIRO TESTE	55
QUADRO 4.2.	RESULTADOS NUMÉRICOS DAS SIMULAÇÕES DO TESTE I	
	COM VARIAÇÃO DO NÚMERO DE ITERAÇÕES	56
QUADRO 4.3.	AUTOVALORES EM ORDEM DECRESCENTE TESTE II	58
QUADRO 4.4.	TOPOLOGIAS DO TESTE II.1 COM 30	
	COMPONENTES PRINCIPAIS	60
QUADRO 4.5.	VARIAÇÃO DO NÚMERO DE ITERAÇÕES DO TESTE II.1	
	COM 30 COMPONENTES PRINCIPAIS	. 61
QUADRO 4.6.	TOPOLOGIAS DO TESTE II.2 COM 15	
	COMPONENTES PRINCIPAIS	62
QUADRO 4.7.	NÚMERO DE ITERAÇÕES DO TESTE II.2 COM 15	
	COMPONENTES PRINCIPAIS	63
QUADRO 4.8.	TOPOLOGIAS DO TESTE II.3 COM 11	
	COMPONENTES PRINCIPAIS	64
QUADRO 4.9.	VARIAÇÃO DO NÚMERO DE ITERAÇÕES DO TESTE II.3	
	COM 11 COMPONENTES PRINCIPAIS	64
QUADRO 4.10	AUTOVALORES EM ORDEM DECRESCENTE TESTE III	66
QUADRO 4.11	.TOPOLOGIAS DO TESTE III.1 COM 25 COMPONENTES	
	PRINCIPAIS	68
QUADRO 4.12	NÚMERO DE ITERAÇÕES DO TESTE III.1 COM 25	
	COMPONENTES PRINCIPAIS	68

QUADRO 4.13.10POLOGIAS DO TESTE III.2 COM 13 COMPONENTES	
PRINCIPAIS	69
QUADRO 4.14.NÚMERO DE ITERAÇÕES DO TESTE III.2 COM 13	
COMPONENTES PRINCIPAIS	70
QUADRO 4.15.TOPOLOGIAS DO TESTE III.3 COM 10 COMPONENTES	
PRINCIPAIS	71
QUADRO 4.16.NÚMERO DE ITERAÇÕES DO TESTE III.3 COM 10	
COMPONENTES PRINCIPAIS	71
QUADRO 4.17.TOPOLOGIA DO QUARTO TESTE	72
QUADRO 4.18.NÚMERO DE ITERAÇÕES DO QUARTO TESTE	73
QUADRO 4.19. MELHORES RESULTADOS DAS REDES NEURAIS	74
QUADRO 4.20. AJUSTE DO PRIMEIRO TESTE DE REGRESSÃO COM 30	
VARIÁVEIS	75
QUADRO 4.21.AJUSTE DO PRIMEIRO TESTE DE REGRESSÃO COM	
SEIS VARIÁVEIS	79
QUADRO 4.22.AJUSTE DO SEGUNDO TESTE DE REGRESSÃO	
COM 30 VARIÁVEIS COM ACP	81
QUADRO 4.23.AJUSTE DO SEGUNDO TESTE DE REGRESSÃO	
COM 13 VARIÁVEIS COM ACP	84
QUADRO 4.24.AJUSTE DO TERCEIRO TESTE DE REGRESSÃO COM	
25 VARIÁVEIS COM ACP	87
QUADRO 4.25.AJUSTE DO TERCEIRO TESTE DE REGRESSÃO COM	
23 VARIÁVEIS COM ACP	90
OLIADRO 4.26 MELHORES RESULTADOS DE RIM	93

#### **RESUMO**

O presente trabalho tem como objetivo prever o tempo de duração de audiências trabalhistas, otimizando dessa maneira, o agendamento dos horários dos juízes do Fórum Trabalhista de São José dos Pinhais (SJP), Paraná. A metodologia proposta neste trabalho consiste em comparar duas técnicas distintas, uma relacionada a Inteligência Artificial que é a Rede Neural Artificial (RNA) e a outra relacionada à estatística que é Regressão Linear Múltipla, de forma a obter o melhor resultado. Para tanto, utilizou-se os dados dos processos, do Fórum Trabalhista de SJP, que serviram de entrada para as RNAs e para Regressão Linear Múltipla. Foram treinadas diversas RNAs, com várias topologias e, em alguns casos, utilizando a Análise de Componentes Principais, buscando melhorar ainda mais os resultados obtidos. Na Regressão Linear Múltipla os testes foram realizados com os mesmos conjuntos de dados utilizados nas RNAs a fim de comparar as duas técnicas. As ferramentas utilizadas mostraram-se bem eficientes, sendo que para o problema abordado, o desempenho das RNAs, com a utilização de Análise de Componentes Principais, foi superior ao resultado apresentado pela técnica de Regressão Linear Múltipla.

#### **ABSTRACT**

This research aims at predicting the length of time of labor hearings in order to optimize the judges' time schedules in São José dos Pinhais Labor Court in Paraná State. To achieve the best result, the methodology used here is a comparison of two distinct techniques: the first one is related to Artificial Intelligence studies and is known as Artificial Neural Network (ANN), the second one is based on Statistics and is called Multiple Linear Regression (MLR). Data collected from São José dos Pinhais Labor Court fed both ANNs and MLR tests. Many ANNs were trained using different topologies, or even using Main Component Analysis with the objective of reaching improved results. The same data was then used in MLR tests. Both tools employed in this research have shown to be efficient, although Artificial Neural Network proved to be more adequate than Multiple Linear Regression.

# **CAPÍTULO I**

# 1. INTRODUÇÃO

Atualmente muitos países possuem legislação trabalhista, mas nem sempre foi assim. No Brasil, a Justiça do Trabalho e a legislação trabalhista surgiram somente depois do século XIX, após várias lutas e reivindicações provenientes das classes operárias.

A partir da Revolução de 1930 é que foi criado o Ministério do Trabalho. Em 1931 criou-se o Conselho Nacional do Trabalho, que passou a ter autoridade para dar opiniões em matéria consultiva e contenciosa, ou seja, onde ocorre divergência entre as partes interessadas.

A Justiça do Trabalho foi prevista pela constituição de 1934 e instituída em 1º de maio de 1939, pelo decreto-lei nº 1.237, declarada por Getúlio Vargas. Foi dividida inicialmente em três instâncias: Junta Conciliadora e Julgamento; Conselhos Regionais do Trabalho e Conselho Nacional do Trabalho. Atualmente a Justiça do Trabalho está estruturada em três graus de jurisdição:

- Primeiro Grau: Varas do Trabalho;
- Segundo Grau: Tribunais Regionais do Trabalho;
- Terceiro Grau: Tribunal Superior do Trabalho.

De acordo com o Tribunal Superior do Trabalho (TST), existem em todo o Brasil 24 Tribunais Regionais do Trabalho (TRT) e cerca de 269 novas Varas do Trabalho foram criadas com o objetivo de acelerar os trâmites legais dos processos trabalhistas (TST, 2007).

Só no estado do Paraná, no TRT da 9ª Região, existem 28 desembargadores distribuídos em todo o estado (TRT, 2007). O Fórum Trabalhista, localizado no município de São José dos Pinhais, no ano de 2006, passou a contar com a 2ª Vara do Trabalho. A instalação dessa nova vara teve como objetivo, desafogar a intensa movimentação processual da justiça trabalhista local, bem como ampliar a

capacidade de atendimento da demanda existente. Porém, segundo o IBGE-2005, a população da jurisdição trabalhista de São José dos Pinhais, PR, envolvendo nove municípios da região, é de cerca de 450 mil habitantes. Só o município de São José dos Pinhais corresponde a 56% de toda essa população.

O fato de São José dos Pinhais ser pólo gerador de empregos de grande importância para a economia do estado do Paraná, traz consigo todos os conflitos trabalhistas que são característicos do mundo do trabalho.

Das 77 Varas do Trabalho do estado do Paraná, São José dos Pinhais ocupa o 2º lugar em número de ações trabalhistas. As reclamações trabalhistas vem aumentando ano após ano. Isso acontece devido a vários fatores, entre eles, a escolha de investidores do Brasil e do exterior para a instalação de seus empreendimentos neste município.

Devido a essa industrialização maciça no município, gerando um aumento dos conflitos trabalhistas, faz-se necessário a expansão e agilidade nos serviços da justiça. Com isso, a necessidade do uso de ferramentas matemáticas para o agendamento inteligente das audiências é de fundamental importância para a agilidade na justiça.

Algumas das ferramentas adequadas para esse tipo de problema são as Redes Neurais Artificiais (RNAs) e Regressão Linear Múltipla. Elas são ferramentas distintas, sendo que a primeira é relacionada à Inteligência Artificial e têm seu funcionamento inspirado na estrutura biológica do cérebro humano, e a Regressão Linear Múltipla é relacionada à estatística, porém ambas se enquadram de maneira bem satisfatória ao tipo de problema em questão.

#### 1.1 OBJETIVOS DO TRABALHO

O objetivo deste trabalho é estimar o tempo aproximado de cada audiência do Fórum Trabalhista de São José dos Pinhais, PR, a fim de obter um agendamento "inteligente" dessas audiências.

Para tanto, utilizar-se-á de dois métodos: um na área de inteligência artificial, Redes Neurais e outro estatístico, Regressão Linear Múltipla.

Estes dois métodos têm sido muito utilizados em diversas áreas, apresentando resultados satisfatórios. O objetivo de utilizar os dois métodos é o de se fazer uma comparação entre os resultados finais obtidos e, com isso, verificar qual fornece o melhor resultado, ou seja, com o menor erro.

Dessa maneira, os juízes poderão programar suas audiências, sem a falta ou o excesso de tempo de uma audiência para outra e, automaticamente, os usuários do sistema terão mais agilidade nos serviços solicitados e, consequentemente, uma maior satisfação.

#### 1.2 JUSTIFICATIVA DO TRABALHO

No Fórum Trabalhista de São José dos Pinhais, PR, o agendamento das audiências é realizado de maneira uniforme, ou seja, o mesmo tempo é fornecido para todos os processos. Não é utilizado nenhum tipo de ferramenta matemática para auxiliar nestes agendamentos.

Pretende-se com este trabalho, através da comparação das técnicas de RNAs e Regressão Linear Múltipla, elaborar uma agenda "inteligente", ou seja, destinar o tempo adequado a cada audiência de cada processo, dependendo das características do mesmo.

#### 1.3 ESTRUTURA DO TRABALHO

Além desta introdução, este trabalho foi dividido em mais quatro capítulos.

No segundo capítulo é apresentada uma descrição detalhada do problema abordado neste trabalho e a forma de obtenção dos dados para a realização do mesmo.

No terceiro capítulo são apresentados os conceitos que envolvem as técnicas empregadas neste trabalho, que são: RNAs, desde o treinamento da rede, as

topologias adotadas, o algoritmo *back-propagation* (retro-propagação), a função de transferência sigmoidal até o balanceamento dos pesos para o reconhecimento de padrões; Análise de Componentes Principais (ACP), suas interpretações algébrica e geométrica; Regressão Linear Múltipla desde a definição até o estabelecimento da relação entre as variáveis envolvidas; e a Revisão Bibliográfica, enfocando trabalhos correlacionados, com breves comentários.

No quarto capítulo faz-se a aplicação dos métodos, RNAs, Análise de Componentes Principais e Regressão Linear Múltipla, ao problema abordado no capítulo II e, também, a análise dos resultados obtidos.

Finalizando, no capítulo V são apresentadas as conclusões obtidas por meio da análise dos resultados do capítulo anterior e as sugestões para futuros trabalhos.

# **CAPÍTULO II**

# 2. DESCRIÇÃO DO PROBLEMA

Neste capítulo é apresentado um breve histórico sobre a Justiça do Trabalho, bem como a sua estrutura e as etapas de um processo trabalhista. São também relatados, de maneira objetiva, a obtenção e o tratamento dos dados coletados junto ao Fórum Trabalhista de São José dos Pinhais, PR.

# 2.1 HISTÓRICO DA JUSTIÇA DO TRABALHO

Com base em informações obtidas junto ao Tribunal Superior do Trabalho (TST) e ao Tribunal Regional do Trabalho da 9ª Região, pode-se constatar que atualmente muitos países possuem legislação trabalhista, mas nem sempre foi assim. No Brasil, por exemplo, a legislação trabalhista e a Justiça do Trabalho surgiram através de muitas lutas e reivindicações operárias que aconteciam dentro e fora do país, a partir do século XIX.

As primeiras normas trabalhistas surgem a partir da última década do século XIX. Em 30 de abril de 1923 foi criado o Conselho Nacional do Trabalho, órgão consultivo para assuntos trabalhistas e previdenciários que, naquele momento, ainda não decidia sobre divergências surgidas nas relações de trabalho.

A partir da Revolução de 1930 foi criado o Ministério do Trabalho e, em 1931, o Conselho Nacional do Trabalho vinculado ao novo Ministério passou a ter autoridade para dar opiniões em matéria contenciosa (em que há divergência entre as partes interessadas) e consultiva. Em 1932, Getúlio Vargas criou as Comissões Mistas de Conciliação e as Juntas de Conciliação e Julgamento, cujas funções eram conciliar e julgar os dissídios coletivos e individuais do trabalho, respectivamente.

A Justiça do Trabalho foi prevista pela Constituição de 1934 e instituída em 1º de maio de 1939, pelo Decreto-lei nº 1.237, e foi declarada instalada por Getúlio Vargas em ato público realizado no dia 1º de maio de 1941, no campo de futebol do Vasco da Gama, Rio de Janeiro. Foi dividida em três instâncias: na base, pela Junta Conciliadora e Julgamento, onde o presidente é um juiz de direito ou bacharel,

nomeado pelo Presidente da República; em nível intermediário, pelos Conselhos Regionais do Trabalho e, em nível superior, pelo Conselho Nacional do Trabalho.

Dessa forma, a Justiça do Trabalho é transformada em órgão do Poder Judiciário a partir da Constituição de 1946, mantendo a estrutura que tinha como órgão administrativo, inclusive com representação classista. O título classista da 1ª instância passou de vogal para juiz. Foi estabelecido que em cada unidade da Federação houvesse "pelo menos um" Tribunal Regional do Trabalho (TRT). Hoje existem 24 TRT em todo o país, conforme dados obtidos junto ao TST.

Em nove de dezembro de 1999 foi promulgada a Emenda Constitucional nº24, que alterou dispositivos da Constituição Federal pertinentes à representação classista na Justiça do Trabalho, extinguindo-a. A emenda mudou também a denominação das Juntas de Conciliação e Julgamento, que passaram a se chamar varas do trabalho. Nas comarcas onde não foram instituídas, a emenda estabeleceu que a jurisdição das varas fosse atribuída aos juízes de direito.

Em 21 de novembro de 2003 foi sancionada a Lei 10.770, que criou 269 novas varas do trabalho. A criação das varas foi iniciativa do TST, devido ao expressivo aumento do número de processos trabalhistas nos últimos anos.

Diante desse aumento de processos trabalhistas que tramitam nas varas do trabalho, faz-se necessária a utilização de ferramentas matemáticas para prever o tempo de duração de audiências trabalhistas, buscando assim um melhor atendimento aos cidadãos que procuram seus direitos junto à Justiça do Trabalho.

# 2.2 ESTRUTURA DA JUSTIÇA DO TRABALHO

A Justiça do Trabalho divide-se em três graus de jurisdição de acordo com o artigo 111 da Constituição da República, como se segue:

1. Varas do trabalho: onde ocorrem os julgamentos provenientes de reclamações trabalhistas entre empregado e empregador. O empregador pode ser pessoa física ou jurídica, já o empregado é sempre pessoa física. A jurisdição da vara abrange um ou mais municípios. O local da prestação de serviços do

empregado, é o que determina a jurisdição para o julgamento da ação trabalhista. Quando o empregado se encontra em uma comarca onde não exista vara do trabalho, a lei pode designar ao juiz de direito a jurisdição trabalhista.

Atualmente existem 1327 varas do trabalho em todo país. No período de 2004 a 2008 têm sido implementadas, de acordo com o orçamento e a necessidade da Justiça do Trabalho, mais 269 varas que já foram criadas. As varas são compostas por um juiz do trabalho titular e um juiz do trabalho substituto.

2. Tribunais Regionais do Trabalho: julgam recursos ordinários contra decisões de varas do trabalho.

Segundo o artigo 112 da Constituição Federal, "A lei criará varas da Justiça do Trabalho podendo, nas comarcas não abrangidas por sua jurisdição, atribuí-las aos juízes de direito, com recurso para o respectivo Tribunal Regional do Trabalho". De acordo com o TST, atualmente a Justiça do Trabalho possui 24 TRT, conforme citado anteriormente, que foram distribuídos, segundo o Art. 670 da Consolidação das Leis Trabalhistas (CLT), como mostra o quadro 2.1 a seguir.

QUADRO 2.1 – LOCALIZAÇÃO DOS TRT NO BRASIL

Região	Local	No. de Juízes
1ª	Rio de Janeiro	54
2ª	São Paulo	64
3ª	Minas Gerais	36
4 <u>a</u>	Rio Grande do Sul	36
5ª	Bahia	29
6ª	Pernambuco	18
7 <u>ª</u>	Ceará	8
8ª	Pará	23
9ª	Paraná	28
10ª	Distrito Federal	17
11ª	Amazonas	8
12ª	Santa Catarina	18
13ª	Paraíba	8
14ª	Rondônia	8
15ª	Campinas (SP)	36
16ª	Maranhão	8
17ª	Espírito Santo	8

continua

continuação

Região	Local	No. de Juízes
18ª	Goiás	8
19ª	Alagoas	8
20ª	Sergipe	8
21ª	Rio Grande do Norte	8
22ª	Piauí	8
23ª	Mato Grosso	8
24ª	Mato Grosso do Sul	8

A composição do TRT da 9ª região, com sede em Curitiba e jurisdição no estado do Paraná, é estabelecida pelo seu Regimento Interno, o qual prevê 28 juízes, sendo 22 de carreira, nomeados por promoção e respeitando o critério de antiguidade e merecimento dentre todos os juízes titulares das Varas do Trabalho da Região, e seis juízes que tenham mais de 10 anos de efetiva atividade e reputação inquestionável, são oriundos da advocacia e do ministério publico, é o chamado Quinto Constitucional. No caso, para a escolha desses seis juízes é feita a indicação dos nomes e realizada uma eleição cujo voto é secreto, sendo que em caso de empate é utilizado o critério da antiguidade.

3. Tribunal Superior do Trabalho: julga recurso de revista, recursos ordinários e agravos de instrumento contra decisões de TRT e dissídios coletivos de categorias organizadas em nível nacional, além de mandados de segurança, embargos opostos a suas decisões e ações rescisórias.

O TST possui a função de uniformizar a jurisprudência trabalhista. A sede do TST encontra-se em Brasília, DF, e sua jurisdição abrange todo território nacional. De acordo com o artigo 111-A da Constituição Federal de 1988, o TST compor-se-á de 27 Ministros, togados e vitalícios, todos nomeados pelo Presidente da República.

# 2.3 ETAPAS DE UM PROCESSO TRABALHISTA

De acordo com PAVANELLI (2007) um processo trabalhista apresenta as seguintes fases. A primeira fase começa quando o empregado (reclamante) autua sua petição em uma Vara do Trabalho, a qual realiza o cadastramento do processo. A seguir a Justiça do Trabalho informa o empregador (reclamado) sobre a petição.

Este poderá apresentar seus argumentos contrariando o que requer o reclamante. Em seguida o juiz analisa e julga todos os pedidos feitos pelo reclamante. No caso de uma das partes não concordar com a análise e o julgamento do juiz, esta pode interpor um recurso junto ao TRT. Se ambas as partes ficarem satisfeitas ou se não couber mais recursos, o juiz encerra o processo e determina que seja cumprido o que foi estipulado; neste momento, se for o caso, são calculados todos os valores que o autor tem direito.

#### 2.4 ESTUDO DE CASO

O Fórum Trabalhista de São José dos Pinhais, PR, que hoje conta com a 1ª e 2ª Varas vem trabalhando em ritmo acelerado e, devido a essa grande demanda de processos trabalhistas, está prestes a inaugurar a 3ª Vara. Através do juiz da 1ª Vara procura soluções para melhorar o tempo de agendamento de audiências. No ano de 2006, recebeu cerca de seis mil processos trabalhistas, número este que vem aumentando ano após ano.

Desta forma, o presente trabalho, realizado junto ao Fórum Trabalhista de São José dos Pinhais, visa implementar uma "agenda inteligente", ou seja, utilizar métodos matemáticos e técnicas computacionais com o objetivo de fazer uma estimativa do tempo de duração de cada audiência trabalhista. Atualmente todos os agendamentos das audiências são efetuados sem nenhuma ferramenta matemática ou computacional, apenas usando o critério do bom senso. Buscando eliminar o subjetivismo do bom senso, este trabalho propõe o uso de ferramentas matemáticas e computacionais, tais como Redes Neurais Artificiais (RNAs) e Regressão Linear Múltipla.

As RNAs consistem em um método matemático para solucionar problemas da área da inteligência artificial. São técnicas computacionais que apresentam um modelo inspirado na estrutura neural de organismos inteligentes e que adquirem conhecimento através da experiência, podendo dessa forma serem utilizadas para reconhecer padrões.

Por outro lado, o método de Regressão Linear Múltipla tem como principal objetivo descrever a relação entre uma variável resposta e suas variáveis explicativas. É uma técnica estatística utilizada para estudar a relação entre uma variável dependente e várias variáveis independentes. Os objetivos podem ser: explicativo ou preditivo. Se for explicativo demonstrará uma relação matemática que pode indicar, mas não prova, uma relação causa e efeito. No caso de ser preditivo, obterá uma relação que permita perante futuras observações das variáveis independentes, prever o correspondente valor da variável dependente, sem a necessidade de medi-lo. Dessa forma estas técnicas atingem plenamente os objetivos propostos neste trabalho.

# 2.5 OBTENÇÃO DOS DADOS

Em junho de 2007 foram realizadas reuniões com o juiz da 1ª Vara do Trabalho de São José dos Pinhais, a fim de determinar quais dados seriam relevantes para a determinação da duração de uma audiência trabalhista. Tais dados foram coletados, a fim de treinar as RNAs e também na aplicação da Regressão Linear Múltipla. Esses dados coletados, também chamados de atributos da RNA, são citados a seguir.

- a. Rito: pode ser reclamação trabalhista (RT) ou procedimento sumaríssimo (PS).
- b. Tempo de serviço: é dado em meses pela diferença entre a data de dispensa e data de admissão.
  - c. Salário do reclamante: último salário recebido.
- d. Profissão: função exercida pelo reclamante. Dividiu-se este atributo em duas partes: setor, que se subdivide em comércio, indústria e serviço; cargo, que se subdivide em direção e execução.
- e. Objeto do processo: corresponde aos pedidos feitos pelo reclamante. São elas: falta de registro em carteira profissional, diferenças salariais, verbas rescisórias, multa do § 8 do Art. 477 da CLT, penalidade prevista no Art. 467 da

CLT, horas extras e reflexos, fundo de garantia por tempo de serviço, indenização por danos morais, seguro desemprego, vale transporte, adicional de insalubridade, adicional noturno e plano de saúde.

- f. Juiz: pela 1ª Vara do Trabalho passaram vários juizes em determinadas situações, neste trabalho foram coletados dados de dois juizes substitutos além do titular.
  - g. Depoimentos: quantidade de depoimentos em cada audiência.
  - h. Acordo: quando ocorre o acordo entre as partes.
- i. Tempo da audiência: é dado em minutos pela diferença entre o término e o início da audiência.

Os processos analisados foram ajuizados no ano de 2006, na 1ª Vara do Trabalho do Fórum de São José dos Pinhais, PR. Foram coletados dados de 108 processos através da Ficha de Dados (Apêndice I), Os atributos listados anteriormente serviram como dados para criar a matriz destinada ao treinamento e ao teste da RNA bem como para aplicar a técnica de Regressão Linear Múltipla.

# 2.6 TRATAMENTO DOS DADOS

A maioria dos dados foi tratado de forma a corresponder a uma ou mais coordenadas binárias (LU *et al*, 1996), (BAESENS *et al*, 2003) do vetor de entrada para as técnicas utilizadas.

Quando o atributo "Rito" for do tipo "RT", apresentará entrada com valor "1"; quando for do tipo "PS", apresentará valor "0", caracterizando-a como uma variável nominal.

O atributo "tempo de serviço" foi dividido em faixas, mantendo a mesma cardinalidade dentro de cada uma delas. Devido ao fato de ser uma variável ordinal, as coordenadas binárias que a representam foram designadas conforme o quadro 2.2 a seguir, apresentando assim três coordenadas no vetor de entrada da RNA.

QUADRO 2.2 – CODIFICAÇÃO DO ATRIBUTO "TEMPO DE SERVIÇO"

FAIXA	DURAÇÃO	ENTRADA NA RN
1	>=1 e < 15meses	0 0 0
2	> = 15 e < 35 meses	0 0 1
3	>=35 e < 85 meses	0 1 1
4	>= 85	111

O atributo "salário", da mesma maneira que o atributo "tempo de serviço", foi dividido em faixas procurando manter a mesma cardinalidade dentro de cada uma delas. Conforme mostra o quadro 2.3, a seguir, este atributo fornece quatro coordenadas para o vetor de entrada da RNA.

QUADRO 2.3 – CODIFICAÇÃO DO ATRIBUTO "SALÁRIO DO RECLAMANTE"

FAIXA	ÚLTIMO SALÁRIO	ENTRADA NA RN
1	>=330 e < 450	0000
2	>=450 e < 620	0 0 0 1
3	>=620 e < 800	0 0 1 1
4	>=800 e < 1340	0111
5	>=1340	1111

O atributo "profissão", classificado como variável nominal, foi dividido em "setor" e "cargo", conforme citado anteriormente. De acordo com o quadro 2.4, a seguir, este atributo apresentará quatro coordenadas no vetor de entradas da RNA.

QUADRO 2.4 – CODIFICAÇÃO DO ATRIBUTO "PROFISSÃO"

SETOR	CARGO	COORDENADAS DO SETOR	COORDENADAS DO CARGO	ENTRADA NA RN
COMÉRCIO	Direção	0 0 1	1	0011
00111211010	Execução	0 0 1	0	0010
INDÚSTRIA	Direção	010	1	0101
	Execução	010	0	0100
SERVIÇO	Direção	100	1	1001
- 113	Execução	100	0	1000

O atributo "objeto do processo" possui 13 coordenadas binárias no vetor de entrada da RNA. Cada uma das coordenadas corresponde a uma das solicitações do autor do processo, que são, conforme já mencionado, as seguintes: falta de registro em carteira profissional, diferenças salariais, verbas rescisórias, multa do Art. 477, penalidade do Art. 467, horas extras e reflexos, fundo de garantia por

tempo de serviço, indenização por danos morais, seguro desemprego, vale transporte, adicional de insalubridade, adicional noturno e plano de saúde. Apresentará valor "1", se for solicitada; valor "0", em caso de não solicitação.

Como foram analisados processos de três juizes diferentes, e por se tratar de um atributo nominal, cada um deles foi codificado conforme o quadro 2.5, a seguir.

QUADRO 2.5 – CODIFICAÇÃO DO ATRIBUTO "JUIZ"

JUIZ	ENTRADA NA RN			
1	1 0 0			
2	0 1 0			
3	0 0 1			

Como o número de depoimentos em cada audiência não era superior a quatro, manteve-se este atributo com o seu valor original.

Quando houver acordo entre as partes antes do julgamento este atributo apresentará o valor "1", caso contrário apresentará o valor "0".

Sendo assim o vetor de entrada dos dados possui 30 coordenadas, que são os atributos codificados do processo conforme especificado anteriormente. A matriz de entrada de dados possui então 108 linhas e 30 colunas (Apêndice II), considerando-se que os dados foram retirados dos 108 processos (padrões).

Nesta pesquisa foram implementadas RNAs supervisionadas com a função de transferência sigmoidal, que fornece saídas de entre "0" e "1" para entradas variando de -∞ a +∞. Já que os tempos de audiência, que são as saídas da RNA, variaram de um até 93 minutos, foi necessário dividi-los por 93 a fim de enquadrá-los dentro do intervalo de abrangência da função sigmoidal (Apêndice III).

Encontram-se no quadro 2.6 todos os atributos considerados neste trabalho e suas respectivas codificações tornando-os binários.

# QUADRO 2.6 - ATRIBUTOS E CODIFICAÇÕES

			Entrada	Entrada	Entrada	Entrada	Número
Atributos	Valores originais	Intervalos	1	2	3	4	de
	dos Atributos						Entradas
1. Tipo de Rito	1 = RT	1 = RT	1				1
(atributo nominal)	0 = PS	0 = PS	0				
2. Tempo de Serviço	Faixa	meses					3
(atributo ordinal)	1	>=1 e < 15	0	0	0		
	2	>=15 e < 35	0	0	1		
	3	>=35 e < 85	0	1	1		
	4	>=85	1	1	1		
3. Salário do Reclamante	Faixas	Salário em reais					4
(atributo ordinal)	1	>= 330 e < 450	0	0	0	0	
	2	>=450 e < 620	0	0	0	1	
	3	>=620 e < 800	0	0	1	1	
	4	>=800 e < 1340	0	1	1	1	
	5	>=800	1	1	1	1	
4. Profissão	Setor	Cargo					4
(atributo nominal)	Comércio	Direção	0	0	1	1	
	Comércio	Execução	0	0	1	0	
	Indústria	Direção	0	1	0	1	
	Indústria	Execução	0	1	0	0	
	Serviço	Direção	1	0	0	1	
	Serviço	Execução	1	0	0	0	
5.1 Objeto do Processo – Falta							1
de Registro em Carteira	1 = sim	1 = sim	1				
(atributo nominal)	0 = não	0= não	0				
5.2 Objeto do Processo –							1
Diferenças Salariais	1 = sim	1 = sim	1				
(atributo nominal)	0 = não	0= não	0				
5.3 Objeto do Processo –							1
Verbas Rescisórias (atributo nominal)	1 = sim	1 = sim	1				
5.4 Objeto do Processo – Multa	0 = não	0= não	0				1
Art 477	1 = sim	1 - aim	1		1		1
(atributo nominal)	$0 = n\tilde{a}o$	1 = sim 0= não	0				
5.5 Objeto do Processo – Multa	0 = 1140	0= 1140					1
Art 467	1 = sim	1 = sim	1				1
(atributo nominal)	$0 = n\tilde{a}o$	0= não	0				
5.6 Objeto do Processo – Horas	0 – 1140	0-1100					1
Extras e Reflexos	1 = sim	1 = sim	1				1
(atributo nominal)	0 = não	0= não	0				
5.7 Objeto do Processo – F.G.							1
(atributo nominal)	1 = sim	1 = sim	1				-
,	0 = não	0= não	0				
5.8 Objeto do Processo – Danos							1
Morais	1 = sim	1 = sim	1				
(atributo nominal)	0 = não	0= não	0				
5.9 Objeto do Processo –							1
Seguro Desemprego	1 = sim	1 = sim	1				
(atributo nominal)	0 = não	0= não	0				
5.10 Objeto do Processo – Vale							1
Transporte	1 = sim	1 = sim	1				
(atributo nominal)	0 = não	0= não	0				
5.11 Objeto do Processo –							1
Adicional de Insalubridade	1 = sim	1 = sim	1				
(atributo nominal)	0 = não	0= não	0				

CONTINUA

# CONCLUSÃO

Atributos	Valores originais dos Atributos	Intervalos	Entrada 1	Entrada 2	Entrada 3	Entrada 4	Número de Entradas
5.12 Objeto do Processo –							1
Adicional Noturno	1 = sim	1 = sim	1				
(atributo nominal)	0 = não	0= não	0				
5.13 Objeto do Processo –							1
Plano de Saúde	1 = sim	1 = sim	1				
(atributo nominal)	0 = não	0= não	0				
6. Juiz	Juiz						3
(atributo nominal)	1		1	0	0		
	2		0	1	0		
	3		0	0	1		
7. Depoimento							1
(atributo nominal)	N° de dep.						
8. Acordo	_						1
(atributo nominal)	1 = sim	1 = sim	1				
	0 = não	0= não	0				
Total de Atributos: 8							30

# **CAPÍTULO III**

# 3. REFERENCIAL TEÓRICO

Neste capítulo são abordadas as técnicas utilizadas para o reconhecimento de padrões aplicadas nesse trabalho. É feita uma pequena introdução seguida de algumas definições e alguns conceitos de Redes Neurais Artificiais (RNAs). Também são apresentadas características gerais das principais arquiteturas desenvolvidas no processo de pesquisa, desde o treinamento da rede até o balanceamento dos pesos para o reconhecimento dos padrões. São relatados, ainda, os conceitos da Análise de Componentes Principais (ACP) bem como a técnica de Regressão Linear Múltipla. Ainda são apresentados resumos de alguns trabalhos correlacionados ao tema aqui tratado.

## 3.1 REDES NEURAIS ARTIFICIAIS (RNAs)

Um dos maiores desafios da comunidade científica é e sempre foi entender o cérebro humano. A agilidade e rapidez do cérebro humano constituem o objetivo a ser alcançado por sistemas da Inteligência Artificial, que baseiam seus estudos na simulação em computadores.

O cérebro humano realiza diversas tarefas desde as mais simples como, por exemplo, classificação de padrões até as mais complexas. Os sistemas computacionais buscam desenvolver algoritmos de Inteligência Artificial que são baseados no funcionamento do cérebro humano, porém ainda estão longe de atingir a perfeição, mesmo nas tarefas mais simples.

As RNAs, também conhecidas como sistemas conexionistas, que podem ser considerados como uma subárea da Inteligência Artificial têm como objetivo modelar esta estrutura tão complexa, de forma a ficar facilmente compreensível. Têm tido desempenho satisfatório em diversas aplicações (LIPPMAN, 1989) tais como, finanças, engenharia, medicina, geologia e física. Em qualquer área em que existam problemas de predição, classificação ou controle, pode-se empregar RNAs. Isso

porque as redes neurais possuem um grande poder de resolução e são de fácil utilização.

# 3.1.1 Definições de RNAs

Muitas definições foram elaboradas desde que as RNAs começaram a surgir como uma nova perspectiva à Inteligência Artificial. Em todas elas prevaleceram as semelhanças ao sistema nervoso humano. A maioria das pesquisas sobre RNAs foram motivadas pela idéia de que o cérebro humano é um computador com processamento de informações bastante complexas. São apresentadas a seguir, algumas definições básicas de RNAs.

NELSON & ILLINGWORTH (1990) definem as RNAs como sendo técnicas inovadoras de processamento de informações, que têm como objetivo básico, simular, em computadores, o funcionamento do sistema nervoso biológico.

Seguindo a mesma linha, FAUSETT (1994) também define as RNAs como sistemas de processamento de informações que possuem características de funcionamento similares às das redes neurais biológicas, mais especificamente, generalizações de modelos matemáticos da biologia neural.

As definições citadas podem ser complementadas e melhor compreendidas pela análise da afirmativa de HAYKIN (2002):

Uma rede neural é um processador maciçamente paralelamente distribuído constituído de unidades de processamento simples, que tem a propensão natural para armazenar conhecimento experimental e torná-lo disponível para uso. Ela se assemelha ao cérebro em dois aspectos:

- 1. O de que o conhecimento é adquirido pela rede a partir de seu ambiente através de um processo de aprendizagem.
- 2. Forças de conexão entre neurônios, conhecidas como pesos sinápticos, são utilizadas para armazenar o conhecimento adquirido (HAYKIN, 2002).

Esta capacidade de "aprender", destacada por HAYKIN em sua definição, também foi decisiva para TAFNER, XEREZ & RODRIGUES FILHO (1996) basearem seus estudos. Segundo os autores, "o modelo neurológico é programado para aprender" e aprender é uma capacidade que a RNA possui devido a interconexão

entre seus neurônios, que ocorre em um grau similar ao da interconexão ocorrida com os neurônios biológicos e não encontrado em técnicas de cálculo convencionais.

Dessa forma, uma RNA pode ser definida como uma estrutura computacional que tem como objetivo permitir a implementação de modelos matemáticos que representem a forma como o cérebro humano processa as informações que adquire.

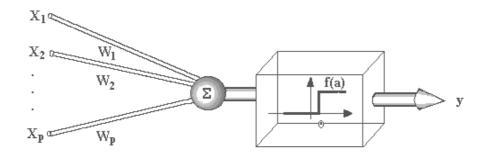
Apesar de muitas definições darem a impressão de simplicidade, é de fundamental importância ressaltar que na prática, essa idéia não acontece de forma tão simples. Durante a implementação da RNA vários fatores podem ocorrer impossibilitando a aplicação em certos casos. Percebe-se também que as soluções não são precisas quando as RNAs são aplicadas isoladamente.

Também não se pode deixar de mencionar que ainda existe uma longa e árdua trajetória a ser percorrida no sentido das pesquisas para chegar a uma arquitetura computacional que reproduza fielmente a capacidade do cérebro humano.

# 3.1.2 Histórico

As primeiras pesquisas na área de RNAs surgiram há aproximadamente meio século. W. S. McCuloch e W. Pitts (HAYKIN, 1994) iniciaram a modelagem de um neurônio biológico, gerando o modelo de neurônio artificial, atualmente utilizado no desenvolvimento de RNAs. O trabalho realizado fazia uma comparação entre células vivas e o processamento eletrônico, simulando o comportamento do neurônio natural. O neurônio artificial possuía apenas uma saída, que era uma função de entrada (*threshold*) da soma do valor de suas diversas entradas. Na figura 3.1, a seguir, apresenta-se o neurônio artificial projetado por McCulloch, onde  $X_1, X_2, ..., X_p$  são as entradas da RNA;  $W_1, W_2, ..., W_p$  são os pesos sinápticos; f(a) a função de ativação e y é a saída da RNA.

FIGURA 3.1 NEURÔNIO ARTIFICIAL PROJETADO POR MCCULLOCH

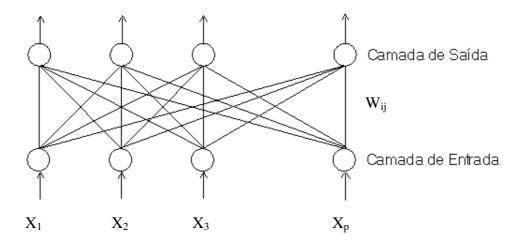


FONTE: DIN (2007)

Também proveniente deste período foi a construção do primeiro neuro computador, denominado *Snark*, por Mavin Minsky, em 1951 (DIN, 2007). O *Snark* operava com sucesso a partir de um ponto de partida técnico, ajustando seus pesos automaticamente, entretanto, ele nunca executou qualquer função de processamento de informação interessante, mas serviu de inspiração para as idéias de estruturas que o sucederam.

Em 1957 surge o neuro computador Mark I *Perceptron* que obtém sucesso, o qual foi criado por Frank Rosenblatt, Charles Wightman e outros (DIN, 2007). Frank Rosenblatt é visto como fundador da neuro computação e tinha como objetivo inicial para a criação do *perceptron* o reconhecimento de padrões. Ele descreveu uma topologia de RNA, que são estruturas de ligação entre os nodos, como pode ser observado na figura 3.2 a seguir. O mais importante foi que ele propôs um algoritmo para treinar a rede a fim de executar determinados tipos de funções. Este tipo básico de *perceptron* comporta-se como classificador de padrões, dividindo o espaço de entrada em regiões distintas para cada uma das classes existentes. Inicialmente a saída era aleatória, mas, pelo ajuste dos pesos, o *perceptron* é treinado para fornecer saídas de acordo com os dados do conjunto de treinamento. Nesse modelo os neurônios eram organizados em camadas de entradas e saídas onde os pesos das conexões eram adaptados a fim de se atingir a eficiência sináptica.

FIGURA 3.2 REDE DE PERCEPTRONS PROPOSTA POR ROSEMBLATT



FONTE: DIN (2007)

Após Rosenblatt, Bernard Widrow, com a ajuda de alguns estudantes, desenvolveu um novo tipo de elemento de processamento de redes neurais chamado de *Adaline*, equipado com uma poderosa lei de aprendizado, que diferente do *Perceptron* ainda permanece em uso. Widrow também fundou a primeira companhia de *hardware* de neuro computadores e componentes (DIN, 2007).

Segundo STEINER (2006), as décadas de 60 e 70 quase não são mencionadas com relação a abordagem conexionista. Somente com o surgimento do algoritmo *back- propagation* para treinamento de redes de múltiplas camadas, em 1986, com Rumelhart, Hinton e Williams, a comunidade científica voltou a se interessar pelas RNAs como ferramenta para reconhecimento de padrões. Esse algoritmo marcou a "explosão" nesse campo da pesquisa. Acontece também nesse período a publicação dos trabalhos de Hopfield relatando a utilização de redes simétricas para otimização.

A partir da década de 80 diversos modelos de RNAs surgem com o propósito de aperfeiçoar e aplicar esta técnica. Muitos pesquisadores passaram a publicar diversas propostas para exploração de desenvolvimento de RNAs. O fato marcante desse período ocorre quando Ira Skurnick, um administrador de programas da DARPA (*Defense Advanced Research Projects Agency*) decidiu ouvir os argumentos

da neuro computação e seus projetistas, e divergindo dos caminhos tradicionais dos conhecimentos convencionais, inicia suas pesquisas em neuro computação.

Atualmente, os campos de aplicações das RNAs são imensos, porém, na prática, o que se encontra são aplicações em problemas específicos, onde se tem um grande volume de dados disponíveis, mas não se consegue descrever regras para o comportamento do sistema. Outra característica da RNA é sua capacidade de tolerar erros ou ruídos nos dados obtidos. Com certeza a RNA é uma ferramenta importante para muitas aplicações, entre elas, apoio ao diagnóstico médico, modelos econômicos e financeiros, análise de imagens, reconhecimento de escritas, dentre outros.

# 3.1.3 Neurônio Biológico

Os neurônios e a glia são os principais tipos de células encontradas no cérebro humano. Estudos realizados pelo Dr. Frank Pfrieger e Dra. Barbara Barres (WELLS, 2007) demonstram que grande parte da eficiência do cérebro deve-se a produção pela glia de uma proteína ou fator químico, que "envolve" os neurônios e aprimora a transmissão de impulsos elétricos, fortalecendo as conexões sinápticas.

A perda da memória e outros distúrbios cerebrais ocorrem normalmente pelo enfraquecimento das conexões sinápticas. Logo, para que o cérebro funcione bem, deve-se fortalecer as conexões.

Apesar das afirmações de que células nervosas conectadas sem a presença do fator glial, normalmente, são enfraquecidas e começam a falhar, as RNAs ainda não oferecem uma modelagem para a atuação da glia, e atribuem as funções primordiais do cérebro aos neurônios.

Os neurônios biológicos apresentam-se de várias formas, entretanto, de maneira geral, possuem os seguintes elementos principais: o corpo celular, as ramificações de entrada (dendritos), a ramificação de saída (axônio) e as conexões sinápticas que interligam os neurônios, conectando dendritos a axônios (MACHADO, 2006).

Os neurônios biológicos se comunicam através de sinapses. Sinapse é a região onde dois neurônios entram em contato e através da qual os impulsos nervosos são transmitidos entre eles. A figura 3.3 a seguir mostra um modelo de neurônio biológico.

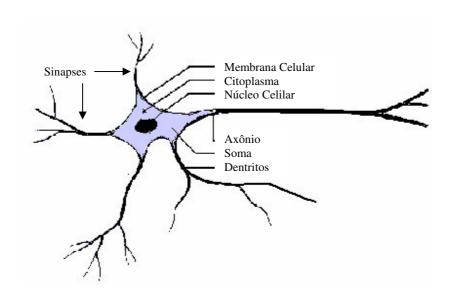


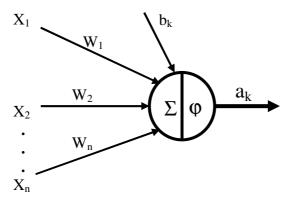
FIGURA 3.3 MODELO DE UM NEURÔNIO BIOLÓGICO

FONTE: ICMC.USP (2008)

### 3.1.4 Neurônio Artificial

O neurônio artificial é a estrutura básica de processamento de uma RNA. Segundo PACHECO (1996) os neurônios artificiais são estruturas lógicas matemáticas que têm o objetivo de simular o funcionamento de um neurônio biológico, fazendo com que a RNA atue de forma indutiva. A figura 3.4 mostra um modelo de neurônio artificial, com suas entradas  $(X_1, X_2,..., X_n)$ , pesos sinápticos  $(W_{1k}, W_{2k},..., W_{nk})$ , bias  $(b_k)$ , função soma  $(\Sigma)$ , função de transferência  $(\varphi)$  e saída  $(a_k)$ .

FIGURA 3.4 MODELO DE UM NEURÔNIO ARTIFICIAL



O neurônio funciona basicamente como integrador de sinais. Tem a função de coletar sinais provenientes de outros neurônios, ou sinais da entrada da rede, ponderar os dados através de pesos específicos e repassar esses dados para outros neurônios ou para saída da rede. De acordo com a figura 3.4 pode-se entender a estrutura básica de um neurônio artificial.

Para se calcular o sinal de saída  $(a_k)$ , efetuada por um neurônio desse tipo, pode-se utilizar a equação (3.1) a seguir:

$$a_k = \varphi(\sum_{i=1}^n x_i w_{ik} + b_k)$$
 (3.1)

onde : n = o número total de sinais de entrada que chegam até o neurônio que está sendo calculado;  $x_i = v$ alor de entrada para esse neurônio;  $w_{ik} = p$ eso associado a essa conexão;  $b_k = t$ êm a função de aumentar ou diminuir a entrada da função de ativação.

O resultado da somatória das componentes do produto interno entre o vetor de entrada (X) e o vetor de pesos (W) do neurônio, é mapeado através da função de ativação ( $\varphi$ ), produzindo o valor da saída ( $a_k$ ) do neurônio (k).

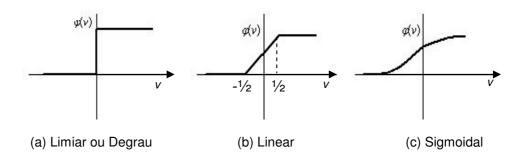
#### 3.1.5 Funções de Ativação de uma RNA

O objetivo de uma função de ativação é restringir a amplitude da saída do neurônio, ou seja, limitar sua saída em um intervalo de valor finito.

Segundo STEINER (1995), é a função de ativação que define a saída do neurônio artificial, ou seja, o caminho onde a informação será conduzida, tornandose muito importante para o comportamento da RNA.

Os tipos de função de ativação mais usados para mapear uma RNA são basicamente três de acordo com HAYKIN (2002): Limiar ou Degrau, Linear por partes e Sigmoidal. As representações gráficas dessas funções de ativação são mostradas na figura 3.5 a seguir.

FIGURA 3.5 FUNÇÕES DE ATIVAÇÃO DE UMA RNA



Na Função Limiar ou degrau: A saída do neurônio assume valor "0" quando seu resultado for negativo, e valor "1" caso contrário (figura 3.5(a)):

$$\varphi(v) = \begin{cases} 1 & se & v \ge 0 \\ 0 & se & v < 0 \end{cases}$$

Na Função Linear por partes: Esse tipo de função é visto como uma aproximação de um amplificador não linear (figura 3.5(b)):

$$\varphi(v) = \begin{cases} 1 & se \quad v \ge \frac{1}{2} \\ v, & se - \frac{1}{2} < v < \frac{1}{2} \\ 0 & se \quad v \le -\frac{1}{2} \end{cases}$$

E na Função sigmoidal: É o tipo de função mais utilizado em RNA. Encontram-se de várias formas, porém as mais comuns são: a função logística (figura 3.5(c)), dada por  $\varphi(v) = \frac{1}{1 + e^{-av}}$ , onde a é o parâmetro de inclinação da função, ou seja, quanto maior seu valor, mais inclinada a curva se tornará, e a função tangente hiperbólica, dada por  $\varphi(v) = tanh(v)$ , função esta que pode assumir valores negativos.

#### 3.1.6 Características Gerais das RNAs

Uma das principais vantagens e importância das RNAs é a sua capacidade de "aprender sozinha" através do seu próprio uso, e de melhorar seu desempenho baseado nessa aprendizagem.

A capacidade de uma rede aprender vem dos neurônios artificiais, que têm funcionamento baseado no neurônio biológico. Embora pareça simples, o aprendizado é um processo altamente complexo. Além de envolver diversos níveis de abstração, também reúne habilidades e conceitos advindos de várias áreas do conhecimento e não há em relação a ele uma definição única e plena.

Apesar da complexidade, a analogia com os elementos do cérebro humano é essencial para entender-se de maneira satisfatória a estrutura e o funcionamento de uma RNA.

Segundo PANDYA & MACY (1996), o sistema nervoso de um ser humano, assim como o de qualquer primata, consiste de três estágios básicos: o estágio inicial, no qual os estímulos de entrada externos são captados pelas unidades "sensoras" (os olhos, por exemplo, captam sinais visuais); o estágio de processamento destes sinais pelo sistema nervoso central (o cérebro) e o estágio no qual as respostas aos estímulos de entrada são obtidas (a voz pode ser ativada em reposta a determinada entrada, bem como ações motoras ou orgânicas).

De acordo com esta definição, o cérebro humano recebe informações do meio exterior, processa, avalia e compara as outras informações que tem armazenado na memória, tornando-se apto a tomar decisões apropriadas. As RNAs são baseadas no funcionamento no cérebro humano. Assim, ela é estruturada de maneira a

simular todas as etapas de processamento das informações. Segundo a definição de PANDYA & MACY (1996), uma RNA pode apresentar-se da seguinte forma:

- a. uma camada inicial de unidades sensoras aos estímulos de entrada, que não é composta por neurônios;
- b. uma ou mais camadas intermediárias de neurônios interligados (formando a estrutura central de processamento da rede neural);
- c. uma camada de neurônios de saída, conectada aos neurônios da(s) camada(s) escondida(s), gerando a resposta final da RNA.

A figura 3.6, a seguir, mostra a estrutura de uma RNA. As entradas da rede representam a informação existente. Elas alimentam a primeira camada de neurônios que através do cálculo executado pela aplicação da função de transferência, geram repostas que alimentam a camada seguinte, e assim atingem a camada de saída.

 $W_{ij}$   $W_{hi}$   $W_{gh}$   $W_{gh}$  W

FIGURA 3.6 REDE NEURAL ARTIFICIAL

A forma com que os neurônios se agrupam em camadas e o conjunto de suas conexões define a arquitetura da RNA. As arquiteturas neurais são organizadas em camadas, com os neurônios de uma determinada camada, conectados aos neurônios da camada posterior. Os dispositivos processadores são agrupados por pelo menos duas camadas: uma camada para apresentação dos dados e outra para obtenção dos resultados. As redes, em geral, possuem uma ou mais camadas intermediárias, também conhecidas como camadas escondidas. Segundo HAYKIN (2002) existem três tipos de arquitetura de rede:

a. redes alimentadas adiante com camada única (*feedforward*): o termo camada única se refere a camada de saída, ou seja, o processamento ocorre somente na camada de saída. A figura 3.7 a seguir mostra um modelo de uma rede *feedforward* com uma única camada, o Apêndice IV, mostra um exemplo deste tipo de rede treinada com o algoritmo *back-propagation*.

 $X_1$   $W_2$   $X_n$ 

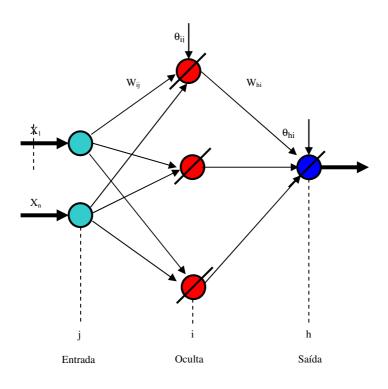
Saída

FIGURA 3.7 MODELO DE REDE NEURAL COM UMA CAMADA

b. redes alimentadas adiante com múltiplas camadas (*feedforward*): esta possui uma ou mais camadas ocultas. A figura 3.8 ilustra uma rede *feedforward* com duas camadas – uma oculta e uma de saída.

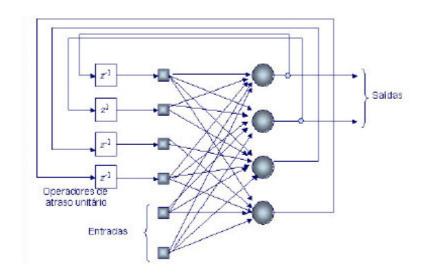
Entrada





c. redes recorrentes: possui pelo menos um laço de realimentação. A figura 3.9 ilustra esse tipo de arquitetura.

FIGURA 3.9. MODELO DE REDE NEURAL RECORRENTE



FONTE: HAYKIN (2002)

Geralmente as redes *feedforward* de múltiplas camadas apresentam a seguinte estrutura:

- Camada de entrada: onde os padrões são apresentados à rede; nesta camada não ocorre o processamento de informações;
- Camadas intermediárias ou escondidas (não obrigatórias): recebem informação da camada anterior, processam os dados e enviam a resposta para a camada seguinte;
- Camada de saída: local onde se obtém o resultado final através do processamento das informações vindas da camada anterior.

### 3.1.7 Treinamento de uma RNA de Múltiplas Camadas

Em geral o treinamento é um processo gradual e lento, onde os pesos são modificados várias vezes, seguindo-se um algoritmo de treinamento que estabelece a forma como estes pesos são alterados. O treinamento de uma RNA pode ser efetuado de uma das seguintes maneiras:

- a. Treinamento supervisionado: é utilizado quando são conhecidos os valores das saídas para um determinado grupo de padrões. Para cada padrão apresentado, a RNA calcula a saída (valor obtido) e o compara com o valor desejado (real) e atualiza os pesos das conexões entre todos os neurônios buscando reduzir o erro. Redes de Retropropagação, *GRNN* ("General Regression Neural Networks"), *PNN* ("Probabilistic Neural Networks"), e GMDH ("Group Method Data Handling") são exemplos de redes supervisionadas.
- b. Treinamento não supervisionado: neste caso, como não se conhecem as saídas, os pesos são modificados em função de critérios internos.

#### 3.1.8 Aprendizado da RNA

Aprender significa se adaptar ao ambiente de acordo com as regras impostas, alterando seu desempenho ao longo do tempo. Toda RNA precisa passar pela etapa do treinamento para aprender, isso significa que os pesos associados às conexões serão alterados, segundo um algoritmo.

Esse algoritmo especifica como os pesos devem ser alterados durante o aprendizado para melhorar cada vez mais o desempenho da RNA. A mudança nesses pesos só pode ocorrer durante a fase do treinamento, permanecendo inalterado durante a fase de teste.

De acordo com a técnica de aprendizado utilizada, pode-se fazer uso de outros conjuntos de dados, os quais ainda não foram apresentados a RNA, a fim de se fazer o teste de validação. Durante o teste de validação os pesos sinápticos não se alteram, busca-se apenas validar o treinamento realizado, ou seja, verificar se o erro obtido está dentro dos parâmetros aceitáveis. Após a validação da RNA, verifica-se a sua generalização, que é a capacidade de um modelo de aprendizado responder corretamente aos exemplos que lhe são apresentados sendo que estes exemplos não devem estar presentes na base de aprendizado. Um modelo que tem uma boa generalização é aquele modelo que responde corretamente não somente aos exemplos contidos na base de aprendizado, mas também a outros exemplos.

Os resultados podem ser verificados em termos de porcentagem de respostas corretas que resultam do modelo. O aprendizado, em geral, precisa de uma grande quantidade de dados, porém, nenhum tipo de aprendizado é garantia de poder obter-se sempre uma resposta absolutamente correta, principalmente se os dados forem incompletos ou conflitantes.

### 3.1.9 Algoritmo Back- Propagation

O algoritmo *back-propagation* é o algoritmo de aprendizado supervisionado mais conhecido (HAYKIN, 2002; FAUSETT, 1994). Este algoritmo é de fácil compreensão, o que favorece a sua utilização.

Durante o treinamento com este algoritmo, a rede opera em dois estágios fundamentais. No primeiro, *forward* (para frente), deve-se apresentar um padrão à camada de entrada. Todo o processo é realizado, camada por camada, até que se obtenha uma resposta na camada de saída. Neste momento a saída obtida é comparada à saída desejada e calcula-se o erro. No estágio seguinte, *backward* (para trás), a propagação ocorre da camada de saída para a camada de entrada,

onde os pesos das conexões das camadas internas vão sendo modificados conforme o erro é retro propagado.

O ajuste corretivo nos pesos das conexões entre os neurônios, para se obter uma boa aproximação da saída encontrada à resposta desejada, será realizado passo a passo, até que se atinja uma situação estável, ou seja, quando os pesos não precisam mais ser ajustados.

O algoritmo implementado neste trabalho é o *back-propagation* que utilizará a função de ativação logística sigmoidal, que fornece saídas entre "0" e "1" para entradas entre  $(-\infty, \infty)$ ).

A seguir especificar-se-á, por meio de equações, cada um dos passos do algoritmo *back-propagation* em suas fases: propagação *forward* e propagação *backward*.

Na propagação *forward*, onde todos os padrões descritos por suas coordenadas  $x_j^P$ , são apresentados à rede, verifica-se que qualquer unidade i da rede recebe os sinais de entrada e agrupa-os na equação (3.2) (STEINER, 2006).

$$\mathbf{j}_{i}^{P} = \sum_{j=1}^{n} w_{ij} x_{j}^{P} + \theta_{i}, \quad i = 1, \dots k$$
 (3.2)

onde  $i_i^P$  é a entrada do padrão p para o neurônio i, k é o número de neurônios na camada escondida;  $w_{ij}$  é a conexão peso entre as unidades i e j; n é o número de sinais de entrada na rede;  $x_j^P$  são as coordenadas do padrão p e  $\theta_i$  é o bias do neurônio i.

Utilizando-se da função de transferência logística sigmoidal, de acordo com a equação (3.2), cada unidade i gera um sinal de saída  $a_i^P$ , expresso na função (3.3).

$$a_i^P = \frac{1}{1 + e^{-i_i^P}} \tag{3.3}$$

De acordo com a equação (3.3), os sinais gerados são enviados para a camada h e são agregados em  $i_h^P$  conforme a equação (3.4)

$$\mathbf{j}_{h}^{P} = \sum_{i=1}^{k} w_{hi} a_{i}^{P} + \theta_{hi}$$
 (3.4)

onde  $i_h^P$  é a entrada para o neurônio h;  $w_{hi}$  é a conexão peso entre as unidades h e i; k é o número de neurônios da camada anterior;  $\theta_{hi}$  é o bias do neurônio h.

Utilizando a função de transferência sigmoidal, a partir desses sinais, obtémse a saída  $a_h^P$  da rede de acordo com a equação (3.5)

$$a_h^P = \frac{1}{1 + e^{-i_h^P}} \tag{3.5}$$

Realiza-se então uma comparação entre o valor obtido  $a_h^P$  e o valor da saída  $d^P$ , através do cálculo do erro quadrático, de acordo com a equação (3.6):

$$E = \sum_{P} E^{P} = \frac{1}{2} \sum_{P} (d^{P} - a_{h}^{P})^{2}$$
 (3.6)

É o vetor de pesos W, segundo STEINER (2006), que constitui o que a rede neural "sabe" e também determina como ela responderá a qualquer entrada arbitrária do meio ambiente.

A seguir têm-se a propagação *backward* que executa o gradiente descendente em W a fim de localizar a solução ótima.

Segundo STEINER (2006) primeiramente encontra-se a variação dos pesos  $w_{hi}$  de acordo com a equação (3.7):

$$\Delta^{p} w_{hi} = -\gamma \frac{\partial E^{p}}{\partial w_{hi}} \tag{3.7}$$

onde  $\gamma$  é a taxa de aprendizagem, tal que  $0 < \gamma < 1$ .

como 
$$\frac{\partial E^p}{\partial w_{hi}} = -\left(d^p - a_h^p\right) \left[\frac{\left(e_h^{-ip} a_i^p\right)}{\left(1 + e_h^{-ip}\right)^2}\right]$$

$$\frac{\partial E^{p}}{\partial w_{hi}} = \left[\frac{-1}{\left(1 + e_{h}^{-ip}\right)}\right] \left[\frac{\left(e_{h}^{-ip}\right)}{\left(1 + e_{h}^{-ip}\right)^{2}}\right] \left[a_{i}^{p}\left(d^{p} - a_{h}^{p}\right)\right]$$

$$\frac{\partial E^{p}}{\partial w_{hi}} = -a_{h}^{p} \left( 1 - a_{h}^{p} \right) a_{i}^{p} \left( d^{p} - a_{h}^{p} \right)$$

então 
$$\Delta^p w_{hi} = \gamma a_h^p \left(1 - a_h^p\right) a_i^p \left(d^p - a_h^p\right)$$

Conforme a equação (3.8), considerando na variação dos pesos para o padrão atual t a troca de pesos obtida no padrão anterior (t-1) tem-se:

$$\Delta^{p} w_{hi}(t) = \gamma a_{h}^{p} \left( 1 - a_{h}^{p} \right) a_{i}^{p} \left( d^{p} - a_{h}^{p} \right) + \alpha w_{hi}(t - 1)$$
(3.8)

onde  $\alpha$  é a constante que determina o efeito na troca de pesos em (t-1),  $0 < \alpha < 1$ .

Dessa maneira obtêm-se os pesos atualizados (t) entre a camada escondida e a camada de saída, como segue na equação (3.9):

$$W_{hi}(t) = W_{hi}(t-1) + \Delta^{p} W_{hi}(t)$$
(3.9)

A seguir os pesos entre as entradas e a camada intermediária são atualizados (STEINER, 2006)

$$\Delta^p w_{ij} = -\gamma \frac{\partial E^p}{\partial w_{ii}}$$

$$\Delta^{p} w_{ij} = -\left(d^{p} - a_{h}^{p}\right) \left[\frac{\left(-\left(-e_{h}^{-ip}\right)\frac{\partial i_{h}^{p}}{\partial w_{ij}}\right)}{\left(1 + e_{h}^{-ip}\right)^{2}}\right]$$

como 
$$\frac{\partial i_h^p}{\partial w_{ij}} = w_{hi} \frac{\partial a_i^p}{\partial w_{ij}}$$

$$\frac{\partial a_i^p}{\partial w_{ij}} = \frac{e_i^{-ip} \frac{\partial i_i^p}{\partial w_{ij}}}{\left(1 + e_i^{-ip}\right)^2}$$

$$\frac{\partial i_i^p}{\partial w_{ij}} = x_j^p$$

Realizadas as substituições, tem-se:

$$\frac{\partial a_i^p}{\partial w_{ij}} = \frac{e_i^{-ip} x_j^p}{\left(1 + e_i^{-ip}\right)^2}$$

$$\frac{\partial i_i^p}{\partial w_{ij}} = w_{hi} \left[ \frac{\left( e_i^{-ip} \right) x_j^p}{\left( 1 + e_i^{-ip} \right)^2} \right]$$

assim,  $\Delta^p w_{ij}(t) = \gamma \left(d^p - a_h^p\right) \left[\frac{\left(e_h^{-ip}\right)}{\left(1 + e_h^{-ip}\right)^2}\right] w_{hi} \left[\frac{\left(e_i^{-ip}\right) x_j^p}{\left(1 + e_i^{-ip}\right)^2}\right]$ 

$$\Delta^{p} w_{ij}(t) = \gamma \left( d^{p} - a_{h}^{p} \right) a_{h}^{p} \left( 1 - a_{h}^{p} \right) w_{hi} \ a_{i}^{p} \left( 1 - a_{i}^{p} \right) x_{j}^{p}$$

De acordo com a variação dos pesos para o padrão atual t a troca de pesos obtida no padrão anterior (t-1) tem-se, conforme a equação (3.10):

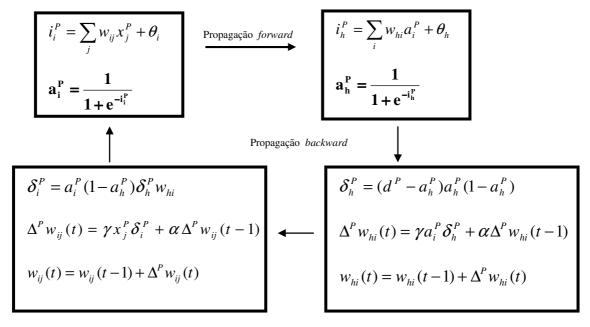
$$\Delta^{p} w_{ij}(t) = \gamma \left( d^{p} - a_{h}^{p} \right) a_{h}^{p} \left( 1 - a_{h}^{p} \right) w_{hi} a_{i}^{p} \left( 1 - a_{i}^{p} \right) x_{j}^{p} + \alpha \Delta^{p} w_{ij}(t - 1)$$
 (3.10)

Obtêm-se, dessa maneira, os pesos atualizados  $w_{ij}(t)$  entre a camada de entrada e a camada escondida como descrito na equação (3.11):

$$W_{ij}(t) = W_{ij}(t-1) + \Delta^{p} W_{ij}(t)$$
(3.11)

A figura 3.10 a seguir mostra o esquema do algoritmo *back-propagation*, para h=1, ou seja, para uma saída, cuja arquitetura está ilustrada na figura 3.8.

# FIGURA 3.10 ILUSTRAÇÃO DAS PROPAGAÇÕES *FORWARD* (PARA FRENTE) E *BACKWARD* (PARA TRÁS) DO ALGORITMO *BACK-PROPAGATION*



FONTE: PAVANELLI (2007)

onde: p = padrão; t = iteração;  $\gamma$  = taxa de aprendizagem;  $\alpha$  = taxa de momento;  $w_{ij}$  e  $w_{hi}$  = pesos entre as camadas de entrada-oculta e oculta-saída, respectivamente;  $i^P$  = input para o padrão p;  $a^P$  = output para o padrão p;  $d^P$  = valor desejado para o padrão p.

#### 3.2 ANÁLISE DE COMPONENTES PRINCIPAIS

#### 3.2.1 Introdução

A Análise de Componentes Principais (ACP) é um método de identificar padrões nos dados obtidos, visando expressar os mesmos de modo a salientar as similaridades e também diferenças existentes. Está relacionada com a explicação da estrutura da covariância por meio de poucas combinações lineares das variáveis originais.

Os objetivos de se aplicar ACP são basicamente dois. O primeiro é o de reduzir a dimensão original da matriz de dados, ou seja, obter um pequeno número de combinações lineares de um conjunto de variáveis que retenham o máximo

possível de informação contida nas variáveis originais e o segundo é de facilitar a interpretação das análises realizadas, bem como julgar a importância das próprias variáveis originais escolhidas.

Essa análise deve ser aplicada ao problema como uma técnica intermediária a outra ferramenta utilizada como, por exemplo, quando é aplicada a técnica Análise de Regressão Linear Múltipla. ACP é uma técnica muito utilizada, segundo MARQUES (2007), para investigar as relações entre um conjunto de *p* variáveis correlacionadas e transformar o conjunto de variáveis originais em um novo conjunto de variáveis não correlacionadas.

Em qualquer tipo de problema, que possui um número grande de variáveis, e que se deseja investigar as relações entre um conjunto de *p* variáveis correlacionadas, pode ser útil transformar o conjunto de variáveis originais em um novo conjunto de variáveis não relacionadas. Esse conjunto de variáveis não relacionadas é chamado de componentes principais, sendo que este novo conjunto pode ter propriedades especiais em termos de variâncias.

As componentes principais ou novas variáveis são combinações lineares das variáveis originais e são derivadas em ordem decrescente de importância, de maneira que a primeira componente principal é a combinação linear normalizada com variância máxima. A transformação das variáveis originais em componentes principais acontece com uma transformação linear e ortogonal, que garante o não correlacionamento entre elas.

A ACP é uma técnica que não depende da suposição inicial de normalidade, tornando-se uma ferramenta bastante atrativa e poderosa para dados de alta dimensionalidade.

#### 3.2.2 Método para Descarte de Variáveis Usando Componentes Principais

Essa técnica pode ser empregada em Análise de Regressão Linear Múltipla bem como em casos de colinearidade ou multicolinearidade.

A colinearidade que eventualmente existe entre as linhas de uma matriz faz com que algumas variáveis independentes contribuam pouco para a regressão.

Segundo MARDIA *et al* (1979), o método descrito a seguir, define uma possível maneira de descartar variáveis usando a técnica de componentes principais, com o objetivo de obter uma nova matriz de dados com ordem menor.

Procedimento para descarte:

Passo 1: Determinam-se os autovalores e autovetores da matriz de correlação das variáveis independentes, ou seja, das covariáveis.

Passo 2: Considera-se o autovetor correspondente ao menor autovalor. Descarta-se então a variável cujo coeficiente no autovetor for o maior. O autovetor com menor autovalor é o menos importante, e uma variável importante contida nele será a menos importante no conjunto.

Passo 3: O número de variáveis descartadas pode ser igual ao número de autovalores menores ou iguais a 0,70.

Outro critério, descrito por JOHNSON e WICHERN (2002), que pode ser utilizado para determinar quantas componentes devem permanecer no modelo, foi estabelecido em 1960, por Kaiser. Segundo este critério, mantêm-se somente as componentes cujos autovalores são superiores a "1".

Pode-se também estabelecer a permanência das n primeiras componentes (n < p), de acordo com a variação cumulativa que elas explicam. Uma variação cumulativa com um bom grau de explicação é superior a 75%; fica, porém, a cargo do usuário julgar a necessidade de variação a ser explicada.

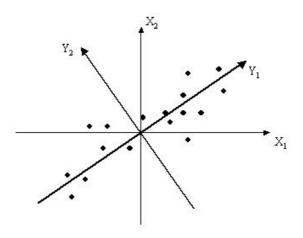
### 3.2.3 Componentes Principais Populacionais

De acordo com JOHNSON e WICHERN (2002), algebricamente as componentes principais  $Y_1,Y_2,\cdots,Y_p$  representam combinações lineares de p variáveis aleatórias  $X_1,X_2,\cdots,X_p$  do vetor aleatório X. Geometricamente essas

combinações lineares representam a seleção de um novo sistema de eixos coordenados, obtido pela rotação do sistema de eixos original. Os novos eixos representam as direções com variabilidade máxima.

A figura 3.11 mostra geometricamente os sistemas de coordenadas original  $(X_1, X_2)$  e de componentes principais  $(Y_1, Y_2)$  para p = 2.

FIGURA 3.11. REPRESENTAÇÃO GEOMÉTRICA DE COMPONENTES PRINCIPAIS



FONTE: JOHNSON e WICHERN (2002)

onde:

 $X_1$  e  $X_2$  são eixos originais e

 $Y_1$  e  $Y_2$  são novos eixos (eixos originais rotacionados: centrado na média amostral).

As componentes principais dependem somente da matriz de covariância  $\Sigma$  de  $X_1, X_2, \cdots, X_p$ , e seu desenvolvimento não requer pressuposições de normalidade multivariada.

Seja o vetor aleatório  $X=[X_1,X_2,\cdots,X_p]$  de uma população com covariância  $\Sigma$ , cujos autovalores são  $\lambda_1 \geq \lambda_2 \geq \ldots \geq \lambda_p \geq 0$ .

Considere as seguintes combinações lineares:

$$Y_{1} = \underline{e}_{1} \underline{X} = e_{11} X_{1} + e_{12} X_{2} + \dots + e_{1p} X_{p}$$

$$Y_{2} = \underline{e}_{2} \underline{X} = e_{21} X_{1} + e_{22} X_{2} + \dots + e_{2p} X_{p}$$

$$\vdots \qquad \vdots \qquad \vdots \qquad \vdots$$

$$Y_{p} = \underline{e}_{p} \underline{X} = e_{p1} X_{1} + e_{p2} X_{2} + \dots + e_{pp} X_{p}$$

Ou Y = e'X, onde:

$$Y = \begin{bmatrix} \overline{Y}_1 \\ \overline{Y}_2 \\ \vdots \\ \overline{Y}_p \end{bmatrix} \qquad e = \begin{pmatrix} e_{11} & e_{12} & \cdots & e_{1p} \\ e_{21} & e_{22} & \cdots & e_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ e_{p1} & e_{p2} & \cdots & e_{pp} \end{pmatrix} \qquad e \quad X = \begin{bmatrix} \overline{x}_1 \\ \overline{x}_2 \\ \vdots \\ \overline{x}_p \end{bmatrix}$$

$$E(Y_i) = E(e_i X) = e_i E(X) = e_i \mu$$
 (3.12)

$$V(Y_i) = V(e^i X) = \underline{e}^i V(X) e_i = \underline{e}^i \Sigma e_i = \underline{e}^i \lambda_i e_i = \lambda_i \underline{e}^i e_i = \lambda_i$$
(3.13)

$$Cov(Y_iY_j) = V(e^{\gamma}_iX, e^{\gamma}_jX) = \underline{e}^{\gamma}_i\Sigma e_j$$
(3.14)

Dessa forma pode-se definir o i-ésimo componente principal  $Y_i$  como:

$$Y_{i} = \underline{e}_{i} X = e_{i1} X_{1} + e_{i2} X_{2} + \dots + e_{in} X_{n}$$
(3.15)

Assumindo que o vetor X possui covariância  $\Sigma$  com pares de autovalores e autovetores ( $\lambda_i, e_i$ ), i = 1, 2, ..., p, em que  $\lambda_1 \ge \lambda_2 \ge ... \ge \lambda_p \ge 0$ .

Assim a porcentagem da variação total explicada pela *k*-ésima componente principal é dada por:

$$\%VarExp(Y_k) = \frac{\lambda_k}{\sum_{i=1}^p \lambda_i} 100$$
(3.16)

Em certos problemas onde se aplicam as componentes principais, se uma porcentagem de 70% ou mais for atribuída às primeiras r componentes principais, então, esses podem substituir as p variáveis originais sem significativa perda de

informações. A determinação dessa porcentagem depende do problema em questão. Um dos problemas que dificulta o emprego dessa técnica é a determinação do número *r* de componentes.

As componentes do autovetor podem informar sobre a importância das p variáveis para a i-ésima componente principal por meio de suas magnitudes. Podese utilizar uma importante medida de associação que não depende da magnitude das mensurações das variáveis originais, que é o coeficiente de correlação entre  $y_i$  e  $y_k$ . Esse coeficiente de correlação é mostrado na equação (3.17) seguir.

$$P_{yi,yk} = \frac{e_{ik} (\lambda_i)^{1/2}}{(\sigma_{kk})^{1/2}} \quad i, k = 1, 2..., p$$
(3.17)

### 3.2.4 Componentes Principais de Variáveis Padronizadas

As componentes principais podem ser obtidas pela padronização das variáveis originais por (3.18) a seguir.

$$Z_{i} = \frac{(X_{i} - \mu_{i})}{(\sigma_{ii})^{1/2}}$$
 (3.18)

Em notação matricial:

$$Z = (V)^{-1/2} \cdot (X - \mu) \tag{3.19}$$

Onde  $V^{-1/2}$  é a matriz desvio padrão,  $\mu$  é o vetor das médias e X é o vetor das variáveis originais.

$$V^{1/2} = \begin{pmatrix} \sigma_1 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_p \end{pmatrix} \quad \mu = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} \quad X = \begin{bmatrix} \overline{x}_1 \\ \overline{x}_2 \\ \vdots \\ \overline{x}_p \end{bmatrix}$$

É fácil verificar que  $Cov(Z) = \rho$  e E(Z) = 0, logo:

$$Y_{j} = \underline{e}_{j}^{T} Z = e_{j}^{T} (V)^{-1/2} . (X - \mu) \quad j = 1, 2, ..., p$$
 (3.20)

$$\sum_{i=1}^{p} V(Y_i) = \sum_{i=1}^{p} V(Z_i) = p$$
(3.21)

$$\sum_{i=1}^{p} \lambda_i = p \tag{3.22}$$

Propriedades:

1. 
$$\sum_{j=1}^{p} V(y_j) = \sum_{i=1}^{p} V(z_i) = p$$

- $2. \ Py_jz_i=e_{ij}(\lambda_j)^{1/2} \quad i,j=1,2,...,p \ \text{ onde } \ (\lambda_1,e_1),(\lambda_2,e_2),...,(\lambda_p,e_p)\,, \text{ são pares} \\ \text{autovalores e autovetores de } p \text{ com } \lambda_1 \geq \lambda_2 \geq ... \geq \lambda_p > 0.$
- 3. A proporção da variância total explicada pela j-ésima componente principal de Z é dada por  $\lambda_j/p = \sum \lambda_j$  que é a porcentagem da variação total explicada por ele.

#### 3.2.5 Componentes Principais Amostrais

Seja uma amostra aleatória  $X_1$ ,  $X_2$ ,...,  $X_p$ , retirada de uma população p variada, com média  $\mu$  e covariância  $\Sigma$ . Com vetor de médias amostrais X, matriz de covariância S e a matriz de correlação é R. Componentes principais amostrais são as combinações lineares das variáveis mensuradas que maximizam a variação total da amostra e que são mutuamente ortogonais.

Na prática, quando os parâmetros p e  $\Sigma$  são desconhecidos, obtêm-se as componentes principais através de seus estimadores, que são a matriz de covariância amostral S ou a matriz de correlação amostral R, que são definidas segundo BAPTISTELLA (2005) através de (3.23) e (3.24).

$$S = \frac{1}{n-1} \sum_{i=1}^{n} (\underline{x}_i - \underline{x})(\underline{x}_i - \underline{x})^{-1}$$
(3.23)

$$R = D^{-1}SD^{-1} (3.24)$$

onde D é a matriz desvio padrão amostral e  $\bar{\underline{x}}$  é o vetor médio amostral, mostrados em (3.25) e (3.26).

$$D = \begin{pmatrix} s_1 & 0 & \cdots & 0 \\ 0 & s_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & s_p \end{pmatrix}$$
 (3.25)

$$\frac{\overline{x}}{\underline{x}} = \begin{bmatrix} \overline{x}_1 \\ \overline{x}_2 \\ \vdots \\ \overline{x}_p \end{bmatrix}$$
 (3.26)

Calculam-se os autovalores  $\hat{\lambda}_1, \hat{\lambda}_2, \cdots, \hat{\lambda}_p$  e os respectivos autovetores  $\hat{e}_1, \hat{e}_2, \cdots, \hat{e}_p$  para depois construir as componentes principais amostrais, através de (3.27).

Todas as propriedades das componentes principais se mantêm e são obtidas com base em estimadores.

O ponto forte da técnica de componentes principais são os autovalores e autovetores da matriz de correlação. Os autovetores definem as direções de máxima variabilidade e os autovalores especificam as variâncias. Se os primeiros autovalores são maiores que os demais, isto quer dizer que a maior parte da

variância total pode ser explicada por um número menor do que as *p* dimensões do vetor *X*.

A variação total explicada pelo *k*-ésimo componente principal amostral é dado por (3.28).

$$\% VarExp(\hat{Y}_k) = \frac{\hat{\lambda}_k}{\sum_{i=1}^p \hat{\lambda}_i} 100$$
 (3.28)

## 3.3 REGRESSÃO

Os métodos de regressão têm como principal objetivo descrever a relação entre uma variável resposta e uma ou mais variáveis explicativas. A seguir é apresentado um breve resumo de dois tipos de regressão, Logística e Linear, muito utilizados em diversas áreas do conhecimento.

#### 3.3.1 Regressão Logística

Em 1845 surgiu a técnica Regressão Logística com o objetivo de resolver problemas de crescimento demográfico, que é ainda nos tempos atuais muito utilizada. Essa técnica passou também a ser empregada na área da biologia na década de 30 (LIMA, 2002). Já sua aplicação em problemas econômicos e sociais aparece somente nos anos 60. Recentemente essa metodologia tornou-se referência obrigatória em muitos manuais de econometria.

A Regressão Logística é uma técnica estatística muito usada em análise de dados com respostas binárias (dicotômicas), ou seja, respostas "0" ou "1". É basicamente essa a diferença entre Regressão Logística e Regressão Linear. No modelo de Regressão Linear pode-se obter valores de respostas estimadas fora do intervalo [0, 1], que é a técnica mais apropriada para o presente trabalho.

#### 3.3.2 Regressão Linear Múltipla

Esse modelo, muito utilizado em diversas áreas da pesquisa, sendo um tipo de técnica que pode produzir valores de resposta estimada fora do intervalo [0, 1]. Ele é considerado um modelo clássico de regressão.

#### 3.3.2.1 Definição

O Modelo de Regressão Linear Múltipla (MRLM) descreve a variável y como sendo uma soma da parte determinística e parte aleatória, sendo a parte determinística mais geral, de forma que se pode expressar o valor esperado de y de duas maneiras. A primeira como função de variáveis regressoras, já a segunda como função de polinômio de maior grau de uma única variável regressora.

É uma técnica utilizada para estudar a relação entre uma variável dependente e várias variáveis independentes. O objetivo pode ser explicativo, ou seja, demonstrar uma relação matemática que pode indicar, mas não provar, uma relação causa e efeito, ou preditivo, quer dizer, obter uma relação que permita, perante futuras observações das variáveis  $x_p$ , prever o correspondente valor de y, sem a necessidade de medi-lo. Independente do objetivo, as variáveis  $x_p$  são muitas vezes designadas por variáveis explicativas, uma vez que tentam explicar as razões da variação de y.

Suponha que está se querendo construir um modelo que relacione a variável resposta y com p fatores  $x_1, x_2, ...x_p$ . Esse modelo sempre incluirá uma parcela de erro.

Tem-se então:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_1 x_{i2} + ... + \beta_p x_{ip} + \varepsilon$$
 para  $i = 1, 2, ..., n$  (3.29)

onde n é o número de observações; p o número de variáveis.

Usando notação matricial:

$$y = X\beta + \varepsilon$$

onde y é a variável resposta; X matriz do modelo;  $\beta$  é o vetor de parâmetros a serem estimados;  $\varepsilon$  vetor de erros aleatórios.

$$Y = \begin{bmatrix} \overline{Y}_1 \\ \overline{Y}_2 \\ \vdots \\ \overline{Y}_n \end{bmatrix} \qquad X = \begin{pmatrix} 1 & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{pmatrix} \qquad \beta = \begin{bmatrix} \overline{\beta}_0 \\ \overline{\beta}_1 \\ \vdots \\ \overline{\beta}_p \end{bmatrix} \qquad \varepsilon = \begin{bmatrix} \overline{\varepsilon}_1 \\ \overline{\varepsilon}_2 \\ \vdots \\ \overline{\varepsilon}_n \end{bmatrix}$$

O modelo de regressão linear que se apresenta aqui consiste em estimar os valores dos parâmetros  $\beta_0$ ,  $\beta_1$ ,  $\beta_2$ , ...,  $\beta_p$ , através da minimização da soma dos quadrados dos desvios, daí o nome de método dos mínimos quadrados. Esse método é muito usado para regressão simples, ou seja, p=1. O termo regressão múltipla é usado no caso de p ser maior que "1".

Deve-se minimizar a soma dos quadrados dos erros e supor que estas variáveis aleatórias sejam independentes e identicamente distribuídas (i.i.d.) para se determinar o estimador de mínimos quadrados ordinários do vetor  $\beta$ , ou seja, é condição que  $\varepsilon_i \approx \left(0,\sigma^2\right)$  e  $\varepsilon_i \approx \left(0,\sigma^2I_n\right)$ , que são Gaussianas independentes com média "0" e variância constante.

O modelo de regressão linear  $y = X \beta + \varepsilon$  depende de algumas suposições que descrevem as formas do modelo e também os procedimentos adequados de estimação. A seguir algumas suposições:

- a. o vetor de erros  $\varepsilon' = [\varepsilon_1, \varepsilon_2, ..., \varepsilon_n]$  é um vetor aleatório cujas componentes  $\varepsilon_i$  com i = 1, 2, ..., n são variáveis aleatórias.
- b. a esperança de cada componente de  $\varepsilon$  é zero,  $E(\varepsilon) = 0$ .
- c. as componentes do vetor  $\varepsilon$  não são correlacionadas e possuem variância constante,  $\sigma^2$ .

d. a distribuição de  $\varepsilon_i$  com i = 1, 2, ..., n é a normal (Gaussiana).

Na relação entre a variável resposta e os fatores no modelo de Regressão Linear supõe-se que a variável resposta relaciona-se com os fatores através do modelo  $y = X \beta' + \varepsilon$ . Tomando-se como base n observações de y e das covariáveis X's estima se os  $\beta'$ .

Em qualquer problema de regressão, a variável resposta é o valor médio da variável dependente, dado o valor das variáveis independentes, ou seja, E(Y/X).

Na Regressão Linear supõe-se que esta variável possa ser expressa por:

$$E(Y/X) = \beta_0 + \sum_{i=1}^p \beta_i X_{ij} + \varepsilon_i$$
(3.30)

Assim, E(Y/X) pode assumir qualquer valor para X, ou seja,  $X \in (-\infty, \infty)$  parâmetros que são determinados através de solução de equações lineares.

#### 3.3.2.2 Linearidade do Modelo de Regressão

A linearidade, dentro do contexto de regressão, se dá pela forma na qual os parâmetros e o distúrbio estocástico entram na equação e não necessariamente a relação entre as variáveis envolvidas. Ou seja, uma relação não linear poderá ser linearizada através do uso dos logaritmos de x e y.

## 3.3.2.3 Valor Esperado do Vetor de Erro

O valor esperado do vetor de erros deve ser assumido como "0" para cada observação, quer dizer que  $\varepsilon_i$  possui média "0" para cada i, ou seja,  $E\left(\frac{\varepsilon_i}{X}\right) = 0$ .

#### 3.3.2.4 Normalidade

A verificação visual da normalidade é feita ordenando os resíduos de forma crescente, e desenhando-os em papel de distribuição normal. Se a hipótese de normalidade se verificar, os resíduos deverão estar aproximadamente em linha reta.

Em testes estatísticos é adequado que se assuma que os distúrbios sejam normalmente distribuídos, com média "0" e variância constante. Isto implicará que as observações em  $\varepsilon_i$  serão estatisticamente independentes, ou seja,  $\varepsilon \mid X \sim N \big( 0, \sigma^2 I \big) \mid$ .

#### 3.3.2.5 Poder de Explicação do Modelo

Para verificar o ajuste do modelo, relacionado à estatística *T* de *Student*, é de fundamental importância o coeficiente de determinação múltipla, que informa o poder de explicação do modelo em função das *p* variáveis independentes consideradas. Esse coeficiente é encontrado dividindo-se a variação explicada pela variação total do modelo, conforme equação (3.31) a seguir.

$$R^{2} = \frac{\sum_{i=1}^{n} (\hat{Y}_{i} - \overline{Y})^{2}}{\sum_{i=1}^{n} (Y_{i} - \overline{Y})^{2}} \quad 0 < R^{2} < 1$$
(3.31)

onde  $\mathbb{R}^2$  é chamado de coeficiente de correlação múltipla ao quadrado ou coeficiente de determinação.

O coeficiente de determinação é uma medida da qualidade do ajuste. Quando o valor de  $\mathbb{R}^2$  está próximo de "1" significa que o ajuste é bom e o modelo explica boa parte da variação total.

Esse coeficiente possui a desvantagem de que para uma mesma amostra ele cresce na medida em que aumentam o número de variáveis independentes. Porém essa desvantagem pode ser corrigida utilizando-se o Coeficiente de Determinação Ajustado, que para um modelo com k variáveis independentes, ajustado a uma amostra de n elementos, é calculado através da equação a seguir:

$$R_{aj} = 1 - \left[ \left( 1 - R^2 \right) \frac{n - 1}{n - k - 1} \right]$$
 (3.32)

## 3.3.2.6 Relação entre as Variáveis

O coeficiente de correlação,  $\hat{\rho}$ , expressa numericamente como as variáveis estão relacionadas entre si. Com base em n observações do par (X,Y) este parâmetro é estimado através da estatística, por:

$$\hat{\rho} = r = \frac{\sum_{i=1}^{n} (X_i - \overline{X})(Y_i - \overline{Y})}{\sqrt{(X_i - \overline{X})^2 (Y_i - \overline{Y})^2}} = \frac{\hat{\sigma}_{xy}}{\hat{\sigma}_x \hat{\sigma}_y}$$
(3.33)

onde  $\overline{X}$  é a média da variável independente  $X; \overline{Y}$  é a média da variável dependente  $Y; \hat{\sigma}_{xy}$  é a covariância amostral entre X e  $Y; \hat{\sigma}_x$  é o desvio padrão amostral de  $X; \hat{\sigma}_y$  é o desvio padrão amostral de Y.

O coeficiente de correlação varia no intervalo [-1, 1]. Quando o coeficiente de correlação é nulo, quer dizer que não existe relação entre as variáveis. Já se o valor for -1 ou 1, a relação entre as variáveis é ideal. Quanto ao sinal positivo ou negativo, indica somente se a relação entre as variáveis é direta ou indireta. O coeficiente não possui dimensão, isto é, não depende da unidade de medida das variáveis X e Y. O grau de relacionamento entre as variáveis pode ser interpretado da seguinte maneira, de acordo com o quadro 3.1 a seguir:

QUADRO 3.1 - CORRELAÇÃO ENTRE AS VARIÁVEIS

Coeficiente	Correlação	
$ \hat{\rho}  = 0$	relação nula	
$0 <  \hat{\rho}  \le 0.30$	relação fraca	
$0.30 <  \hat{\rho}  \le 0.70$	relação média	
$0.70 <  \hat{\rho}  \le 0.90$	relação forte	
$0.90 <  \hat{\rho}  \le 0.99$	relação fortíssima	
$ \hat{\rho}  = 1$	relação perfeita	

A expressão (3.33) é conhecida como coeficiente de correlação linear de Pearson e mede o grau de associação entre duas variáveis *X* e *Y*. Deve-se lembrar que nem sempre uma elevada correlação representa a existência de relação causa e efeito.

Encontra-se no Apêndice V a resolução de um exemplo numérico de Regressão Linear Múltipla, utilizando coeficiente de correlação linear de Pearson.

#### 3.4. REVISÃO DE LITERATURA – TRABALHOS RELACIONADOS

Nesta seção são apresentados alguns trabalhos que utilizam RNA e Regressão Linear Múltipla como ferramentas matemáticas para solucionar os mais diversos problemas. Atualmente as RNAs têm aplicações nas mais diversas áreas e com resultados bem satisfatórios. Alguns campos de aplicações das RNAs são: finanças, engenharia, medicina, geologia, física, transportes entre outros. Em qualquer área em que existam problemas de predição, classificação ou controle, se pode empregar RNA.

O trabalho de PAVANELLI (2007) tem como objetivo fornecer uma previsão do tempo de duração de um processo trabalhista. Os dados foram obtidos junto à 1ª Vara do Trabalho de São José dos Pinhais − PR. Foram analisados 100 processos, dos quais 75 serviram para o treinamento da RNA e os outros 25 serviram de testes. A técnica utilizada foi RNA com o algoritmo *back-propagation* e função de ativação sigmoidal, que fornece saídas contidas num intervalo entre "0" e "1" para entradas contidas num intervalo de (-∞, ∞). Foi realizado o treinamento supervisionado, e realizados diversos "testes" com o grupo de treinamento variando o número de neurônios na camada escondida, bem como o número de iterações, de forma a obter o melhor resultado com o menor erro global no grupo de testes. Em alguns "testes" utilizou-se a Análise de Componentes Principais, buscando melhorar ainda mais os resultados obtidos. As ferramentas utilizadas apresentaram-se bem eficientes e forneceram bons resultados, com uma margem de erro dentro do esperado.

BAPTISTELLA *et al (*2006) procuram alternativas com o objetivo de determinar valores venais para imóveis de Guarapuava – PR, pois é sabido que não existe nenhuma técnica para calcular o valor de um imóvel, apenas a experiência. O método utilizado é a comparação de técnicas matemáticas, no caso, é utilizado RNA com múltiplas camadas com diversas topologias e Análise de Regressão Linear Múltipla. Os dados foram retirados de um Cadastro Imobiliário da cidade, fornecido pelo setor de Planejamento da prefeitura Municipal. As duas técnicas se mostraram eficientes, porém a RNA forneceu um resultado superior.

ADAMOWICZ (2000) utiliza técnicas de reconhecimento de padrões tais como RNA e Análise Discriminante Linear de Fisher, com o objetivo de classificar empresas como solventes ou insolventes. Os dados foram fornecidos pelo Banco Regional de Desenvolvimento do Extremo Sul (BRDE), Regional de Curitiba. As duas técnicas se apresentaram eficientes na discriminação das empresas, porém o desempenho da RNA se apresentou um pouco melhor que a Análise Discriminante Linear de Fisher.

AMBROSIO (2002) apresenta um trabalho que tem como objetivo desenvolver um sistema computacional para auxiliar médicos radiologistas na confirmação de diagnósticos das chamadas lesões intersticiais pulmonares. Os dados foram obtidos junto ao Hospital das Clínicas da Faculdade de Medicina de Ribeirão Preto (HCFMRP) por meio de protocolos gerados por especialistas. O sistema foi desenvolvido através de RNA do tipo perceptron multicamadas, que funcionou como um classificador de padrões. O algoritmo de treinamento foi o *back-propagation*, e a função de ativação foi do tipo sigmoidal. Vários testes foram realizados para diferentes configurações de redes. Apesar da técnica RNA não ter alcançado 100% de êxito, ficou claro que o uso da mesma é viável já que uma vez a rede treinada e seus pesos fixados, não é preciso mais acessar o banco de dados. Isso torna o sistema mais rápido e computacionalmente mais leve. A pesquisa conclui que a RNA cumpre bem seu papel como classificador de padrões.

BOCANEGRA (2002) desenvolve procedimentos capazes de permitir a aplicação direta, em planejamento de transportes, de um modelo desenvolvido em RNA. Aplicou-se nessa pesquisa, o modelo já inserido em um sistema de

Informação Geográfica, para estimar viagens em uma cidade. O desenvolvimento desse trabalho partiu do estudo realizado por RAIA JR (2000). Os dados originais foram obtidos no Instituto Brasileiro de Geografia e Estatística, na contagem populacional de 1996, cidade de Bauru-SP. Chegou-se a conclusão que os procedimentos apresentados podem ser utilizados para quaisquer outros modelos que tenham sido desenvolvidos a partir de RNA, sejam eles ou não para planejamento de transportes.

SOUSA et al (2003) utilizam técnicas de RNA com três camadas de neurônios com o algoritmo back-propagation. O objetivo é fazer a previsão do teor de carne mecanicamente separada (CMS) em produtos cárneos a partir do teor de minerais contido nas salsichas formuladas com diferentes teores de carne de frango. A técnica utilizada mostrou-se bem eficiente durante a fase de treinamento e testes, no entanto, a aplicação da RNA às amostras comerciais foi inadequada devido à diferença de ingredientes das salsichas usadas no treinamento e os ingredientes das amostras comerciais.

BIONDI NETO *et al* (2007) mostram em seu trabalho que atualmente, a determinação do tipo de solo acontece através de ábacos; o objetivo dessa pesquisa é aplicar um método computacional para classificar o solo. A técnica utilizada é RNA com método Levenberg–Marquardt, que apresenta como resultado a classificação do solo para cada incremento de profundidade. Todos os dados foram obtidos de situações reais. O tempo de convergência foi rápido, o que facilitou a realização de vários testes. Os resultados apresentaram um acerto de 95% na classificação dos solos.

INFANTOSI *et al* (2004) afirmam que na área médica, a utilização de sistemas computacionais no auxílio de decisões não é muito usado. O objetivo desse trabalho é mostrar uma metodologia eficiente no auxílio de predição em transplante renal. Foram utilizadas as técnicas de RNA e Análise de Componentes Principais, com a intenção de reduzir as variáveis de entrada da RNA. Os dados foram obtidos no Departamento de Nefrologia do hospital Universitário Pedro Ernesto – RJ. A utilização da ACP resultou em significativa melhoria do desempenho e do processo de modelagem de RNA.

## **CAPÍTULO IV**

# 4. APLICAÇÃO DOS MÉTODOS PARA RESOLUÇÃO DO PROBLEMA E ANÁLISE DOS RESULTADOS

## 4.1 APLICAÇÃO DAS RNAs PARA RESOLUÇÃO DO PROBLEMA

Conforme descrito no capítulo II, os métodos propostos neste trabalho foram aplicados após a coleta e o tratamento dos dados dos 108 processos analisados, que foram ajuizados no ano de 2006, junto ao Fórum Trabalhista de São José dos Pinhais - PR. Todos os dados retirados de cada um dos processos trabalhistas serviram para compor a matriz de entrada da RNA. Dessa forma, a fim de executar o treinamento e testes da RNA foi implementado um programa utilizando o *Software Visual Basic* 6.0.

Para a realização do treinamento da RNA foi utilizado o algoritmo supervisionado *back-propagation* e a função de ativação, em todos os neurônios, foi a sigmoidal, como já mencionado, que fornece saídas entre (0, 1) para entradas no intervalo (-∞, ∞). Devido a essas condições da função de ativação, foi necessário enquadrar as saídas, ou seja, o tempo de duração de cada audiência, que variam de 1 a 93 minutos, ao intervalo de (0, 1). O enquadramento das saídas foi realizado dividindo-as pelo maior valor que no caso, é 93.

A arquitetura ou topologia da RNA adotada apresenta somente uma camada oculta. Essa decisão é baseada no Teorema da Aproximação Universal (HAYKIN, 2002). Esse teorema afirma que uma única camada oculta é suficiente para um *perceptron* de multicamadas computar uma aproximação uniforme para um dado conjunto de treinamento, representado pelo conjunto de entradas, e a saída desejada.

Foi adotado o *MSE* (*mean squared error*) para verificar-se a qualidade dos resultados da RNA, tendo por objetivo encontrar o menor erro global para o grupo de teste. O cálculo de *MSE* pode ser obtido através da equação (4.1), a seguir.

$$MSE = \frac{\sum_{i=1}^{n} (d_i^P - a_i^P)^2}{2n}$$
 (4.1)

onde:

 $d_i^P$  é a saída desejada (valor real) para o padrão p;

 $a_i^P$  é a saída obtida para o padrão p (pela rede);

n é o número de padrões a serem avaliados.

A matriz de dados foi dividida em dois grupos, sendo que dos 108 processos analisados aleatoriamente, 75% serviram para realizar o treinamento supervisionado da rede; o restante, ou seja, 25% serviram para o teste da rede. No conjunto de treinamento a saída obtida pela rede era comparada à saída desejada, e assim o conjunto dos pesos da RNA era atualizado através da propagação *backward*.

A partir do conjunto de treinamento, os testes I, II, III e IV, descritos a seguir, foram realizados com um número previamente determinado de iterações, de maneira a se obter o menor erro possível dentro do conjunto de testes, buscando encontrar a melhor arquitetura para a RNA. Em seguida, variou-se o número de iterações, a fim de encontrar a melhor topologia. A cada iteração os pesos sinápticos eram alterados e atualizados automaticamente, até obter o melhor conjunto de pesos.

O conjunto de testes foi utilizado para verificar o grau de aprendizado da rede, através do MSE. Durante o teste da RNA os pesos sinápticos não são mais alterados, ou seja, os melhores pesos encontrados no treinamento são aplicados no grupo de testes, a fim de se verificar o grau de aprendizagem da RNA.

Com o objetivo de facilitar o entendimento, a nomenclatura da RNA foi escolhida de forma a representar, pela ordem, as seguintes características: número de entradas, número de neurônios na camada oculta e o número de iterações. Logo, a denominação das redes começa com o número correspondente à quantidade de entradas (letra E), seguido do número de neurônios na camada oculta (letra N), e

finalmente o número de iterações (letra I). Por exemplo, uma rede com a topologia E15N2I50, é uma rede que representa 15 entradas, dois neurônios na camada oculta e foi treinada com 50 iterações.

Foram realizados quatro tipos de testes. No primeiro a maioria das entradas foram codificadas, conforme mencionado no capítulo II. No segundo teste, além das entradas serem codificadas, também foi realizada a Análise de Componentes Principais (ACP). No terceiro as variáveis ordinais, ou seja, os atributos salário, tempo de serviço e número de audiências, não foram codificados e a matriz de dados foi submetida ao processo de análise de componentes principais a fim de avaliar a importância relativa das variáveis que a compõem. No último teste as variáveis ordinais não foram codificadas e a matriz de dados não foi submetida a ACP. O fluxograma mostrado na figura 4.1, a seguir, ilustra os tipos de testes realizados.

Dados Codificação Codificação de Variáveis de Variáveis Qualitativas Teste II Teste III . Teste IV Teste I **RNA RNA RNA** RNA com sem com sem **ACP ACP ACP** ACP

FIGURA 4.1. FLUXOGRAMA DOS TESTES REALIZADOS

#### 4.1.1 Teste I

No primeiro teste realizado as entradas foram codificadas conforme descrito no capítulo II. Foram utilizados, em todos os testes, 4 conjuntos de pesos iniciais.

Neste teste cada padrão apresenta um vetor de entrada com 30 coordenadas. As saídas foram ajustadas de acordo com a função de transferência sigmoidal, conforme já mencionada anteriormente.

A camada de entrada ficou definida com 30 neurônios e a camada de saída com um neurônio. Nesse momento o objetivo era definir o melhor número de neurônios da camada oculta. Inicialmente variou-se de um até 15 o número de neurônios na camada oculta. Foram realizadas 50 iterações para cada uma das topologias. A melhor arquitetura obtida voltou a ser treinada, agora variando-se o número de iterações. O quadro 4.1 a seguir apresenta as redes consideradas com melhor desempenho; na primeira coluna tem-se o número da simulação, na segunda coluna tem-se a topologia adotada, na terceira coluna o erro do conjunto de treinamento (MSE Tr) e na última o erro do conjunto de testes (MSE Tes), ambos os erros foram calculados através da equação 4.1, descrita anteriormente.

QUADRO 4.1. TOPOLOGIA DO PRIMEIRO TESTE

Simulação	Topologia	MSE Tr	MSE Tes
1	E30N1I50	0,00440	0,14169
2	E30N2I50	0,00275	0,03378
3	E30N3I50	0,00340	0,02384
4	E30N4I50	0,00245	0,02513
5	E30N5I50	0,00203	0,00893
6	E30N6I50	0,00164	0,00910
7	E30N7I50	0,00172	0,01427
8	E30N8I50	0,00181	0,01182
9	E30N9I50	0,00246	0,02277
10	E30N10I50	0,00112	0,05406
11	E30N11I50	0,00149	0,01151
12	E30N12I50	0,00131	0,04626
13	E30N13I50	0,00128	0,01728
14	E30N14I50	0,00193	0,02538
15	E30N15I50	0,00193	0,02538

No quadro 4.1 percebe-se que a melhor arquitetura é a que apresenta 5 neurônios na camada escondida, onde verifica-se que o MSE para o conjunto de

teste é igual a 0,00893, ou seja, é a topologia que apresenta a melhor generalização.

Verificada a melhor topologia, a rede voltou a ser treinada, agora variando-se o número de iterações, com o objetivo de reduzir o MSE no grupo de teste. O quadro 4.2 a seguir apresenta os valores mais importantes deste treinamento.

QUADRO 4.2. RESULTADOS NUMÉRICOS DAS SIMULAÇÕES DO TESTE I COM VARIAÇÃO DO NÚMERO DE ITERAÇÕES.

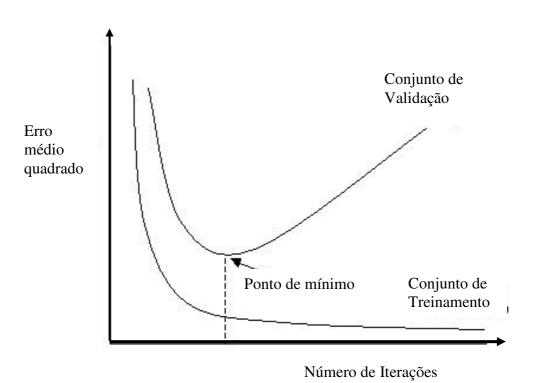
SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
1	E30N5I10	0,00869	0,00694
2	E30N5I20	0,00639	0,00667
3	E30N5I30	0,00400	0,00653
4	E30N5I40	0,00258	0,00778
5	E30N5I50	0,00203	0,00893
6	E30N5I60	0,00182	0,00977
7	E30N5I70	0,00167	0,01056
8	E30N5I80	0,00151	0,01139
9	E30N5I90	0,00135	0,01232
10	E30N5I100	0,00120	0,01328
11	E30N5I150	0,00066	0,01551
12	E30N5I200	0,00045	0,01737
13	E30N5I300	0,00033	0,01760
14	E30N5I400	0,00023	0,01730
15	E30N5I500	0,00019	0,01802
16	E30N5I600	0,00016	0,01790
17	E30N5I700	0,00014	0,01791
18	E30N5I800	0,00013	0,01803
19	E30N5I900	0,00027	0,01963
20	E30N5I1000	0,00012	0,01802

Verifica-se através do quadro 4.2 que o melhor resultado apresentado para este teste, possui a topologia E30N5I30 onde o valor do MSE no grupo de testes é igual a 0,00653. Pode-se observar através do quadro 4.2 que o MSE do conjunto de treinamento diminui consideravelmente à medida que o número de iterações vai aumentando, chegando a atingir o valor mínimo de 0,00012 com 1000 iterações. Já no conjunto de teste o MSE diminui a medida que aumentam o número de iterações até atingir o valor mínimo em 30 iterações, a partir de então o erro passa a aumentar

a medida que se aumenta o número de iterações. Esse aumento do erro a partir de certa quantidade de iterações se deve ao excesso de treinamento. Todas as vezes que acontece excesso de treinamento, as RNAs podem perder a capacidade de generalização, passando a apresentar baixo valor de erro para o conjunto de treinamento, porém um valor elevado do erro para o grupo de teste, prejudicando assim o desempenho da rede.

A figura 4.2 mostra formas conceituais de duas curvas de aprendizagem, uma em relação ao conjunto de treinamento e outra em relação ao conjunto de teste. As curvas são distintas, sendo que a curva de aprendizagem de treinamento decresce monotonamente para um número crescente de iterações. Já a curva de aprendizagem de teste decresce até um mínimo e então volta a crescer à medida que o treinamento prossegue.

FIGURA 4.2 TREINAMENTO VERSUS CAPACIDADE DE GENERALIZAÇÃO DA RNA



FONTE: HAYKIN (2002)

A impressão inicial que se tem quando é observada uma curva de aprendizagem é que poder-se-ia aumentar o desempenho de uma rede indo além do ponto mínimo, porém, o que a RNA aprende após esse ponto é somente ruído contido nos dados do treinamento. Esse procedimento sugere que o ponto mínimo na curva de aprendizagem seja usado como critério para encerrar o treinamento.

#### 4.1.2 Teste II

Neste teste, além da codificação, as RNAs foram treinadas após a ACP, cujo objetivo é o de avaliar a importância relativa das variáveis que compõem a amostra de dados. Para esse treinamento, a fim de obter a ACP, foi utilizado *software STATIGRAPHICS PLUS* 5.1.

As componentes principais, que são as combinações lineares das variáveis principais, seus autovalores e variâncias são mostrados no quadro 4.3, onde se verifica, por exemplo, que quando se utilizam as componentes de número 1 até o 20 está se representando a estrutura de covariância inicial com uma fidelidade de 90,135%. Utilizando as 15 primeiras, tem-se uma fidelidade de 79,758% e fazendose o uso das 11 primeiras componentes a fidelidade cai para 68,135%. Ainda através do quadro 4.3 pode-se verificar que das 30 variáveis que compõem o vetor de entrada bastam as 29 iniciais para representar toda a variância do conjunto de dados, já que a última apresenta variância nula.

QUADRO 4.3. AUTOVALORES EM ORDEM DECRESCENTE TESTE II

COMPONENTES		VARIÂNCIA	
NÚMERO	AUTOVALOR	PERCENTUAL	ACUMULADA
1	3,9204	13,068	13,068
2	2,52594	8,42	21,488
3	2,17464	7,249	28,737
4	1,89857	6,329	35,065
5	1,7306	5,769	40,834
6	1,63687	5,456	46,29
7	1,48324	4,944	51,234
8	1,42319	4,744	55,978
9	1,2618	4,206	60,184

continuação

COMPONENTES		VARIÂNCIA	
NÚMERO	AUTOVALOR	PERCENTUAL	ACUMULADA
10	1,23836	4,128	64,312
11	1,147	3,823	68,135
12	0,998403	3,328	71,463
13	0,895756	2,986	74,449
14	0,830929	2,77	77,219
15	0,761756	2,539	79,758
16	0,69511	2,317	82,075
17	0,692883	2,31	84,385
18	0,601734	2,006	86,391
19	0,583524	1,945	88,336
20	0,539792	1,799	90,135
21	0,488334	1,628	91,763
22	0,450646	1,502	93,265
23	0,419616	1,399	94,664
24	0,353124	1,177	95,841
25	0,330967	1,103	96,944
26	0,3021	1,007	97,951
27	0,258842	0,863	98,814
28	0,199732	0,666	99,48
29	0,156127	0,52	100
30	0	0	100

O número de componentes a ser utilizado varia de acordo com a necessidade de fidelidade de informação que se deseja. Utilizando-se 15 componentes principais é observada uma fidelidade de quase 80% em relação ao conjunto original, porém, está se reduzindo o conjunto de dados para 50% do original. Fazendo o uso das 11 primeiras componentes principais, a fidelidade é de pouco mais de 68%, sempre em relação ao conjunto original, mas o conjunto de dados reduz-se a aproximadamente 37% do original. A figura 4.3 a seguir mostra os autovalores das respectivas componentes principais.

FIGURA 4.3. AUTOVALORES VERSUS COMPONENTES DA ACP - TESTE II

Assim, foram treinadas neste Teste II, redes com 30, 15 e 11 componentes principais, respectivamente denominados como testes: II.1, II.2 e II.3. A fim de encontrar o número de neurônios da camada oculta que apresentasse o melhor resultado, a rede foi treinada com 50 iterações variando o número de neurônios na camada escondida de um até 15. De posse da melhor arquitetura, variou-se o número de iterações de 10 até 1000, sempre buscando encontrar o menor erro possível no grupo de teste. Os resultados mais relevantes das topologias do teste II são apresentados no quadro 4.4 a seguir. O Apêndice VI apresenta os resultados completos do teste II.1.

Componentes

QUADRO 4.4. TOPOLOGIAS DO TESTE II.1 COM 30 COMPONENTES PRINCIPAIS

SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
1	E30N1I50	0,00368	0,01845
2	E30N2I50	0,00244	0,02811
3	E30N3I50	0,00095	0,03154
4	E30N4I50	0,00082	0,07066
5	E30N5I50	0,00072	0,03289
6	E30N6I50	0,00052	0,01832

continuação

SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
7	E30N7I50	0,00051	0,07542
8	E30N8I50	0,00065	0,05511
9	E30N9I50	0,00066	0,01376
10	E30N10I50	0,00046	0,00562
11	E30N11I50	0,00050	0,02122
12	E30N12I50	0,00062	0,02392
13	E30N13I50	0,00051	0,02115
14	E30N14I50	0,00056	0,03212
15	E30N15I50	0,00041	0,02349

Através do quadro 4.4, pode-se verificar que, realizadas as simulações variando os neurônios da camada escondida de 1 a 15, o melhor resultado encontrase na simulação com 10 neurônios na camada escondida. Novamente a rede é treinada, agora variando o número de iterações de 10 a 1000, sempre buscando encontrar o menor MSE no grupo de teste. Os resultados podem ser vistos no quadro 4.5 a seguir, enquanto os dados completos do teste II.1 compõem o Apêndice VII.

QUADRO 4.5. VARIAÇÃO DO NÚMERO DE ITERAÇÕES DO TESTE II.1 COM 30 COMPONENTES PRINCIPAIS

SIMULAÇÃO	TOPOLOGIA	RMSE Tr	RMSE Tes
1	E30N10I10	0,00869	0,00694
2	E30N10I20	0,00167	0,00563
3	E30N10I30	0,00090	0,00544
4	E30N10I40	0,00061	0,00556
5	E30N10I50	0,00046	0,00562
6	E30N10I60	0,00037	0,00568
7	E30N10I70	0,00032	0,00573
8	E30N10I80	0,00028	0,00577
9	E30N10I90	0,00026	0,00580
10	E30N10I100	0,00024	0,00581
11	E30N10I200	0,00014	0,00581
12	E30N10I300	0,00009	0,00635
13	E30N10I400	0,00006	0,00714
14	E30N10I500	0,00004	0,00762
15	E30N10I1000	0,00001	0,00857

O melhor resultado, conforme se pode verificar no quadro 4.5 é obtido na terceira simulação, cuja topologia é E30N10I30 onde se tem 30 iterações e MSE igual a 0,00544 no grupo de teste.

O treinamento apresentado a seguir na quadro 4.6, foi realizado com as 15 primeiras componentes principais. Este número de componentes utilizadas teve por objetivo reduzir a cardinalidade do conjunto de dados a 50% do valor original. Porém, cabe ressaltar que a fidelidade de informações cai para 79,758%, conforme observado. Aqui novamente o treinamento foi realizado variando-se o número de neurônios da camada oculta de 1 a 15, sempre buscando o menor MSE possível.

QUADRO 4.6. TOPOLOGIAS DO TESTE II.2 COM 15 COMPONENTES PRINCIPAIS

SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
1	E15N1I50	0,00975	0,02811
2	E15N2I50	0,00698	0,02288
3	E15N3I50	0,00579	0,01990
4	E15N4I50	0,00523	0,21091
5	E15N5I50	0,00373	0,03340
6	E15N6I50	0,00229	0,09939
7	E15N7I50	0,00233	0,10476
8	E15N8I50	0,00281	0,02543
9	E15N9I50	0,00267	0,02844
10	E15N10I50	0,00221	0,04619
11	E15N11I50	0,00251	0,02290
12	E15N12I50	0,00113	0,02051
13	E15N13I50	0,00148	0,04437
14	E15N14I50	0,00172	0,01682
15	E15N15I50	0,00176	0,03966

A partir do quadro 4.6, pode-se verificar que a melhor arquitetura da rede é E15N14I50, ou seja, a RNA composta por 14 neurônios na camada oculta, a qual apresenta MSE é igual a 0,01686. A rede volta a ser treinada com 14 neurônios na camada escondida, variando-se apenas o número de iterações, sempre buscando o menor MSE no grupo de teste. Os resultados mais importantes apresentam-se no quadro 4.7, a seguir.

QUADRO 4.7. NÚMERO DE ITERAÇÕES DO TESTE II.2 COM 15 COMPONENTES PRINCIPAIS

SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
1	E15N14I10	0,01127	0,01616
2	E15N14I20	0,00570	0,01581
3	E15N14I30	0,00289	0,01723
4	E15N14I40	0,00210	0,01734
5	E15N14I50	0,00172	0,01682
6	E15N14I60	0,00156	0,01645
7	E15N14I70	0,00145	0,01622
8	E15N14I80	0,00135	0,01608
9	E15N14I90	0,00127	0,01599
10	E15N14I100	0,00118	0,01592
11	E15N14I200	0,00047	0,01695
12	E15N14I300	0,00026	0,01912
13	E15N14I400	0,00012	0,02127
14	E15N14I500	0,00007	0,02256
15	E15N14I1000	0,00004	0,02175

Pode-se observar a partir do quadro 4.7 que o menor MSE no grupo de teste é obtido quando a rede é treinada com 20 iterações, apresentando um valor igual a 0,01581. Pode-se verificar ainda que quando utilizam-se apenas 15 componentes os resultados não são tão bons como quando utilizam-se todas, pois houve uma perda de aproximadamente 20% na fidelidade das informações.

O próximo treinamento é realizado com apenas 11 componentes principais. Este treinamento foi realizado usando o critério de Kaiser (JOHNSON E WICHERN, 2002), segundo o qual se mantêm somente as componentes cujos autovalores são superiores a um. Este treinamento mantém uma fidelidade de informações de 68,135% do valor original, conforme já mencionado. É realizado de maneira análoga aos anteriores. Os resultados mais importantes se encontram no quadro 4.8, a seguir.

QUADRO 4.8. TOPOLOGIAS DO TESTE II.3 COM 11 COMPONENTES PRINCIPAIS

SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
1	E11N1I50	0,01034	0,02642
2	E11N2I50	0,00967	0,07422
3	E11N3I50	0,00714	0,08801
4	E11N4I50	0,00658	0,06438
5	E11N5I50	0,00543	0,09374
6	E11N6I50	0,00441	0,07347
7	E11N7I50	0,00357	0,13946
8	E11N8I50	0,00291	0,02555
9	E11N9I50	0,00318	0,04285
10	E11N10I50	0,00392	0,05619
11	E11N11I50	0,00358	0,05021
12	E11N12I50	0,00314	0,18189
13	E11N13I50	0,00354	0,03748
14	E11N14I50	0,00285	0,04511
15	E11N15I50	0,00343	0,08971

Através do quadro 4.8 pode-se verificar que o menor MSE no grupo de teste, cujo valor é igual a 0,02555, ocorre quando o número de neurônios na camada oculta é igual a oito. A rede é treinada novamente com oito neurônios na camada oculta e variando apenas o número de iterações, buscando encontrar o menor MSE no grupo de teste. O quadro 4.9 mostra os resultados relevantes.

QUADRO 4.9. VARIAÇÃO DO NÚMERO DE ITERAÇÕES DO TESTE II.3 COM 11 COMPONENTES PRINCIPAIS

SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
1	E11N8I10	0,01103	0,02699
2	E11N8I20	0,00615	0,02432
3	E11N8I30	0,00414	0,02354
4	E11N8I40	0,00336	0,02446
5	E11N8I50	0,00291	0,02555
6	E11N8I60	0,00262	0,02618
7	E11N8I70	0,00241	0,02661
8	E11N8I80	0,00225	0,02698
9	E11N8I90	0,00213	0,02730
10	E11N8I100	0,00203	0,02747

continuação

SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
11	E11N8I200	0,00159	0,02928
12	E11N8I300	0,00150	0,03108
13	E11N8I400	0,00144	0,03303
14	E11N8I500	0,00139	0,03633
15	E11N8I1000	0,00053	0,05012

Verifica-se, a partir do quadro 4.9, que o menor MSE no grupo de teste é obtido quando a rede é treinada com 30 iterações.

Observa-se que os erros vão aumentando à medida que o número de componentes principais vai diminuindo. Isso acontece devido à perda de informações ao se desprezarem algumas componentes. No caso de 30 componentes o erro é igual a 0,00544 (quadro 4.5); já com 15 componentes principais o erro passa para 0,01581 (quadro 4.7), e com 11 componentes o erro é de 0,02354 (quadro 4.9).

#### 4.1.3 Teste III

Para a realização desse teste foram utilizados os mesmos dados dos testes anteriores, porém, as variáveis ordinais (salário, tempo de serviço e número de audiências) não foram codificadas. Assim o vetor de entrada da RNA possui apenas 25 coordenadas, gerando uma matriz de108 linhas por 25 colunas.

A matriz de dados, neste teste, também foi submetida à ACP para uma avaliação estatística dos dados, com o propósito avaliar a importância relativa das variáveis que compõem a amostra. No quadro 4.10, a seguir, podem ser observadas as componentes principais, seus respectivos autovalores, bem como a variância percentual e acumulada.

QUADRO 4.10 AUTOVALORES EM ORDEM DECRESCENTE TESTE III

COMP	ONENTES	VARIÂNCIA	
NÚMERO	AUTOVALOR	PERCENTUAL	ACUMULADA
1	2,81704	11,268	11,268
2	2,40709	9,62	20,897
3	1,98024	7,921	28,817
4	1,73261	6,93	35,748
5	1,63125	6,525	42,273
6	1,57179	6,287	48,56
7	1,41519	5,661	54,221
8	1,33975	5,359	59,58
9	1,16264	4,651	64,23
10	1,07975	4,319	68,549
11	0,96021	3,841	72,39
12	0,865868	3,463	75,854
13	0,802393	3,21	79,063
14	0,738991	2,956	82,019
15	0,684911	2,74	84,759
16	0,587244	2,349	87,108
17	0,557988	2,232	89,34
18	0,508703	2,035	91,375
19	0,460658	1,843	93,217
20	0,418356	1,673	94,891
21	0,391953	1,568	96,459
22	0,348022	1,392	97,851
23	0,282156	1,129	98,979
24	0,255193	1,021	100
25	3,09x10 <sup>-17</sup>	0	100

Pode-se verificar, analisando o quadro 4.10, que a componente 25 apresenta variância nula. Logo, se a mesma for descartada, o conjunto não sofre nenhum tipo de perda de informação.

A figura 4.4, a seguir, mostra o gráfico, relacionando as componentes principais e seus respectivos autovalores.

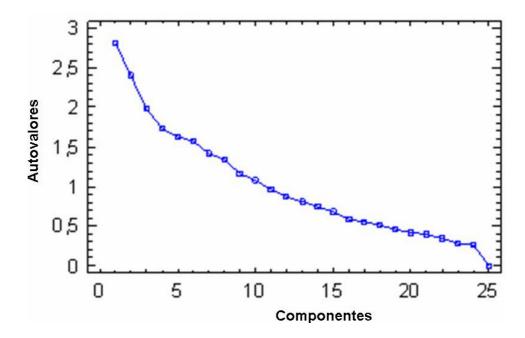


FIGURA 4.4. AUTOVALORES VERSUS COMPONENTES DA ACP - TESTE III

Esse teste foi realizado com três conjuntos iniciais de dados. Primeiramente foram utilizadas as 25 componentes principais (teste III.1). O segundo treinamento foi feito com 13 componentes principais (teste III.2), reduzindo a matriz de dados praticamente pela metade. E o terceiro foi realizado mantendo somente as componentes com autovalores maiores que um (critério de Kaiser), ou seja, 10 componentes principais (teste III.3).

Os testes foram realizados segundo os mesmos critérios dos testes anteriores. Primeiramente as redes foram treinadas com 50 iterações, variando o número de neurônios de 1 a 15 na camada oculta. Encontrado o menor erro, a mesma rede volta a ser treinada, agora variando somente o número de iterações, de 10 até 1000, a fim de obter o menor MSE no grupo de teste. Os resultados mais relevantes encontram-se no quadro 4.11 a seguir:

QUADRO 4.11. TOPOLOGIAS DO TESTE III.1 COM 25 COMPONENTES PRINCIPAIS

SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
1	E25N1I50	0,00402	0,01299
2	E25N2I50	0,00225	0,02651
3	E25N3I50	0,00108	0,03123
4	E25N4I50	0,00072	0,02424
5	E25N5I50	0,00101	0,04129
6	E25N6I50	0,00093	0,03453
7	E25N7I50	0,00125	0,02005
8	E25N8I50	0,00049	0,01765
9	E25N9I50	0,00042	0,01850
10	E25N10I50	0,00029	0,03223
11	E25N11I50	0,00096	0,02840
12	E25N12I50	0,00043	0,01792
13	E25N13I50	0,00080	0,01570
14	E25N14I50	0,00046	0,01131
15	E25N15I50	0,00053	0,02191

De acordo com o quadro 4.11, pode-se verificar que a melhor topologia se encontra na simulação 14, onde o número de neurônios na camada escondida é igual a 14. Essa RNA voltou a ser treinada, agora variando somente o número de iterações, sempre buscando encontrar o menor erro dentro do grupo de teste. O quadro 4.12, a seguir, mostra os melhores resultados.

QUADRO 4.12. NÚMERO DE ITERAÇÕES DO TESTE III.1 COM 25 COMPONENTES PRINCIPAIS

SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
1	E25N14I10	0,00264	0,01191
2	E25N14I20	0,00137	0,01434
3	E25N14I30	0,00085	0,01426
4	E25N14I40	0,00060	0,01273
5	E25N14I50	0,00046	0,01131
6	E25N14I60	0,00038	0,01041
7	E25N14I70	0,00032	0,00992
8	E25N14I80	0,00028	0,00970
9	E25N14I90	0,00024	0,00958

continuação

SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
10	E25N14I100	0,00022	0,00949
11	E25N14I200	0,00006	0,00845
12	E25N14I300	0,00002	0,00829
13	E25N14I400	0,00002	0,00850
14	E25N14I500	0,00001	0,00868
15	E25N14I1000	0,00001	0,00901

Através do quadro 4.12 verifica-se que a melhor topologia é E25N14I300, ou seja, com 300 iterações obtém-se o menor erro dentro do grupo de teste, cujo valor é igual a 0,00829.

O treinamento seguinte foi realizado com 13 componentes principais, reduzindo-se a quase 50% a matriz de dados inicial. Novamente para esse treinamento variou-se o número de neurônios na camada escondida, e manteve-se o número de iterações igual a 50. Os resultados encontram-se no quadro 4.13, a seguir.

QUADRO 4.13. TOPOLOGIAS DO TESTE III.2 COM 13 COMPONENTES PRINCIPAIS

011111111111111111111111111111111111111	TOPOL OOLA	MOET	MOET
SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
1	E13N1I50	0,00846	0,02662
2	E13N2I50	0,00779	0,01674
3	E13N3I50	0,00605	0,06607
4	E13N4I50	0,00410	0,03033
5	E13N5I50	0,00521	0,03127
6	E13N6I50	0,00390	0,03903
7	E13N7I50	0,00615	0,02062
8	E13N8I50	0,00231	0,02469
9	E13N9I50	0,00185	0,05266
10	E13N10I50	0,00206	0,06833
11	E13N11I50	0,00244	0,01923
12	E13N12I50	0,00223	0,02759
13	E13N13I50	0,00241	0,02207
14	E13N14I50	0,00330	0,04133
15	E13N15I50	0,00175	0,01571

Pode-se verificar que a melhor arquitetura da rede é a que apresenta 15 neurônios na camada escondida. A fim de encontrar o menor erro fez-se variar o número de iterações de 10 até 1000. Os resultados relevantes estão no quadro 4.14.

QUADRO 4.14. NÚMERO DE ITERAÇÕES DO TESTE III.2 COM 13 COMPONENTES PRINCIPAIS

SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
1	E13N15I10	0,01028	0,01448
2	E13N15I20	0,00639	0,01776
3	E13N15I30	0,00391	0,01880
4	E13N15I40	0,00254	0,01694
5	E13N15I50	0,00175	0,01571
6	E13N15I60	0,00137	0,01519
7	E13N15I70	0,00117	0,01497
8	E13N15I80	0,00102	0,01498
9	E13N15I90	0,00086	0,01505
10	E13N15I100	0,00062	0,01521
11	E13N15I200	0,00022	0,01698
12	E13N15I300	0,00016	0,01750
13	E13N15I400	0,00014	0,01772
14	E13N15I500	0,00013	0,01795
15	E13N15I1000	0,00002	0,01559

O quadro 4.14 anterior mostra que na arquitetura com 15 neurônios na camada oculta, bastam apenas 10 iterações para se obter a melhor topologia cujo erro é igual a 0,01448.

No treinamento seguinte, utilizaram-se somente as 10 primeiras componentes principais. O descarte das demais componentes foi realizado de acordo com o critério de Kaiser, que diz que as componentes que devem ser mantidas são as que possuem autovalores maiores de um. A redução de 25 para 10 coordenadas do vetor de entrada de dados acarreta uma perda de informações de 31,451% em relação ao conjunto de dados inicial.

De maneira análoga aos outros treinamentos, esse foi realizado inicialmente variando o número de neurônios da camada escondida de um até 15, sempre

buscando o menor erro possível. O quadro 4.15 a seguir, mostra os melhores resultados.

QUADRO 4.15. TOPOLOGIAS DO TESTE III.3 COM 10 COMPONENTES PRINCIPAIS

SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
1	E10N1I50	0,00926	0,02739
2	E10N2I50	0,00951	0,02253
3	E10N3I50	0,00891	0,06109
4	E10N4I50	0,00823	0,03365
5	E10N5I50	0,00740	0,03300
6	E10N6I50	0,00596	0,03419
7	E10N7I50	0,00581	0,13684
8	E10N8I50	0,00309	0,05066
9	E10N9I50	0,00415	0,03323
10	E10N10I50	0,00326	0,03336
11	E10N11I50	0,00327	0,07192
12	E10N12I50	0,00588	0,03868
13	E10N13I50	0,00507	0,02769
14	E10N14I50	0,00311	0,04241
15	E10N15I50	0,00336	0,03109

De acordo com o quadro 4.15, verifica-se que a melhor arquitetura é a que apresenta dois neurônios na camada oculta. Essa RNA volta a ser treinada, agora variando o número de iterações, conforme mostra o quadro 4.16 a seguir.

QUADRO 4.16. NÚMERO DE ITERAÇÕES DO TESTE III.3 COM 10 COMPONENTES PRINCIPAIS

SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
1	E10N2I10	0,01321	0,01734
2	E10N2I20	0,01120	0,01951
3	E10N2I30	0,01047	0,02094
4	E10N2I40	0,00994	0,02193
5	E10N2I50	0,00951	0,02253
6	E10N2I60	0,00920	0,02285
7	E10N1I70	0,00895	0,02295
8	E10N1I80	0,00876	0,02288

continuação

SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
9	E10N2I90	0,00860	0,02273
10	E10N2I100	0,00846	0,02261
11	E10N2I200	0,00774	0,02231
12	E10N2I300	0,00733	0,02163
13	E10N2I400	0,00713	0,02130
14	E10N2I500	0,00677	0,02101
15	E10N2I1000	0,00521	0,02157

Observa-se, a partir do quadro 4.16 que a melhor arquitetura é a que apresenta dez iterações com dois neurônios na camada escondida, onde o erro igual a 0,01734.

#### 4.1.4 Teste IV

Na realização desse teste foi utilizada a mesma matriz de dados do teste anterior, porém, sem aplicação da ACP.

Tal qual os testes anteriores, primeiramente fez-se variar o número de neurônios na camada escondida de um até 15 a fim de encontrar a melhor topologia para a RNA. O quadro 4.17 a seguir mostra os resultados mais importantes para este teste.

QUADRO 4.17. TOPOLOGIA DO QUARTO TESTE

SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
1	E25N1I50	0,13588	0,11967
2	E25N2I50	0,17542	0,08235
3	E25N3I50	0,17309	0,14133
4	E25N4I50	0,18372	0,07653
5	E25N5I50	0,18578	0,10141
6	E25N6I50	0,18308	0,11393
7	E25N7I50	0,17969	0,09052
8	E25N8I50	0,18783	0,10570
9	E25N9I50	0,18655	0,06035

Continua

continuação

SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
10	E25N10I50	0,18814	0,08033
11	E25N11I50	0,18274	0,11777
12	E25N12I50	0,18819	0,11430
13	E25N13I50	0,18955	0,08687
14	E25N14I50	0,18877	0,06925
15	E25N15I50	0,18724	0,07789

De acordo com O quadro 4.17 pode-se verificar que a melhor arquitetura foi obtida na simulação nove, onde a RNA apresenta 25 neurônios na camada de entrada e nove neurônios na camada oculta. Essa RNA voltou a ser treinada, agora fazendo-se variar o número de iterações a fim de encontrar o menor erro no grupo de testes. O quadro 4.18 a seguir apresenta os melhores resultados.

QUADRO 4.18. NÚMERO DE ITERAÇÕES DO QUARTO TESTE

SIMULAÇÃO	TOPOLOGIA	MSE Tr	MSE Tes
1	E25N9I10	0,13719	0,06453
2	E25N9I20	0,16771	0,06241
3	E25N9I30	0,17770	0,05793
4	E25N9I40	0,18207	0,05869
5	E25N9I50	0,18442	0,05944
6	E25N9I60	0,18595	0,06007
7	E25N9I70	0,18706	0,06062
8	E25N9I80	0,18792	0,06109
9	E25N9I90	0,18860	0,06153
10	E25N9I100	0,19208	0,06463
11	E25N9I200	0,19344	0,06624
12	E25N9I300	0,19417	0,06726
13	E25N9I400	0,19465	0,06800
14	E25N9I500	0,19546	0,06944
15	E25N9I1000	0,19577	0,07007

Verifica-se através do quadro 4.18, que o melhor resultado para esse teste é obtido a partir da topologia E25N9I30, o qual apresenta MSE igual a 0,05793 para o conjunto de teste.

## 4.2 ANÁLISE DOS RESULTADOS OBTIDOS DAS RNAs

Com o objetivo de encontrar uma previsão de duração do tempo de audiências trabalhista, foram treinadas diversas RNAs com as mais variadas topologias.

No quadro 4.19 a seguir, têm-se os melhores resultados, ou seja, as topologias que apresentaram o menor MSE, para cada um dos quatro testes.

TESTE	TOPOLOGIA	MSE Tr	MSE Tes
I	E30N5I30	0,00400	0,00653
II.1	E30N10I30	0,00090	0,00544
II.2	E15N14I20	0,00570	0,01581
II.3	E11N8I30	0,00414	0,02354
III.1	E25N14I300	0,00002	0,00829
III.2	E13N15I10	0,01028	0,01448
III.3	E10N2I10	0,01321	0,01734
IV	E25N9I30	0,17770	0,05793

QUADRO 4.19. MELHORES RESULTADOS DAS REDES NEURAIS

De acordo com a análise realizada no quadro 4.19, é possível verificar que a RNA do Teste II.1 apresentou o melhor desempenho, ou seja, apresentou o menor erro no conjunto de teste. Neste teste a matriz de dados foi codificada, em seguida submetida a ACP e mantidas todas as suas componentes no treinamento. Os resultados do teste realizado encontram-se no Apêndice VIII.

# 4.3 APLICAÇÃO DA ANÁLISE DE REGRESSÃO LINEAR MÚLTIPLA PARA RESOLUÇÃO DO PROBLEMA.

Na aplicação da técnica de Regressão Linear utilizou-se o mesmo conjunto de dados das RNAs. As tabelas de dados foram construídas no *software Excel*, e o *software* utilizado para a validação dos resultados do método de Regressão Linear Múltipla foi o *STATIGRAPHICS* plus 5.1.

Assim como nas RNAs, esta ferramenta foi aplicada nos três tipos de testes com o objetivo de comparar os resultados obtidos. No primeiro teste as entradas foram codificadas sem a ACP. No segundo teste as entradas foram codificadas e foi realizado ACP, e no terceiro os dados não foram codificados e foi aplicado a ACP.

### 4.3.1 Teste I com Regressão Linear Múltipla

Neste teste foi ajustado o modelo de Regressão Linear Múltipla para os dados da matriz codificada e sem ACP.

Verificou-se, através do ajuste ao modelo  $y = X\beta + \varepsilon$ , que algumas variáveis não são significativamente importantes, com isso, o *software* utilizado exclui estas variáveis, trabalhando apenas com as mais relevantes. Dessa maneira, foram realizados dois testes, o primeiro com todas as variáveis e o segundo retirando as variáveis menos importantes do modelo. O quadro 4.20, a seguir, mostra o primeiro teste com todas as variáveis. Na primeira coluna estão listadas as variáveis, na segunda coluna os coeficientes das variáveis e na terceira coluna o erro padrão.

QUADRO 4.20. AJUSTE DO PRIMEIRO TESTE DE REGRESSÃO COM 30 VARIÁVEIS

Variáveis	Coeficientes	Erro Padrão
Col_1	-0,00694	0,029571
Col_2	0,024825	0,028034
Col_3	-0,13918	0,068083
Col_4	0,043421	0,032632
Col_5	0,043432	0,033747
Col_6	-0,05245	0,042454
Col_7	0,194812	0,067601
Col_8	0,036001	0,030199
Col_9	0,005655	0,036034
Col_10	0,028972	0,043014
Col_11	-0,00698	0,0338
Col_12	0,005867	0,029883
Col_13	-0,01305	0,062012
Col_14	0,086171	0,041498
Col_15	0,050107	0,044811
Col_16	-0,06816	0,047912
Col_17	0,047174	0,043636
Col_18	-0,08794	0,058061
Col_19	0,001287	0,050252
Col_20	0,027553	0,037698
Col_21	0,034361	0,040502
Col_22	0,045512	0,032712
Col_23	0,011199	0,047054
Col_24	0,00271	0,011482

#### continuação

Variáveis	Coeficientes	Erro Padrão
Col_25	-0,00726	0,049213
Col_26	-0,02017	0,050829
Col_27	-0,00438	0,052912
Col_29	0,117229	0,009171
Col 30	0,054292	0,038234

A equação de Regressão Linear Múltipla que descreve a relação entre a variável resposta (tempo de audiência) e as trinta variáveis independentes é:

Tempo de audiência =  $-0,00693725*Col_1 + 0,0248247*Col_2 - 0,139184*Col_3 + 0,0434205*Col_4 + 0,0434317*Col_5 - 0,0524453*Col_6 + 0,194812*Col_7 + 0,0360009*Col_8 + 0,00565462*Col_9 + 0,0289723*Col_10 - 0,00697762*Col_11 + 0,00586744*Col_12 - 0,0130531*Col_13 + 0,0861705*Col_14 + 0,0501074*Col_15 - 0,0681554*Col_16 + 0,0471743*Col_17 - 0,0879361*Col_18 + 0,00128702*Col_19 + 0,0275527*Col_20 + 0,0343612*Col_21 + 0,0455119*Col_22 + 0,0111987*Col_23 + 0,00270983*Col_24 - 0,00725797*Col_25 - 0,0201724*Col_26 - 0,00437959*Col_27 + 0,117229*Col_29 + 0,0542923*Col_30$ 

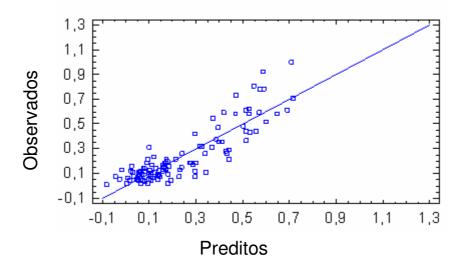
#### onde:

```
Col 1 = objeto do processo: registro;
Col 2 = objeto do processo: diferenças salariais;
Col _3 = objeto do processo: verbas recisórias;
Col 4 = objeto do processo: multa do artigo 477;
Col 5 = objeto do processo: multa do artigo 467:
Col 6 = objeto do processo: horas extras;
Col _7 = objeto do processo: FGTS;
Col 8 = objeto do processo: danos morais;
Col 9 = objeto do processo: seguro desemprego;
Col 10 = objeto do processo: vale transporte;
Col 11 = objeto do processo: adicional insalubridade;
Col 12 = objeto do processo: adicional noturno;
Col 13 = objeto do processo: plano de saúde;
Col 14 = salário do reclamante;
Col 15 = salário do reclamante;
Col 16 = salário do reclamante;
Col 17 = salário do reclamante:
Col _18 = tipo de processo;
Col 19 = tempo de serviço;
Col 20 = tempo de serviço;
Col 21 = tempo de serviço;
Col 22 = profissão;
Col _23 = profissão;
```

```
Col _24 = profissão;
Col _25 = profissão;
Col _26 = juíz;
Col _27 = juíz;
Col _28 = juíz;
Col _29 = número de depoimentos;
Col _30 = acordo.
```

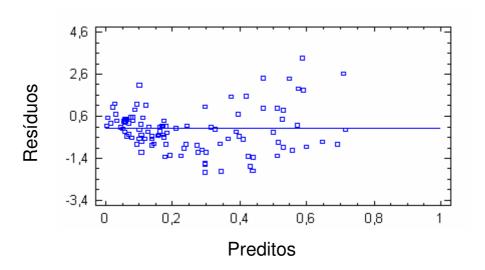
A figura 4.5, a seguir, mostra que os valores preditos estão dispostos em linha diagonal, indicando boa linearidade, ou seja, as previsões se aproximam dos valores reais.

FIGURA 4.5. VALORES PREDITOS X VALORES OBSERVADOS -TESTE I.1



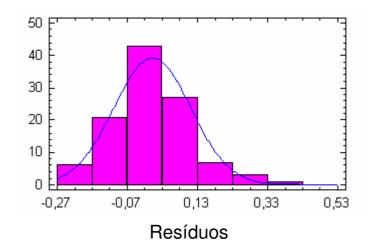
A figura 4.6 a seguir apresenta a relação entre os valores preditos e os resíduos. Verifica-se que os pontos estão distribuídos aleatoriamente em torno da linha que passa pela origem, disposição esta que indica variância constante, ou seja, a condição de homocedasticidade está totalmente satisfeita.

FIGURA 4.6 VALORES PREDITOS X RESÍDUOS -TESTE I.1



O Histograma dos Resíduos, conforme mostra a figura 4.7 a seguir, confirma a sua *Gaussinidade*, ou seja, indica que a distribuição dos resíduos é Gaussiana.

FIGURA 4.7 HISTOGRAMA DOS RESÍDUOS -TESTE I.1



Este teste apresentou um erro médio de 0,01197, que encontra-se no Apêndice IX juntamente com os valores preditos, resíduos e erro quadrático médio de cada processo.

Em seguida foi realizada uma simulação utilizando somente as variáveis mais significativas, apresentadas pelo *software STATIGRAPHICS* plus 5.1. São elas:

verbas rescisórias, multa do artigo 477, FGTS, salário do reclamante, número de depoimentos e acordo. O quadro 4.21 apresenta as variáveis utilizadas, os respectivos valores dos coeficientes e o erro padrão.

QUADRO 4.21 AJUSTE DO PRIMEIRO TESTE DE REGRESSÃO COM SEIS VARIÁVEIS.

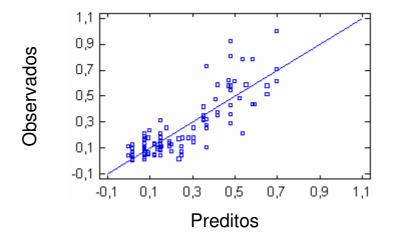
Colunas	Coeficiente	Erro Padrão
Col_3	-0,13257	0,050241
Col_4	0,056407	0,027477
Col_7	0,150753	0,048343
Col_14	0,103671	0,031247
Col_29	0,115028	0,007979
Col_30	0,074464	0,033237

A equação de regressão Linear Múltipla que descreve a relação entre a variável resposta (tempo de audiência) e as seis variáveis independentes é:

Tempo de audiência =  $-0.132568*Col_3 + 0.0564065*Col_4 + 0.150753*Col_7 + 0.103671*Col_14 + 0.115028*Col_29 + 0.074464*Col_30$ 

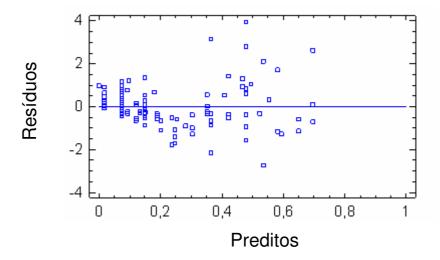
A figura 4.8 a seguir mostra que os valores preditos estão dispostos em linha diagonal, indicando uma linearidade satisfatória, ou seja, as previsões se aproximam dos valores reais.

FIGURA 4.8. VALORES PREDITOS X VALORES OBSERVADOS-TESTE 1.2



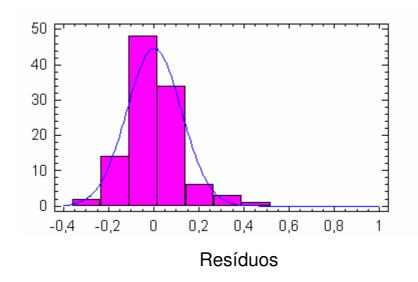
A figura 4.9 a seguir apresenta pontos distribuídos aleatoriamente em torno da linha que passa pela origem, disposição que indica que a suposição de variância constante está correta.

FIGURA 4.9. VALORES PREDITOS X RESÍDUOS -TESTE I.2



O Histograma dos Resíduos, conforme mostra a figura 4.10 a seguir, confirma a Gaussianidade da amostra.

FIGURA 4.10. HISTOGRAMA DOS RESÍDUOS -TESTE I.2



Este teste apresentou um erro médio de 0,01445, como pode ser verificado no Apêndice X, que mostra também os valores preditos, resíduos e erro quadrático médio de cada processo.

Neste teste verifica-se que mantendo-se todas as variáveis, obtém-se um MSE igual a 0,01197. Ao refazer o teste com as seis variáveis de maior significância se reduz a matriz de dados a cerca de 20% dos valores originais e o MSE sofre um pequeno acréscimo passando a ser igual a 0,0144593.

## 4.3.2 Teste II com Regressão Linear Múltipla

Neste teste, além da codificação, a matriz de dados foi submetida à ACP, cujo objetivo é o de avaliar a importância relativa das variáveis que compõem a amostra de dados.

Analogamente ao teste I, verificou-se, através do ajuste ao modelo  $y = X\beta + \varepsilon$ , que algumas variáveis não são significativamente importantes. Assim foram realizados dois testes, um com todas as variáveis e o outro retirando as menos importantes do modelo.

Para esse treinamento, conforme mencionado anteriormente, a fim de obter a ACP, foi utilizado *software STATIGRAPHICS* plus 5.1.

De acordo com o quadro 4.22 a seguir, pode-se observar todas as variáveis, seus respectivos *p*-valores e o erro padrão.

QUADRO 4.22 AJUSTE DO SEGUNDO TESTE DE REGRESSÃO COM 30 VARIÁVEIS COM ACP

Variáveis	Coeficiente	Erro Padrão
Constante	0,220922	0,016828
Col_1	-0,02944	0,007843
Col_2	0,151429	0,068936
Col_3	-0,02651	0,009274
Col_4	0,134604	0,05506
Col_5	-0,027328	0,025005
Col_6	-0,170564	0,069374
Col_7	-0,081632	0,038051

#### continuação

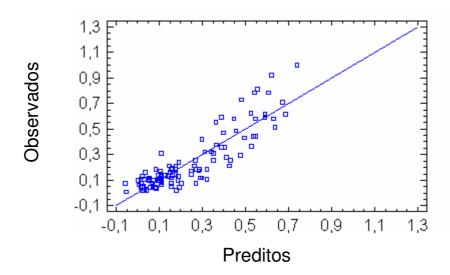
Variáveis	Coeficiente	Erro Padrão
Col_8	0,11438	0,050347
Col_9	-0,065881	0,01413
Col_10	-0,033923	0,011341
Col_11	-0,004854	0,022544
Col_12	0,117835	0,068629
Col_13	0,189141	0,072975
Col_14	-0,011199	0,026533
Col_15	-0,065423	0,033869
Col_16	-0,164584	0,094342
Col_17	-0,186351	0,110532
Col_18	0,112364	0,04252
Col_19	0,063766	0,020164
Col_20	-0,312607	0,131478
Col_21	-0,163999	0,029965
Col_22	-0,132798	0,071059
Col_23	0,173492	0,087044
Col_24	0,116546	0,048183
Col_25	0,133817	0,077307
Col_26	-0,096329	0,044471
Col_27	0,817548	0,419673
Col_28	0,127331	0,071605
Col_29	-0,033464	0,056669
Col_30	-7,25E+14	3,66E+14

A equação de Regressão Linear Múltipla que descreve a relação entre a variável resposta (tempo de audiência) e as variáveis independentes nesse teste é descrita a seguir:

```
Tempo de audiência = 0.220922 - 0.0294401*Col_1 + 0.151429*Col_2 - 0.0265103*Col_3+ 0.134604*Col_4 - 0.0273278*Col_5 - 0.170564*Col_6 - 0.0816318*Col_7+ 0.11438*Col_8 - 0.065881*Col_9 - 0.0339234*Col_10 - 0.00485417*Col_11 + 0.117835*Col_12 + 0.189141*Col_13 - 0.0111986*Col_14 - 0.065423*Col_15 - 0.164584*Col_16 - 0.186351*Col_17+ 0.112364*Col_18 + 0.0637656*Col_19 - 0.312607*Col_20 - 0.163999*Col_21 - 0.132798*Col_22 + 0.173492*Col_23 + 0.116546*Col_24+ 0.133817*Col_25 - 0.0963288*Col_26 + 0.817548*Col_27 + 0.127331*Col_28 - 0.0334636*Col_29 - 7.25014E14*Col_30
```

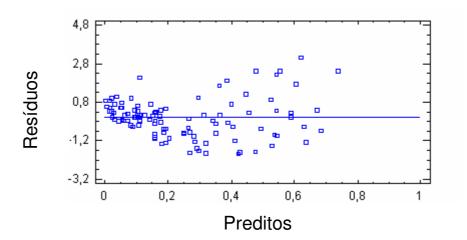
A figura 4.11 a seguir mostra que os valores preditos estão dispostos em linha diagonal, indicando uma boa linearidade, ou seja, as previsões são boas e se aproximam de valores reais.

FIGURA 4.11 VALORES PREDITOS X VALORES OBSERVADOS-TESTE II.1



A figura 4.12 a seguir mostra os pontos distribuídos aleatoriamente em torno da linha que passa pela origem, indicando que foi cumprida a condição da homocedasticidade, ou seja, a suposição de variância constante está correta.

FIGURA 4.12 VALORES PREDITOS X RESÍDUOS -TESTE II.1



A *Gaussinidade* dos resíduos pode ser facilmente observada através do Histograma de Resíduos, conforme figura 4.13 a seguir.

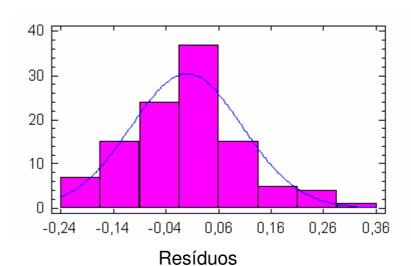


FIGURA 4.13. HISTOGRAMA DOS RESÍDUOS -TESTE II.1

No Apêndice XI apresenta-se o erro médio de 0,011215, obtido nesse teste, bem como os valores preditos, resíduos e erro quadrático médio de cada processo.

O quadro 4.23 a seguir apresenta os dados da simulação quando utilizam-se somente as variáveis mais significativas.

QUADRO 4.23. AJUSTE DO SEGUNDO TESTE DE REGRESSÃO COM 13 VARIÁVEIS COM ACP

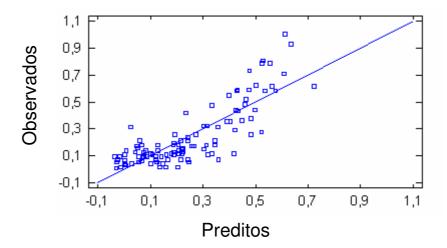
	1	
Variáveis	Coeficiente	Erro Padrão
Constante	0,244126	0,012973
Col_1	-0,039135	0,006582
Col_3	-0,018022	0,008838
Col_4	0,027061	0,009459
Col_6	-0,034585	0,010187
Col_9	-0,047838	0,011603
Col_10	-0,040147	0,011712
Col_11	0,033719	0,01217
Col_13	0,046993	0,013771
Col_14	-0,056625	0,014298
Col_18	0,034123	0,016802
Col_19	0,088372	0,017062
Col_20	-0,054517	0,01774
Col_21	-0,11566	0,018651

A equação de Regressão Linear Múltipla que descreve a relação entre a variável resposta (tempo de audiência) e as variáveis independentes está descrita a seguir:

Tempo de audiência=  $0.244126 - 0.0391354*Col_1 - 0.0180221*Col_3 + 0.0270607*Col_4 - 0.0345854*Col_6 - 0.0478383*Col_9 - 0.0401471*Col_10+ 0.0337194*Col_11 + 0.0469925*Col_13 - 0.0566251*Col_14 + 0.034123*Col_18 + 0.0883716*Col_19 - 0.0545167*Col_20 - 0.11566*Col_21$ 

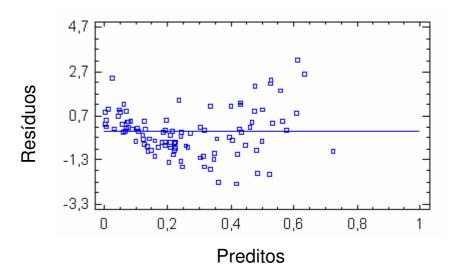
A figura 4.14 a seguir mostra que os valores preditos estão dispostos em linha diagonal, indicando linearidade, ou seja, os valores obtidos se aproximam de valores reais.

FIGURA 4.14 VALORES PREDITOS X VALORES OBSERVADOS -TESTE II.2



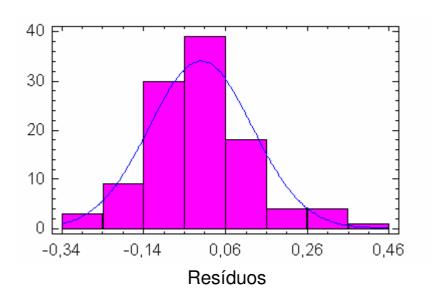
A figura 4.15 a seguir apresenta pontos distribuídos aleatoriamente em torno da linha que passa pela origem, indicando que a suposição da variância constante está correta.

FIGURA 4.15 VALORES PREDITOS X RESÍDUOS-TESTE II.2



A Gaussianidade dos resíduos pode ser verificada através do Histograma de Resíduos, conforme figura 4.16 a seguir.

FIGURA 4.16. HISTOGRAMA DOS RESÍDUOS -TESTE II.2



Este teste apresentou um erro médio de 0,01582, que juntamente com os valores preditos, resíduos e erro quadrático médio de cada processo encontram-se no Apêndice XII.

Neste teste verifica-se que mantendo-se todas as variáveis obtém-se um MSE igual a 0,011215. Ao refazer o teste com as 13 variáveis de maior significância se reduz a matriz de dados a cerca de 43% dos valores originais e o MSE passa a ser igual a 0,01582.

## 4.3.3 Teste III com Regressão Linear Múltipla

Para a realização desse teste, foram codificadas apenas as variáveis nominais, mantendo o valor original das variáveis ordinais. Dessa forma o vetor de entrada possui apenas 25 coordenadas, gerando agora uma matriz de 108 linhas por 25 colunas.

Neste teste a matriz de dados também foi submetida à ACP para uma avaliação estatística dos dados, e teve como propósito avaliar a importância relativa das variáveis que compõem a amostra de dados.

Da mesma maneira que nos testes anteriores, ajustou-se um modelo de Regressão Linear Múltipla para os dados observados.

No ajuste do modelo  $y = X\beta + \varepsilon$  verificou-se que algumas variáveis não são significativamente importantes. Da mesma maneira que nos testes anteriores, foram realizados dois testes, um com todas as variáveis, conforme o quadro 4.24 a seguir, e o outro com as variáveis mais importantes.

QUADRO 4.24 AJUSTE DO TERCEIRO TESTE DE REGRESSÃO COM 25 VARIÁVEIS COM ACP

Variáveis	Coeficientes	Erro Padrão
Col_1	-0,126323	0,016361
Col_2	0,550909	0,071322
Col_3	-0,521153	0,064295
Col_4	0,0398573	0,017392
Col_5	0,0789103	0,018823
Col_6	0,0461446	0,019304
Col_7	-0,340792	0,043367
Col_8	-0,223152	0,037073
Col_9	-0,309516	0,047532
Col_10	-0,1373	0,025637

continuação

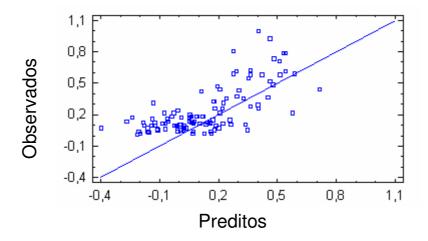
Variáveis	Coeficientes	Erro Padrão
Col_11	-0,23026	0,038027
Col_12	-0,0262991	0,024991
Col_13	-0,449751	0,055858
Col_14	0,16753	0,032649
Col_15	-0,302207	0,051343
Col_16	0,119065	0,03273
Col_17	-0,0079574	0,032486
Col_18	1,42395	0,185986
Col_19	-0,330349	0,065568
Col_20	-0,424319	0,058491
Col_21	-1,441	0,184106
Col_22	-1,08007	0,143184
Col_23	-143,626	18,3558
Col_24	-1,32215	0,173054
Col_25	-2,E+15	2,96E+14

A equação de Regressão Linear Múltipla que descreve a relação entre a variável resposta (tempo de audiência) e as variáveis independentes é:

```
Tempo de audiência = -0,126323*Col_1 + 0,550909*Col_2 - 0,521153*Col_3 +0,0398573*Col_4 + 0,0789103*Col_5 + 0,0461446*Col_6 - 0,340792*Col_7 - 0,223152*Col_8 - 0,309516*Col_9 - 0,1373*Col_10 - 0,23026*Col_11 - 0,0262991*Col_12 - 0,449751*Col_13 + 0,16753*Col_14 - 0,302207*Col_15+ 0,119065*Col_16 - 0,00795741*Col_17 + 1,42395*Col_18 -0,330349*Col_19 - 0,424319*Col_20 - 1,441*Col_21 - 1,08007*Col_22 -143,626*Col_23 - 1,32215*Col_24 - 2,31298E15*Col_25
```

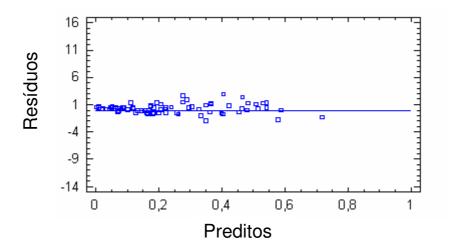
A figura 4.17 a seguir mostra que os valores preditos estão dispostos em linha diagonal, indicando uma linearidade satisfatória.

FIGURA 4.17 VALORES PREDITOS X VALORES OBSERVADOS -TESTE III.1



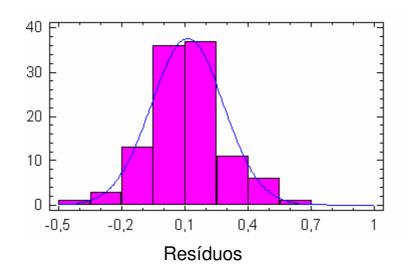
A figura 4.18 a seguir apresenta os pontos distribuídos aleatoriamente em torno da linha que passa pela origem, indicando que a suposição de variância constante está correta.

FIGURA 4.18 VALORES PREDITOS X RESÍDUOS -TESTE III.1



A *Gaussianidade* dos resíduos pode ser verificada através do Histograma dos Resíduos, conforme a figura 4.19 a seguir.

FIGURA 4.19. HISTOGRAMA DOS RESÍDUOS - TESTE III.1



Este teste apresentou um erro médio de 0,04188, que juntamente com os valores preditos, resíduos e erro quadrático médio de cada processo encontram-se no Apêndice XIII.

O quadro 4.25 a seguir apresenta a simulação utilizando somente as 23 variáveis mais significativas com seus respectivos coeficientes, *p*-valores e o erro padrão.

QUADRO 4.25 AJUSTE DO TERCEIRO TESTE DE REGRESSÃO COM 23 VARIÁVEIS COM ACP

Variáveis	Coeficientes	Erro Padrão
Col_1	-0,127589	0,015806
Col_2	0,560392	0,06462
Col_3	-0,529609	0,058382
Col_4	0,0402539	0,017269
Col_5	0,0797915	0,018537
Col_6	0,0470914	0,018989
Col_7	-0,346088	0,039923
Col_8	-0,227434	0,034431
Col_9	-0,315312	0,043768
Col_10	-0,13915	0,024866
Col_11	-0,234369	0,035643
Col_13	-0,456521	0,051486
Col_14	0,170167	0,031454
Col_15	-0,308115	0,047712
Col_16	0,121005	0,03202
Col_18	1,44884	0,168277
Col_19	-0,338024	0,060774
Col_20	-0,430694	0,054763
Col_21	-1,46552	0,166746
Col_22	-1,09881	0,130145
Col_23	-146,119	16,5559
Col_24	-1,34486	0,157215
Col_25	-2,35E+15	2,67E+14

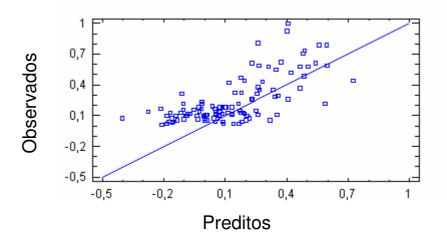
A equação de Regressão Linear Múltipla que descreve a relação entre a variável resposta (tempo de audiência) e as variáveis independentes é:

Tempo de audiência =  $-0.127589*Col_1 + 0.560392*Col_2 - 0.529609*Col_3 + 0.0402539*Col_4 + 0.0797915*Col_5 + 0.0470914*Col_6 - 0.346088*Col_7 - 0.227434*Col_8 - 0.315312*Col_9 - 0.13915*Col_10 - 0.234369*Col_11 - 0.456521*Col_13 + 0.170167*Col_14 - 0.308115*Col_15 + 0.121005*Col_16+$ 

1,44884\*Col\_18 - 0,338024\*Col\_19 - 0,430694\*Col\_20 - 1,46552\*Col\_21-1,09881\*Col\_22 - 146,119\*Col\_23 - 1,34486\*Col\_24 - 2,35313E15\*Col\_25

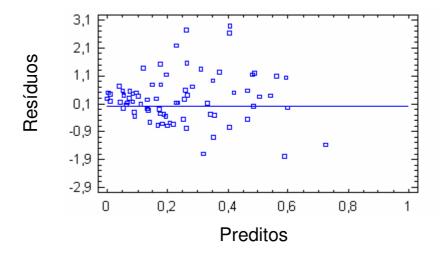
A figura 4.20 mostra que os valores preditos estão dispostos em linha diagonal, indicando linearidade, ou seja, os valores obtidos se aproximam de valores reais.

FIGURA 4.20 VALORES PREDITOS X VALORES OBSERVADOS - TESTE III.2



A figura 4.21 a seguir apresenta os pontos distribuídos aleatoriamente em torno da linha que passa pela origem, indicando que a suposição da variância constante está correta.

FIGURA 4.21 VALORES PREDITOS X RESÍDUOS - TESTE III.2



A *Gaussianidade* dos resíduos pode ser verificada através do Histograma dos Resíduos, conforme a figura 4.22 a seguir.

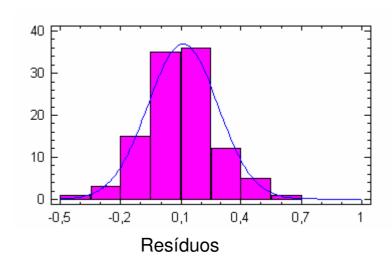


FIGURA 4.22. HISTOGRAMA DOS RESÍDUOS - TESTE III.2

Esse teste apresentou um erro médio de 0,042497, que juntamente com os valores preditos, resíduos e o erro quadrático médio de cada processo encontram-se no Apêndice XIV.

Neste teste verifica-se que mantendo-se todas as variáveis obtém-se um MSE igual a 0,0418804. Ao refazer o teste com as 23 variáveis de maior significância se reduz a matriz de dados a cerca de 92% dos valores originais e o MSE sofre um pequeno acréscimo passando a ser igual a 0,042497.

#### 4.4 ANÁLISE DOS RESULTADOS DE REGRESSÃO LINEAR MÚLTIPLA

Com o objetivo de encontrar uma previsão de duração do tempo de audiências trabalhista, foram realizados diversas simulações. Em todos os testes os melhores resultados são obtidos quando mantêm-se todas as variáveis.

No quadro 4.26 a seguir, tem-se os melhores resultados, ou seja, o menor MSE, para cada um dos três testes.

QUADRO 4.26. MELHORES RESULTADOS DE RLM

TESTE	MSE
l.1	0,01197
1.2	0,01445
II.1	0,011215
II.2	0,01582
III.1	0,04188
III.2	0,042497

De acordo com a análise realizada, é possível verificar que a melhor simulação obtida a partir da RLM foi a do Teste II.1, o qual trata da matriz de dados codificada e com ACP, mantendo-se todas as variáveis do modelo. Os resultados práticos do teste II.1 encontram-se no Apêndice XV.

Comparando as duas técnicas utilizadas neste trabalho, verifica-se que a melhor técnica para fazer a previsão da duração do tempo de audiências trabalhistas de cada um dos processos, embora ambas as técnicas tenham apresentados resultados satisfatórios, é a RNA. Onde o erro é praticamente a metade do valor quando comparado à Regressão Linear Múltipla.

#### **CAPÍTULO V**

#### 5. CONCLUSÕES E SUGESTÕES PARA FUTUROS TRABALHOS

#### 5.1 CONCLUSÕES

O Fórum Trabalhista de São José dos Pinhais, PR, vem aumentando de maneira considerável o número de processos trabalhistas. Diante desse aumento, faz-se necessária a utilização de ferramentas matemáticas que permitam uma previsão de duração do tempo de audiências trabalhistas.

O presente trabalho teve como objetivo comparar as técnicas de Redes Neurais Artificiais e Regressão Linear Múltipla, para encontrar a melhor previsão de duração do tempo das audiências trabalhistas.

Utilizando os dados obtidos de processos do Fórum Trabalhista de São José dos Pinhais, PR, que são as entradas para ambas as técnicas, as mesmas foram treinadas buscando obter de forma automática uma previsão de duração das audiências.

As RNAs foram treinadas através do algoritmo *back-propagation*, fazendo-se variar a codificação dos atributos de entrada, o número de neurônios na camada escondida, o conjunto de pesos iniciais e o número de iterações, fornecendo como resposta (saída da RNA), a duração do tempo das audiências de cada um dos processos trabalhistas.

A Regressão Linear Múltipla foi realizada através do *software STATIGRAPHICS* plus 5.1. Nos testes com esta ferramenta os conjuntos de dados utilizados foram os mesmos das RNAs, a fim de obter parâmetros de comparação entre as duas ferramentas matemáticas.

Na comparação das duas técnicas, embora ambas tenham apresentado resultados satisfatórios, as RNAs apresentaram um desempenho superior quando comparado ao método estatístico. Conforme pode-se verificar comparando a quadro 4.19 e a quadro 4.26, onde têm-se os melhores resultados das técnicas, observa-se

que o menor erro encontra-se no teste II.1 (variáveis codificadas com ACP) para as duas técnicas. O menor erro para a RNA tem o valor de 0,00544 e o da Regressão Linear Múltipla igual a 0,011215, ou seja, o erro encontrado na RNA é praticamente a metade do valor do erro encontrado com a técnica de Regressão Linear Múltipla.

Assim, a melhor maneira de prever a duração do tempo de audiências trabalhistas, é utilizar-se da RNA com pesos gerados no Teste II.1 utilizando-se todas as componentes principais.

#### 5.2 SUGESTÕES PARA FUTUROS TRABALHOS

Sugere-se para o desenvolvimento de trabalhos futuros:

- utilização de outros algoritmos de treinamento para as RNAs, como Radial Basis Function, que são redes supervisionadas, consideradas aproximadoras universais.
- o resolução do mesmo problema utilizando outra ferramenta matemática, como, por exemplo, *Redes Bayesianas*, e também a utilização de outras técnicas de agrupamento para a divisão em faixas das variáveis quantitativas, com o objetivo de encontrar parâmetros de comparação aos resultados obtidos.
- ainda no mesmo problema, construir uma RNA para cada um dos juizes.
- separação dos processos trabalhistas em dois grupos, o primeiro grupo com processos cujo rito é do tipo RT, e o segundo grupo cujo rito é do tipo PS, devido ao fato de a justiça do trabalho tratá-los diferentemente quanto aos prazos a serem seguidos.

#### **REFERÊNCIAS**

ADAMOWICZ, E. C. Reconhecimento de Padrões na Análise Econômico-Financeira de Empresas. Curitiba, 2000. Dissertação de Mestrado - Programa de Pós-Graduação em Métodos Numéricos em Engenharia, Universidade Federal do Paraná.

AMBRÓSIO, P. E. Redes Neurais Artificiais no Apoio ao Diagnóstico Diferencial de Lesões Intersticiais Pulmonares. Ribeirão Preto, 2002. Dissertação de Mestrado - Universidade de São Paulo.

BAESENS, B.; SETIONO, R.; MUES, C. & VANTHIENEN, J. (2003). *Using Neural Network Rule Extraction and Decision Tables for Credit-Risk Evalution*. Management Science Informs, vol. 49, n°3, p. 312-329.

BAPTISTELLA, M.; STEINER, M. T. A.; CHAVES NETO, A. O Uso de Redes Neurais e Regressão Linear Múltipla na Engenharia de Avaliações: Determinação dos Valores Venais de Imóveis Urbanos. XXXVIII SOBRAPO - SIMPOSIO BRASILEIRO DE PESQUISA OPERACIONAL, Goiânia, GO – 2006.

BAPTISTELLA, M. O Uso de Redes Neurais e Regressão Linear Múltipla na Engenharia de Avaliações: Determinação dos Valores Venais de Imóveis Urbanos. Curitiba, 2005. Dissertação de Mestrado - Programa de Pós-Graduação em Métodos Numéricos em Engenharia, Universidade Federal do Paraná.

BIONDI NETO, L.; SIEIRA, A. C. C. F.; DANZIGER, B. R.; SILVA, J. G. S. Classificação de Solos Usando-se Redes Neurais Artificiais. XXXIX SOBRAPO - SIMPOSIO BRASILEIRO DE PESQUISA OPERACIONAL, Fortaleza, CE – 2007.

BOCANEGRA, C. W. R. Procedimentos para Tornar mais Efetivo o uso das Redes Neurais Artificiais em Planejamento de Transportes. São Carlos, 2002. Dissertação de Mestrado – Universidade de São Paulo.

DIN – Departamento de Informática – UEM – Universidade Estadual de Maringá. **Uma Introdução às Redes Neurais**. Disponível em: <a href="http://www.din.uem.br/ia/neurais/">http://www.din.uem.br/ia/neurais/</a> Acesso em 2 fevereiro 2007.

FAUSETT, L. V. *Fundamentals of Neural Networks* - Architectures, Algorithms, and Applications. Prentice Hall International Editions. USA, New Jersey, 1994.

HAYKIN, S. **Redes Neurais: Princípios e Prática**. 2ª Edição, Porto Alegre: Bookman, 2002.

HAYKIN, S. *Neural Networks - A Comprehensive Foundation*. Macmillan College Publishing Company, USA, NY - New York, 1994.

IBGE – INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. Disponível em: <a href="http://www.ibge.gov.br/home/estatistica/calendario\_estudos2005.shtm">http://www.ibge.gov.br/home/estatistica/calendario\_estudos2005.shtm</a> Acesso em 12 outubro 2007.

ICMC.USP - UNIVERSIDADE DE SÃO PAULO. Disponível em: <a href="http://www.icmc.usp.br/~andre/research/neural//index/htm">http://www.icmc.usp.br/~andre/research/neural//index/htm</a> Acesso em 17 fevereiro 2008.

INFANTOSI, A. F. C.; ALMEIDA, R. M. V.; COSTA, J. C. G. D.; ÁVILA, C. A. L.; SUASSUNA, J. H. **Definição de Variáveis em Redes Neurais Artificiais por Análise de Componentes Principais: Aplicação em Transplante Renal**. IX CBIS – Congresso Brasileiro de Informática em Saúde, Ribeirão Preto – SP, 2004.

JOHNSON, R.A.; WICHERN, D.W. *Applied Multivariate Statistical Analysis*. 5.ª Edição, Nova Jersey: Prentice Hall, 2002.

LIMA, J. D. Análise Econômico-Financeira de Empresa Sob a Ótica da Estatística Multivariada. Curitiba, 2002. Dissertação de Mestrado - Programa de Pós-Graduação em Métodos Numéricos em Engenharia, Universidade Federal do Paraná.

LIPPMANN, R. P. *Pattern Classification Using Neural Networks*. IEEE Communications Magazine, novembro de 1989, p. 47-64.

LU, H.; SETIONO, R. & LIU, H. (1996). *Effective Data Mining Using Neural Networks*. IEE Transactions on Knowledge an Data Engineering, vol. 8, n° 6, p.957-961.

MACHADO, A. **Neuroanatomia Funcional**. 2ª Edição, São Paulo: Editora Atheneu, 2006.

MARDIA, K.V., KENT, J.T., BIBBY, J.M.. *Multivariate analysis*. London: Academic Press, 1979, p.520.

MARQUES, J. Notas de aula da disciplina Análise Multivariada Aplicada a Pesquisa. Programa de Pós-Graduação em Métodos Numéricos em Engenharia, UFPR, Curitiba, PR, 2007.

NELSON, M. M. & ILLINGWORTH, W. T. *A Pratical Guide to Neural Nets*. Addison-Wesley Publishing Company, Inc. USA, 1990.

PACHECO, R. C. S. *Hybrid Intelligent System for Prediction and Solving Financial Problems of Small Retail Firms*. Florianópolis, 1996. Tese de Doutorado - Programa de Pós-Graduação em Engenharia de Produção, Universidade Federal de Santa Catarina.

PANDYA, A.S. & MACY, R. B. *Pattern Recognition with Neural Networks in C++*. CRC Press, Inc. Florida Atlantic University, USA, Boca Raton, Florida, 1996.

PAVANELLI, G. Análise do Tempo de Duração de Processos Trabalhistas Utilizando Redes Neurais Artificiais Como Apoio à Tomada de Decisões. Curitiba, 2007. Dissertação de Mestrado - Programa de Pós-Graduação em Métodos Numéricos em Engenharia, Universidade Federal do Paraná.

RAIA JR, A. A. Acessibilidade e Mobilidade na Estimativa de um Índice de Potencial de Viagens Utilizando Redes Neurais Artificiais. São Carlos, 2000. Tese de Doutorado – Escola de Engenharia de São Carlos, Universidade de São Paulo.

SOUSA, E. A.; TEIXEIRA, L. C. V.; MELLO, M. R. P. A.; TORRES, E. A. F. S.; MOITA NETO, J. M. Aplicação de Redes Neurais para Avaliação do Teor de Carne Mecanicamente Separada em Salsicha de Frango. Ciência e Tecnologia de Alimentos, vol.23 no.3 Campinas Sept./Dec. 2003.

STEINER, M. T. A. **Notas de aula da disciplina Aplicações de Pesquisa Operacional**. Programa de Pós-Graduação em Métodos Numéricos em Engenharia, UFPR, Curitiba, PR, 2006.

STEINER, M. T. A. Uma Metodologia Para o Reconhecimento de Padrões Multivariados com Resposta Dicotômica. Florianópolis, 1995. Tese de Doutorado – Programa de Pós Graduação em Engenharia de Produção, Universidade Federal de Santa Catarina.

TAFNER, M. A; XEREZ, M.; FILHO, ILSON W. R. Redes Neurais Articiais - Introdução e Princípios de Neurocomputação. 1ª Edição Blumenal: EKO, 1996.

TRT - TRIBUNAL REGIONAL DO TRABALHO. **Regimento Interno**. Disponível em: <a href="http://www.trt9.gov.br/">http://www.trt9.gov.br/</a> Acesso em 07 outubro 2007.

TST - TRIBUNAL SUPERIOR DO TRABALHO. **Atribuições**. Disponível em: <a href="http://www.tst.gov.br/">http://www.tst.gov.br/</a> Acesso em 16 fevereiro 2007.

WELLS, W. A. *Lowly Glial Cells Strengthen Brain Connections*. <a href="http://www-leland.stanford.edu/dept/news/report/news/september24/glial.html">http://www-leland.stanford.edu/dept/news/report/news/september24/glial.html</a> . Acesso em 25 fevereiro 2007.

## **APÊNDICES**

## **APÊNDICE I**

## FICHA DE COLETA DE DADOS

Autos	NR	
Autos	DATA DE AJUIZAMENTO	
	TIPO	
Daalamanta (Auton)	SEXO	
Reclamante (Autor)	17	
	NASCIMENTO	
	ADMISSÃO	
	DISPENSA  THO DE DISPENSA	
	TIPO DE DISPENSA	
	ÚLTIMO SALÁRIO	
	FUNÇÃO	
	ADVOGADO	
Reclamado (Réu)	QUALIDADE	
	ADVOGADO	
Objeto do Processo	VÍNCULO DE EMPREGO	
	DIFERENÇAS SALARIAIS	
	VERBAS RECISÓRIAS	
	MULTA DO ART 477	
	MULTA DO ART 467	
	HORAS EXTRAS E REFLEXOS	
	FGTS	
	INDENIZAÇÃO POR DANOS MORAIS	
	SEGURO DESEMPREGO	
	VALES TRANSPORTE	
	ADICIONAL INSALUBRIDADE	
	ADICIONAL NOTURNO	
Audiência	JUIZ	
	NR DEPOIMENTOS	
	ACORDO	
	INÍCIO	
	TÉRMINO	
	DURAÇÃO	
	ADVOGADO DO RÉU	
	ADVOGADO DO AUTOR	
	DATA	
	<u> </u>	1

## **APÊNDICE II**

#### QUADRO A.1 – MATRIZ DE ENTRADA DE DADOS

Nr					Ol	ojeto	do I	Proc	esso	)				,	Saláı	rio d	0	Ti	Те	mpo	de		Prof	issão	)		Juiz	<u>.</u>	Dep	Acor
	1	2	3	4	5	6	7	8	9	10	11	12	13	R	lecla	man	te	ро	S	ervi	ço									do
1	0	0	1	1	0	1	1	1	0	0	1	1	1	0	1	1	1	1	0	1	1	0	0	1	1	1	0	0	0	1
2	0	0	1	0	0	1	1	0	1	1	1	0	1	1	1	1	1	1	0	1	1	0	0	1	1	1	0	0	2	0
3	1	0	1	0	0	1	1	0	1	0	0	0	0	0	0	0	0	1	0	0	0	0	1	0	1	0	1	0	1	0
4	0	0	1	0	0	1	1	0	0	0	1	0	0	1	1	1	1	1	0	1	1	0	0	1	1	1	0	0	1	0
5	1	1	1	0	1	1	1	0	1	0	1	0	0	0	0	0	1	1	0	0	1	0	0	1	1	0	1	0	4	1
6	0	1	1	1	1	1	1	0	0	0	0	0	0	0	0	0	1	0	0	0	0	1	0	0	1	1	0	0	0	0
7	1	0	1	1	1	1	1	1	0	0	0	0	0	0	0	0	1	0	0	0	0	0	1	0	0	1	0	0	0	1
8	0	1	1	0	0	1	1	1	0	1	0	1	0	0	1	1	1	1	0	0	0	0	1	0	0	0	1	0	0	1
9	1	0	1	1	1	1	1	1	1	0	0	0	0	0	0	0	0	1	0	0	1	0	1	0	1	1	0	0	0	0
10	1	1	1	1	0	1	1	0	0	0	0	0	0	0	0	0	0	1	0	1	1	0	1	0	1	0	1	0	1	0
11	1	1	1	1	1	1	1	0	1	0	0	0	0	0	0	0	0	1	0	0	0	0	0	1	1	0	1	0	0	1
12	1	1	1	0	1	1	1	0	0	0	0	0	0	1	1	1	1	1	1	1	1	0	0	1	0	1	0	0	0	0
13	0	0	1	1	0	1	1	1	0	1	0	1	0	0	0	0	0	0	0	1	1	1	0	0	1	1	0	0	2	0
14	0	0	1	0	0	1	1	1	0	0	0	1	0	0	1	1	1	1	0	0	0	1	0	0	1	0	1	0	1	0
15	1	1	1	1	1	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	1	0	0	1	0	1
16	1	0	1	1	0	1	1	1	0	0	1	1	0	1	1	1	1	1	0	1	1	0	0	1	0	0	1	0	2	0
17	0	1	1	1	0	1	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	1	0	0	1	0	0	1	0	1
18	0	1	1	1	0	1	1	1	0	1	0	0	0	0	0	0	0	1	0	0	0	0	1	0	1	1	0	0	0	0
19	0	1	1	1	1	1	1	1	1	1	0	0	0	0	0	0	1	1	0	0	1	0	1	0	1	0	1	0	0	1
20	1	0	1	0	0	1	1	1	0	0	0	0	0	1	1	1	1	1	1	1	1	0	0	1	0	1	0	0	5	0
21	1	1	1	0	0	1	1	0	0	1	1	1	0	0	0	0	1	1	0	1	1	0	0	1	1	0	1	0	4	0
22	1	1	1	1	1	0	1	0	1	0	0	0	0	1	1	1	1	1	0	0	1	1	0	0	1	1	0	0	0	1
23	0	0	1	0	1	1	1	1	0	0	1	0	0	1	1	1	1	1	0	0	1	0	0	1	1	0	1	0	0	0
24	0	1	1	0	1	1	1	1	0	1	1	1	0	0	0	0	1	1	0	0	1	0	0	1	1	0	1	0	3	0
25	0	1	1	1	0	1	1	1	0	1	0	0	0	0	0	1	1	1	0	0	1	0	1	0	1	1	0	0	1	0
26	1	1	1	1	1	1	1	1	0	1	1	0	0	0	0	0	0	1	0	0	0	0	0	1	1	0	1	0	0	0
27	0	0	1	1	1	1	1	0	1	0	0	0	0	0	0	0	1	1	0	1	1	0	1	0	1	1	0	0	0	0

28	1	1	1	1	1	1	1	0	0	0	0	0	0	0	0	0	1	1	0	0	0	0	0	1	1	0	1	0	0	0
29	1	1	1	1	1	1	1	0	0	0	1	1	0	0	0	0	1	1	0	0	0	1	0	0	1	1	0	0	0	1
30	1	1	0	1	1	1	1	0	0	0	0	0	1	0	0	1	1	1	1	1	1	1	0	0	1	0	1	0	0	1
31	0	0	1	0	0	1	1	0	0	0	0	1	0	1	1	1	1	1	0	0	1	0	0	1	1	1	0	0	4	0
32	0	0	1	0	0	0	0	1	0	0	0	0	0	1	1	1	1	1	0	0	0	0	1	0	1	0	1	0	2	0
33	0	0	1	1	1	1	1	0	0	0	0	1	0	0	1	1	1	1	0	1	1	1	0	0	1	1	0	0	0	1
34	1	1	1	1	1	1	1	1	0	0	1	0	0	0	0	0	0	1	0	1	1	1	0	0	1	1	0	0	0	1
35	1	0	1	0	0	1	1	1	0	0	1	0	0	0	1	1	1	1	0	0	1	0	0	1	1	0	1	0	2	0
36	0	0	1	1	0	1	1	1	0	0	0	1	0	0	0	1	1	1	0	0	0	0	0	1	1	0	1	0	4	0
37	0	1	1	1	0	1	1	1	0	0	0	1	0	1	1	1	1	1	0	0	1	0	0	1	1	1	0	0	3	0
38	0	0	1	1	1	1	1	0	0	0	0	1	0	0	0	1	1	1	0	0	1	1	0	0	1	0	0	1	3	0
39	1	0	1	0	1	1	1	0	1	0	0	0	0	0	0	1	1	1	0	0	0	1	0	0	1	0	1	0	5	0
40	1	0	1	0	0	1	1	1	0	0	0	1	0	1	1	1	1	1	1	1	1	0	0	1	1	1	0	0	4	0
41	1	0	1	0	1	1	1	1	1	1	0	1	0	0	1	1	1	1	0	0	1	0	1	0	1	0	0	1	0	0
42	0	0	0	0	0	0	0	1	1	0	0	0	0	0	1	1	1	1	0	1	1	0	0	1	1	1	0	0	0	0
43	1	0	1	0	0	1	1	1	0	0	0	1	0	0	1	1	1	1	0	0	1	0	0	1	1	0	1	0	0	0
44	0	1	1	0	0	1	1	0	0	0	1	0	0	0	1	1	1	1	0	1	1	0	0	1	1	1	0	0	4	0
45	1	1	1	0	0	1	1	1	0	0	1	1	0	0	1	1	1	1	0	0	0	0	0	1	1	0	1	0	3	0
46	0	0	1	0	0	1	1	0	0	0	1	0	0	1	1	1	1	1	0	1	1	0	0	1	1	1	0	0	2	0
47	0	0	1	1	0	0	1	0	0	0	0	0	0	0	0	1	1	1	1	1	1	0	1	0	1	1	0	0	3	0
48	1	1	1	0	0	1	1	0	0	1	0	1	0	1	1	1	1	1	0	1	1	0	1	0	1	1	0	0	5	0
49	0	0	1	1	0	1	1	1	0	1	0	0	0	0	1	1	1	1	0	0	1	1	0	0	1	0	1	0	4	0
50	0	1	1	1	0	1	1	0	0	0	0	0	0	0	0	0	0	1	1	1	1	1	0	0	1	1	0	0	0	0
51	0	0	1	0	0	1	1	0	0	0	1	0	0	0	0	1	1	1	0	0	0	1	0	0	1	1	0	0	4	0
52	1	0	1	0	1	1	1	1	0	0	1	0	0	1	1	1	1	1	0	0	1	0	0	1	1	0	1	0	5	0
53	1	0	1	1	1	1	1	0	1	0	0	1	0	0	0	0	1	1	0	0	1	0	0	1	1	0	1	0	0	0
54	1	0	1	0	0	1	1	1	0	0	1	0	0	0	1	1	1	1	0	0	0	0	0	1	1	0	1	0	2	0
55	0	0	1	1	1	1	1	0	0	0	0	1	0	0	0	1	1	1	1	1	1	0	0	1	1	1	0	0	0	1
56	0	1	1	0	0	1	1	0	0	0	0	0	0	0	0	1	1	1	0	0	0	1	0	0	1	0	1	0	0	1
57	0	0	1	0	0	0	1	0	0	0	0	0	0	0	1	1	1	1	0	0	0	0	0	1	1	1	0	0	4	0
58	1	0	1	1	1	1	1	0	0	0	0	1	1	0	0	0	0	1	0	0	1	0	0	1	1	0	1	0	5	0
59	0	0	1	1	1	1	1	0	0	0	1	1	0	0	1	1	1	0	0	0	0	0	0	1	1	1	0	0	0	0
60	0	0	1	0	0	1	0	0	0	0	1	0	0	1	1	1	1	1	1	1	1	1	0	0	1	1	0	0	2	0
61	1	0	1	0	1	1	1	1	1	0	0	0	0	0	0	1	1	0	0	0	0	0	0	1	1	0	0	1	0	0

62	0	0	1	1	1	1	1	1	0	1	1	0	1	0	0	0	0	1	0	0	1	0	0	14	1	0	1	0	0	0
63	0	1	1	0	0	1	1	1	0	0	0	0	0	0	0	0	1	1	1	1	1	0	0	1	1	1	0	0	2	0
64	1	0	1	0	1	1	1	0	0	0	0	0	0	0	0	0	1	1	1	1	1	1	0	0	1	1	0	0	4	0
65	0	1	1	1	1	1	1	0	0	0	0	0	0	1	1	1	1	1	0	1	1	1	0	0	1	0	0	1	0	0
66	1	0	1	1	1	0	1	0	1	0	0	0	0	0	0	1	1	1	0	0	0	1	0	0	1	0	1	0	3	0
67	0	1	1	1	0	1	1	1	0	0	1	1	0	0	0	1	1	0	0	0	0	0	0	1	1	1	0	0	0	0
68	0	0	1	0	1	0	1	0	0	0	1	0	0	0	0	1	1	1	0	1	1	1	0	0	1	1	0	0	2	0
69	1	0	1	1	0	1	1	0	0	0	0	1	0	0	0	1	1	1	0	0	0	1	0	0	1	0	0	1	0	0
70	1	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	1	1	1	0	0	1	0	1	0	2	0
71	1	1	1	1	1	1	1	0	1	0	0	0	0	0	1	1	1	1	0	0	1	1	0	0	1	1	0	0	0	0
72	1	1	1	1	1	1	1	1	1	1	1	0	0	0	0	0	1	1	0	0	1	0	0	1	1	0	0	1	0	0
73	1	1	1	0	0	1	1	0	0	1	0	1	0	0	0	0	1	1	0	1	1	0	0	1	1	1	0	0	0	0
74	1	0	1	1	0	1	1	0	0	0	0	1	0	0	0	0	0	1	0	1	1	1	0	0	0	0	1	0	5	0
75	1	1	1	1	1	1	1	1	1	0	1	0	0	0	0	0	0	1	0	0	1	0	0	1	1	1	0	0	0	0
76	1	1	1	1	1	1	1	0	0	0	0	0	0	0	0	0	0	1	0	0	1	0	0	1	1	0	1	0	0	0
77	0	0	1	1	1	1	1	0	0	0	0	1	0	0	0	1	1	1	0	0	0	1	0	0	1	1	0	0	2	0
78	0	0	1	0	0	1	1	1	0	0	0	0	1	1	1	1	1	1	1	1	1	0	0	1	1	0	1	0	0	0
79	1	1	1	0	0	1	1	1	0	0	1	1	0	0	1	1	1	1	0	0	1	0	0	1	1	1	0	0	1	0
80	0	0	1	0	1	1	1	0	0	0	1	0	0	1	1	1	1	1	0	1	1	0	0	1	1	1	0	0	0	0
81	0	0	1	1	1	1	1	0	0	0	0	0	0	0	0	0	1	1	0	0	1	0	0	1	1	0	1	0	0	0
82	1	1	1	1	1	1	1	0	0	0	0	1	0	0	0	0	1	1	0	1	1	0	0	1	1	1	0	0	0	0
83	1	0	1	1	1	1	1	0	1	0	1	0	0	0	1	1	1	1	0	1	1	1	0	0	1	0	1	0	0	1
84	1	0	1	1	0	0	1	0	1	0	0	0	0	0	1	1	1	1	1	1	1	1	0	0	1	1	0	0	0	1
85	1	0	1	1	0	1	1	1	0	1	0	0	0	0	0	0	1	1	0	1	1	0	0	1	1	0	1	0	0	0
86	0	0	1	0	0	0	1	1	0	0	1	0	0	0	0	0	0	1	0	1	1	0	0	1	1	1	0	0	0	1
87	1	1	0	0	0	1	1	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	1	0	0	1	3	0
88	1	0	0	0	0	1	1	1	0	0	0	0	0	0	0	1	1	1	0	0	0	1	0	0	1	1	0	0	0	0
89	1	1	1	0	0	0	1	1	0	0	0	1	0	1	1	1	1	1	0	0	0	1	0	0	1	0	1	0	3	0
90	0	0	1	0	0	1	1	0	0	1	0	0	1	0	1	1	1	1	0	1	1	1	0	0	1	0	0	1	0	0
91	0	0	1	0	0	1	1	0	0	0	0	1	0	0	0	1	1	1	0	0	0	1	0	0	1	1	0	0	0	0
92	0	0	1	0	0	1	1	1	0	0	0	0	0	0	0	0	0	1	0	0	1	0	1	0	1	0	1	0	0	0
93	1	1	1	1	1	1	1	0	0	0	1	0	0	0	0	1	1	1	0	0	1	0	0	1	1	1	0	0	0	1
94	0	0	1	1	0	1	1	0	0	0	0	1	0	0	0	1	1	1	0	1	1	1	0	0	1	0	1	0	2	0
95	1	1	1	0	0	1	1	1	0	0	1	1	0	1	1	1	1	1	0	1	1	1	0	0	1	1	0	0	2	0

96	1	1	1	0	0	0	1	0	0	0	0	0	0	0	1	1	1	1	0	1	1	1	0	0	0	0	1	0	4	0
97	0	0	1	1	1	1	1	1	0	0	0	1	0	0	0	0	0	1	0	0	1	0	0	1	1	1	0	0	1	0
98	1	1	1	0	0	1	1	1	0	0	1	0	0	0	1	1	1	1	0	1	1	0	0	1	1	0	1	0	4	0
99	1	0	1	1	0	1	1	1	0	0	1	1	0	0	1	1	1	1	0	0	1	0	0	1	1	1	0	0	0	0
100	1	0	1	0	0	1	1	1	0	0	1	0	0	0	1	1	1	1	0	0	1	0	0	1	1	0	1	0	3	0
101	1	1	1	0	1	1	1	0	0	0	1	1	0	1	1	1	1	1	0	1	1	1	0	0	1	1	0	0	1	0
102	0	0	1	0	1	1	1	0	0	0	1	1	0	0	0	1	1	1	0	1	1	0	0	1	1	1	0	0	3	0
103	1	0	1	0	1	1	1	1	0	0	0	0	0	0	0	1	1	1	0	0	0	0	0	1	1	0	1	0	0	0
104	0	1	1	0	0	1	1	1	1	0	1	1	0	1	1	1	1	1	0	1	1	1	0	0	1	1	0	0	3	0
105	0	1	1	0	0	0	1	0	0	0	0	0	0	0	1	1	1	1	0	0	1	1	0	0	1	1	0	0	3	0
106	1	0	1	1	1	1	1	1	0	0	0	0	0	0	0	0	0	1	0	1	1	1	0	0	1	0	1	0	0	1
107	1	0	1	0	1	0	1	0	0	0	1	0	0	0	0	0	1	1	0	0	0	1	0	0	1	1	0	0	2	0
108	1	0	1	0	0	1	1	1	0	0	1	0	0	1	1	1	1	1	0	1	1	1	0	0	1	1	0	0	2	0

APÊNDICE III QUADRO A.2 - CODIFICAÇÃO DAS SAÍDAS

#### **APÊNDICE IV**

EXEMPLO NUMÉRICO DE UMA REDE NEURAL ARTIFICIAL COM UMA CAMADA.

São dados os padrões:

Da classe A (resposta 1):  $A_1 = (0,2), A_2 = (1,2), A_3 = (1,3)$ 

Da classe B (resposta 0):  $B_1 = (1,0), B_2 = (2,1)$ 

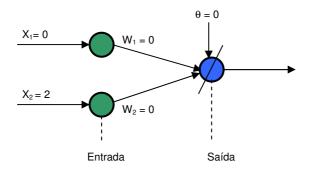
Através de uma rede neural, utilizando o algoritmo *back-propagation*, e a função de transferência sigmoidal, devem ser calculados os pesos adequados para que os padrões A e B sejam corretamente mapeados na saída.

#### Resolução:

Sejam  $w_1 = w_2 = \theta = 0$  e  $\gamma = 0.8$  (valores arbitrários)

#### 1. Primeira iteração

#### 1.1 Padrão A<sub>1</sub>



#### Propagação forward:

$$i^{A1} = \sum_{j} w_{j} x_{j}^{A1} + \theta = w_{1} x_{1} + w_{2} x_{2} + \theta = 0.0 + 2.0 + 0 = 0$$

$$a^{A1} = \frac{1}{1 + e^{-i^{A1}}} = \frac{1}{1 + e^{-0}} = 0.5$$

#### Propagação backward:

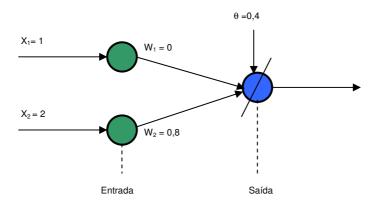
$$\delta^{A1} = d^{A1} - a^{A1} = 1 - 0.5 = 0.5$$

$$\Delta w_1 = \gamma . x_1 \delta^{A1} = 0.8.0.0.5 = 0 \rightarrow w_1 = w_{1a} + \Delta w_1 = 0 + 0 = 0$$

$$\Delta w_2 = \gamma . x_2 \delta^{A1} = 0.8.2.0.5 = 0.8 \rightarrow w_2 = w_{2a} + \Delta w_2 = 0 + 0.8 = 0.8$$

$$\Delta \theta = \gamma . \theta \delta^{A1} = 0.8.1.0.5 = 0.4 \rightarrow \theta = \theta_a + \Delta \theta = 0 + 0.4 = 0.4$$

#### 1.2 Padrão A<sub>2</sub>



#### Propagação forward:

$$i^{A2} = \sum_{j} w_{j} x_{j}^{A2} + \theta = w_{1} x_{1} + w_{2} x_{2} + \theta = 0.1 + 0.8.2 + 0.4 = 2$$

$$a^{A2} = \frac{1}{1 + e^{-i^{A2}}} = \frac{1}{1 + e^{-2}} = 0.88$$

#### Propagação backward:

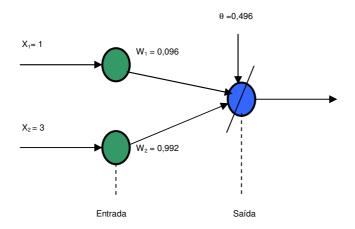
$$\delta^{A2} = d^{A2} - a^{A2} = 1 - 0.88 = 0.12$$

$$\Delta w_1 = \gamma \cdot x_1 \delta^{A2} = 0.8 \cdot 1.0.12 = 0.096 \rightarrow w_1 = w_{1a} + \Delta w_1 = 0 + 0.096 = 0.096$$

$$\Delta w_2 = \gamma \cdot x_2 \delta^{A2} = 0.8 \cdot 2.0.12 = 0.192 \rightarrow w_2 = w_{2a} + \Delta w_2 = 0.8 + 0.192 = 0.992$$

$$\Delta \theta = \gamma \cdot \theta \delta^{A2} = 0.8 \cdot 1.0.12 = 0.096 \rightarrow \theta = \theta_a + \Delta \theta = 0.4 + 0.096 = 0.496$$

#### 1.3 **Padrão A<sub>3</sub>.** Analogamente aos itens 1.1 e 1.2 temos:



## Propagação forward:

$$i^{A3} = 3,568$$

$$a^{A3} = 0.972$$

#### Propagação backward:

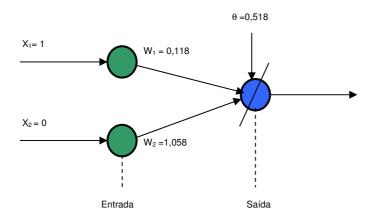
$$\delta^{A3} = 0.0274$$

$$w_1 = 0,118$$

$$w_2 = 1,058$$

$$\theta = 0.518$$

## 1.4 **Padrão B<sub>1</sub>.** Analogamente aos itens 1.1 e 1.2 temos:



#### Propagação forward:

$$i^{B1} = 0.636$$

$$a^{B1} = 0,654$$

## Propagação backward:

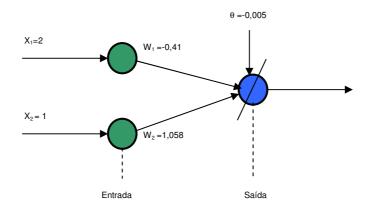
$$\delta^{B1} = -0.654$$

$$w_1 = -0.405$$

$$w_2 = 1,058$$

$$\theta = -0.005$$

## 1.5 **Padrão B<sub>2</sub>.** Analogamente aos itens 1.1 e 1.2 temos:



#### Propagação forward:

$$i^{B2} = 0.243$$

$$a^{B2} = 0.56$$

#### Propagação backward:

$$\delta^{B2} = -0.56$$

$$w_1 = -1,301$$

$$w_2 = 0.61$$

$$\theta = -0.453$$

#### Fim da primeira iteração.

## Análise da situação atual:

$$w_1 = -1,301$$
  $w_2 = 0,61$   $\theta = -0,453$ 

Pesos:

■ Padrão A<sub>1</sub>: 
$$i^{A1} = \sum_{j} w_{j} x_{j}^{A1} + \theta = w_{1} x_{1} + w_{2} x_{2} + \theta =$$

$$= 0.(-1,301) + 2.0,61 + (-0,453) = 0,767$$

$$a^{A1} = \frac{1}{1 + e^{-i^{A1}}} = 0,68$$

• Padrão A<sub>2</sub>:  $a^{A2} = 0.37$ 

• Padrão A<sub>3</sub>:  $a^{A3} = 0.52$ 

• Padrão B<sub>1</sub>:  $a^{B1} = 0.014$ 

■ Padrão B<sub>2</sub>:  $a^{B2} = 0.079$ 

Erro:  $E = \sum_{P} E^{P} = \frac{1}{2} \sum_{P} (d^{P} - a_{h}^{P})^{2}$   $E = \frac{1}{2} [(1 - 0.68)^{2} + (1 - 0.37)^{2} + (1 - 0.52)^{2} + (0 - 0.014)^{2} + (0 - 0.079)^{2}]$  E = 0.377

#### 2. Segunda iteração

Apresentam-se novamente todos os padrões começando com os pesos obtidos ao final da primeira iteração. Feito isto se tem:

Saídas dos padrões:

$$a^{A1} = 0.68;$$
  $a^{A2} = 0.67;$   $a^{A3} = 0.98;$   $a^{B1} = 0.28;$   $a^{B2} = 0.27$ 

Pesos:

$$w_1 = -1,69;$$
  $w_2 = 1,46;$   $\theta = -0,37$ 

Fim da segunda iteração.

Análise da situação atual:

• Pesos:  $w_1 = -1.69$   $w_2 = 1.46$   $\theta = -0.37$ 

• Padrão A<sub>1</sub>:  $a^{A1} = 0.93$ 

• Padrão A<sub>2</sub>:  $a^{A2} = 0.7$ 

• Padrão A<sub>3</sub>:  $a^{A3} = 0.91$ 

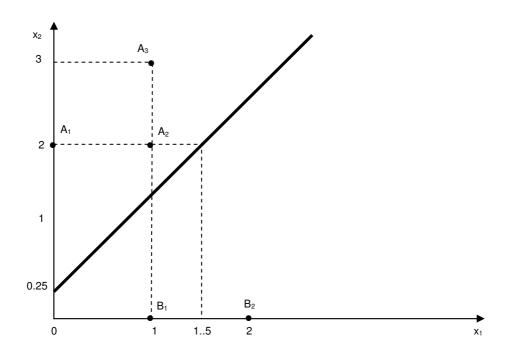
• Padrão B1:  $a^{B1} = 0.11$ 

• Padrão B<sub>2</sub>:  $a^{B2} = 0.092$ 

• Erro: E = 0.061

Interpretação Geométrica:

$$w_1 x_1 + w_2 x_2 + \theta = 0$$
  
-1,69 $x_1$  +1,46 $x_2$  = 0,37



Determinação de classe para um padrão desconhecido:

$$P_1 = (1,4)$$
  $i^{P_1} = 3,78 \Rightarrow a^{P_1} = 0,977 \Rightarrow Classe A$ 

$$P_2 = (1,1)$$
  $i^{P2} = -0.58 \Rightarrow a^{P2} = 0.36 \Rightarrow Classe B$ 

#### **APÊNDICE V**

## EXEMPLO NUMÉRICO DE REGRESSÃO LINEAR MÚLTIPLA COM UMA VARIÁVEL.

Os dados a seguir são provenientes de um estudo que investiga a composição corporal e fornece o percentual de gordura corporal (%), idade e sexo para 18 adultos com idades entre 23 e 61 anos.

- a) Calcule o coeficiente de correlação de Pearson entre a idade e o percentual de gordura para o sexo feminino, sexo masculino e sexo feminino e masculino juntos.
- b) Aplicando Regressão Linear, encontre a equação da reta, ou seja, percentual de gordura e idade, para homens e mulheres juntos.

Idade	%gordura	sexo	Idade	%gordura	sexo
23	9,5	М	53	34,7	F
23	27,9	F	53	42	F
27	7,8	М	54	29,1	F
27	17,8	М	56	32,5	F
39	31,4	F	57	30,3	F
41	25,9	F	58	33,0	F
45	27,4	М	58	33,8	F
49	25,2	F	60	41,1	F
50	31,1	F	61	34,5	F

M=masculino ; F= feminino

#### Resolução:

a. Cálculo do coeficiente de Correlação de Pearson (masculino)

idade	% gordura	$(x-\overline{x})$	$(y-\overline{y})$	$(x-\overline{x})(y-\overline{y})$	$(x-\overline{x})^2$	$(y-\overline{y})^2$
23	9,5	-7,5	-6,13	45,94	56,25	37,52
27	7,8	-3,5	-7,83	27,39	12,25	61,23
27	17,8	-3,5	2,18	-7,61	12,25	4,73
45	27,4	14,5	11,78	170,74	210,25	138,65
30,5	15,625			236,45	291,00	242,13

Coeficiente de correlação: 
$$r_1 = \frac{\sum (x - \overline{x}).(y - \overline{y})}{\sqrt{\sum (x - \overline{x})^2.\sum (y - \overline{y})^2}} = \frac{236,45}{\sqrt{291x242,13}} \cong 0,89$$

Cálculo do coeficiente de Correlação de Pearson (feminino)

idade	% gordura	$(x-\overline{x})$	$(y-\overline{y})$	$(x-\overline{x})(y-\overline{y})$	$(x-\overline{x})^2$	$(y-\overline{y})^2$
23	27,9	-27,86	-4,42	123,17	776,02	19,55
39	31,4	-11,86	-0,92	10,93	140,59	0,85
41	25,9	-9,86	-6,42	63,30	97,16	41,23
49	25,2	-1,86	-7,12	13,23	3,45	50,71
50	31,1	-0,86	-1,22	1,05	0,73	1,49
53	34,7	2,14	2,38	5,10	4,59	5,66
53	42	2,14	9,68	20,74	4,59	93,67
54	29,1	3,14	-3,22	-10,12	9,88	10,38
56	32,5	5,14	0,18	0,92	26,45	0,03
57	30,3	6,14	-2,02	-12,42	37,73	4,09
58	33	7,14	0,68	4,85	51,02	0,46
58	33,8	7,14	1,48	10,56	51,02	2,19
60	41,1	9,14	8,78	80,26	83,59	77,06
61	34,5	10,14	2,18	22,10	102,88	4,75
50,86	32,32			333,64	1389,71	312,12

Coeficiente de correlação (idade, % gordura) feminino:

$$r_2 = \frac{333,64}{\sqrt{1389,71x312,12}} \cong 0,51$$

	0 1 ~ 1 D	, ,	
Cálculo do coeficiente de	Correlacao de Pearson	mascriling A	teminina)
Calculo do Cochcichic de	Correlação de Fedisori	(IIIascallilo C	

idade	% gordura	$(x-\overline{x})$	$(y-\overline{y})$	$(x-\overline{x})(y-\overline{y})$	$(x-\overline{x})^2$	$(y-\overline{y})^2$
23	9,5	-23,3	-19,08	444,56	544,28	364,04
23	27,9	-23,3	-0,68	15,84	544,28	0,46
27	7,8	-19,33	-20,78	401,67	373,65	431,80
27	17,8	-19,33	-10,78	208,38	373,65	116,21
39	31,4	-7,33	2,82	-20,67	53,72	7,95
41	25,4	-5,33	-3,18	16,95	28,40	10,11
45	27,4	-1,33	-1,18	1,57	1,76	1,39
49	25,2	2,67	-3,38	-9,025	7,13	11,42
50	31,1	3,67	2,52	9,25	13,47	6,35
53	34,7	6,67	6,12	40,82	44,49	37,45
53	42	6,67	13,42	89,51	44,49	180,09
54	29,1	7,67	0,52	3,99	58,82	0,27
56	32,5	9,67	3,92	37,90	93,50	15,37
57	30,3	10,67	1,72	18,35	113,85	2,96
58	33	11,67	4,42	5,58	136,19	19,54
58	33,8	11,67	5,22	60,91	136,19	27,25
60	41,1	13,67	12,52	171,15	186,87	156,75
61	34,5	14,67	5,92	86,85	215,21	35,05
46,33	28,61			1629,85	3225,25	1424,46

Coeficiente de correlação (masculino e feminino): 
$$r_3 = \frac{1629,25}{\sqrt{3225,25x1424,86}} \cong 0,79$$

De acordo com a quadro a seguir, tem-se:

Estatística	X(idade)	Y(% gordura)
Média	46,33	28,61
Desvio Padrão	13,38	9,14

b. Aplicando Regressão Linear, admitindo-se Y como função linear de X, ajusta-se a "melhor reta" ao conjunto de dados. Logo, temos a equação da reta:

$$\hat{y} = a + bx$$

Onde:

 $\hat{y}$  é o valor ajustado (valor médio predito);

x é o valor escolhido de X;

Sabendo que  $a = \overline{y} - b\overline{x}$ , logo:

*a* é denominado intercepto, é o valor predito para x=0;

*b* é denominado coeficiente angular, ou seja, indica quantas unidades de Y mudam para a mudança de uma unidade de X.

Aplicando aos dados do exemplo (masculino e feminino), temos:

$$a = 28,61 - b.46,33$$

$$b = 0.79. (9.14/13.22) = 0.548$$

Ou seja, para o aumento de 1 ano, o percentual de gordura aumenta 0,55%.

Substituindo o valor b na equação a, temos:

$$a = 28,61 \cdot 0,548 \cdot 46,33 = 3,221$$

Logo, a equação ajustada será:

% gordura = 3,22 + 0,55 (idade)

## **APÊNDICE VI**

# QUADRO A.3 – VARIAÇÃO DO NÚMERO DE NEURÔNIOS DA CAMADA ESCONDIDA - TESTE II.1, 30 COMPONENTES PRINCIPAIS, 50 ITERAÇÕES

VALOR						NI	EURÔNIOS	NA CAMADA	A ESCONDI	DA					
DESEJADO	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
0,311828	0,09207	0,22479	0,29965	0,30145	0,28019	0,27005	0,28562	0,24109	0,29456	0,28626	0,29299	0,30410	0,31842	0,28013	0,28490
0,3225806	0,32975	0,32307	0,32710	0,32931	0,33756	0,32552	0,34065	0,33146	0,32420	0,32662	0,32578	0,30712	0,31715	0,32633	0,31314
0,1075269	0,09844	0,03401	0,02045	0,01993	0,03649	0,05534	0,08369	0,02938	0,03674	0,04089	0,08758	0,05005	0,05580	0,10087	0,09053
0,0215054	0,15915	0,13868	0,12031	0,15264	0,16722	0,14950	0,16076	0,16675	0,20841	0,16430	0,18974	0,15756	0,18849	0,16760	0,16684
0,5913978	0,68906	0,59734	0,58952	0,59226	0,59800	0,59151	0,60515	0,59947	0,59329	0,58915	0,59095	0,59373	0,59475	0,58805	0,59283
0,1935484	0,09530	0,16829	0,12935	0,19151	0,18653	0,19354	0,16858	0,20335	0,18283	0,14337	0,18834	0,19002	0,19450	0,20240	0,14181
0,2150538	0,09242	0,20488	0,24059	0,20979	0,22571	0,21937	0,22200	0,20963	0,21439	0,21356	0,22483	0,20699	0,20923	0,21169	0,21383
0,0537634	0,09430	0,05103	0,02186	0,11284	0,03776	0,05247	0,05067	0,05283	0,04751	0,05782	0,07254	0,05210	0,04932	0,04834	0,05255
0,0967742	0,09417	0,10334	0,07548	0,03663	0,04412	0,06405	0,07003	0,06260	0,07982	0,09014	0,09551	0,10859	0,09012	0,05851	0,07105
0,1182796	0,14071	0,12334	0,08455	0,03495	0,11133	0,13086	0,12942	0,08660	0,09381	0,10206	0,13572	0,11991	0,10424	0,13357	0,09993
0,0430108	0,09604	0,02852	0,04055	0,02426	0,01939	0,04934	0,05376	0,02218	0,07730	0,05313	0,05108	0,07392	0,06131	0,07352	0,06172
0,0537634	0,11715	0,04497	0,09757	0,05786	0,05412	0,09066	0,09391	0,09231	0,06870	0,07312	0,04899	0,04374	0,07408	0,06450	0,06393
0,2580645	0,26565	0,32121	0,28501	0,28059	0,26056	0,27410	0,25888	0,26946	0,26140	0,27011	0,25783	0,26384	0,27251	0,26144	0,26811
0,0967742	0,09159	0,05237	0,06880	0,06757	0,03465	0,02938	0,06524	0,04546	0,11635	0,06365	0,08744	0,12138	0,03216	0,07542	0,09154
0,1827957	0,09425	0,20772	0,11852	0,18814	0,17845	0,19078	0,15435	0,18776	0,15033	0,19317	0,16692	0,19670	0,18557	0,17366	0,17850
0,4731183	0,46362	0,48042	0,46927	0,47073	0,46830	0,46950	0,47303	0,47157	0,47004	0,47578	0,47094	0,47562	0,47116	0,46437	0,46827
0,0430108	0,09192	0,03939	0,08673	0,05208	0,07673	0,03627	0,04870	0,01849	0,04065	0,06567	0,04707	0,05829	0,05275	0,05141	0,04859
0,0752688	0,09425	0,07434	0,07470	0,03286	0,07230	0,09132	0,03207	0,06030	0,06497	0,08675	0,10228	0,06198	0,07439	0,02320	0,05700
0,1290323	0,12197	0,11186	0,10746	0,12935	0,12107	0,13586	0,10376	0,13088	0,13357	0,14702	0,13814	0,14582	0,13863	0,14207	0,14864
0,6129032	0,68634	0,76638	0,63958	0,61804	0,61614	0,60074	0,60632	0,61266	0,63994	0,60800	0,61566	0,61823	0,61466	0,64272	0,61757
0,4301075	0,68528	0,46642	0,45324	0,42453	0,40360	0,43483	0,42612	0,43181	0,43146	0,43449	0,42605	0,43201	0,45651	0,42974	0,42858
0,1827957	0,18987	0,24802	0,16739	0,17722	0,18717	0,18888	0,18848	0,18479	0,18322	0,16766	0,18877	0,19718	0,19205	0,17954	0,18075
0,1397849	0,09078	0,14507	0,13062	0,12935	0,16619	0,14063	0,06059	0,13178	0,12593	0,15665	0,13265	0,12723	0,14076	0,10277	0,14172
0,7311828	0,62183	0,71516	0,70097	0,73510	0,73329	0,72639	0,73796	0,72758	0,72506	0,72007	0,73822	0,73135	0,71250	0,74716	0,72587
0,1505376	0,11316	0,13280	0,10042	0,15581	0,14242	0,14198	0,15508	0,14564	0,17654	0,15151	0,11591	0,16734	0,15523	0,15210	0,12535
0,0967742	0,13149	0,11752	0,06967	0,09190	0,11271	0,06384	0,10147	0,13321	0,09275	0,10258	0,11030	0,09358	0,09784	0,10222	0,11792
0,0967742	0,08754	0,03933	0,09668	0,05192	0,10005	0,06701	0,09857	0,08415	0,07644	0,08041	0,08558	0,07993	0,06699	0,10310	0,09037
RMSE TER	0,00368	0,00244	0,00095	0,00082	0,00072	0,00052	0,00051	0,00065	0,00066	0,00046	0,00050	0,00062	0,00051	0,00056	0,00041
RMSE TES	0,01845	0,02811	0,03154	0,07066	0,03289	0,01832	0,07542	0,05511	0,01376	0,00562	0,02122	0,02392	0,02115	0,03212	0,02349

## **APÊNDICE VII**

QUADRO A.4 – VARIAÇÃO DO NÚMERO DE ITERAÇÕES - TESTE II, 30 COMPONENTES PRINCIPAIS, 10 NEURÔNIOS NA CAMADA ESCONDIDA

VALOR								TERAÇÕES							
DESEJADO	10	20	30	40	50	60	70	80	90	100	200	300	400	500	1000
0,311828	0,11447	0,21309	0,26242	0,27500	0,28626	0,29547	0,30080	0,30343	0,30499	0,30621	0,30966	0,31001	0,31063	0,31121	0,31172
0,3225806	0,24112	0,32809	0,33131	0,32980	0,32662	0,32414	0,32277	0,32203	0,32177	0,32172	0,32123	0,32135	0,32189	0,32215	0,32241
0,1075269	0,09854	0,05640	0,04348	0,04039	0,04089	0,04194	0,04376	0,04637	0,04988	0,05437	0,09789	0,10239	0,10364	0,10500	0,10700
0,0215054	0,10032	0,18344	0,17886	0,17430	0,16430	0,15529	0,14880	0,14375	0,13961	0,13624	0,11626	0,10475	0,09411	0,08506	0,05740
0,5913978	0,53643	0,62273	0,59132	0,58870	0,58915	0,58948	0,58970	0,58980	0,58979	0,58974	0,59127	0,59180	0,59171	0,59195	0,59167
0,1935484	0,11768	0,12478	0,12307	0,13107	0,14337	0,15633	0,16820	0,17692	0,18229	0,18560	0,19415	0,19500	0,19431	0,19367	0,19361
0,2150538	0,06816	0,19369	0,20358	0,21379	0,21356	0,21396	0,21440	0,21420	0,21403	0,21410	0,21466	0,21484	0,21532	0,21538	0,21523
0,0537634	0,04835	0,07227	0,05967	0,05712	0,05782	0,05741	0,05676	0,05625	0,05600	0,05594	0,05720	0,05703	0,05409	0,05360	0,05349
0,0967742	0,09563	0,08470	0,08909	0,08742	0,09014	0,09246	0,09393	0,09485	0,09528	0,09528	0,09104	0,09344	0,09627	0,09739	0,09702
0,1182796	0,08575	0,08549	0,08993	0,09476	0,10206	0,10958	0,11687	0,12315	0,12807	0,13170	0,12977	0,12523	0,12339	0,12126	0,11900
0,0430108	0,11529	0,07535	0,06187	0,05557	0,05313	0,05052	0,04838	0,04705	0,04633	0,04596	0,04444	0,04791	0,04748	0,04539	0,04291
0,0537634	0,09721	0,11899	0,07881	0,07274	0,07312	0,07171	0,06958	0,06741	0,06530	0,06336	0,05597	0,05613	0,05541	0,05419	0,05305
0,2580645	0,43446	0,30838	0,27915	0,27256	0,27011	0,26700	0,26453	0,26202	0,25971	0,25816	0,25622	0,25680	0,25721	0,25747	0,25793
0,0967742	0,06981	0,11233	0,08341	0,06768	0,06365	0,06213	0,06206	0,06276	0,06382	0,06510	0,08014	0,08853	0,08972	0,09238	0,09621
0,1827957	0,06479	0,13160	0,16866	0,18939	0,19317	0,19139	0,18953	0,18842	0,18772	0,18727	0,18433	0,18362	0,18334	0,18320	0,18286
0,4731183	0,27496	0,49945	0,48063	0,47491	0,47578	0,47596	0,47575	0,47543	0,47493	0,47440	0,47243	0,47211	0,47255	0,47262	0,47287
0,0430108	0,08337	0,06669	0,07400	0,06822	0,06567	0,06326	0,06032	0,05737	0,05464	0,05236	0,04529	0,04332	0,04106	0,04068	0,04241
0,0752688	0,06875	0,09921	0,09630	0,08961	0,08675	0,08454	0,08257	0,08101	0,07996	0,07928	0,07343	0,07056	0,07081	0,07103	0,07235
0,1290323	0,06732	0,20790	0,18461	0,15595	0,14702	0,14235	0,13883	0,13654	0,13521	0,13442	0,13194	0,13068	0,12939	0,12934	0,12966
0,6129032	0,62349	0,68341	0,63333	0,60938	0,60800	0,60852	0,60876	0,60901	0,60934	0,60977	0,61296	0,61356	0,61335	0,61342	0,61320
0,4301075	0,55996	0,52235	0,46991	0,44342	0,43449	0,43273	0,43190	0,43103	0,43036	0,43003	0,43014	0,43074	0,43086	0,43055	0,43008
0,1827957	0,12230	0,18145	0,17211	0,16508	0,16766	0,17163	0,17522	0,17821	0,18029	0,18157	0,18300	0,18225	0,18211	0,18239	0,18278
0,1397849	0,05561	0,16108	0,16954	0,16418	0,15665	0,15151	0,14859	0,14720	0,14659	0,14624	0,14488	0,14445	0,14345	0,14236	0,14017
0,7311828	0,40153	0,65615	0,69365	0,70957	0,72007	0,72519	0,72819	0,73006	0,73115	0,73176	0,73259	0,73168	0,73145	0,73149	0,73167
0,1505376	0,11520	0,11831	0,13768	0,14715	0,15151	0,15273	0,15241	0,15154	0,15081	0,15035	0,15096	0,15172	0,15140	0,15097	0,15054
0,0967742	0,10426	0,06081	0,08688	0,10218	0,10258	0,09986	0,09714	0,09519	0,09424	0,09410	0,09653	0,09529	0,09425	0,09427	0,09633
RMSE TER	0,00869	0,00167	0,00090	0,00061	0,00046	0,00037	0,00032	0,00028	0,00026	0,00024	0,00014	0,00944	0,00766	0,00633	0,00318
RMSE TES	0,00694	0,00563	0,00544	0,00556	0,00562	0,00568	0,00573	0,00577	0,00580	0,00581	0,00581	0,07969	0,08449	0,08730	0,09260

## **APÊNDICE VIII** QUADRO A.5 - RESULTADO PRÁTICO DO TESTE II – RNA

Saída d	da RNA	Tempo de	Processo		Saída d	la RNA	Tempo de	Processo
Desejada	Obtida	Desejado	Obtido		Desejada	Obtida	Desejado	Obtido
0,311828	0,26242	29	24,4		0,1397849	0,11075	13	10,3
0.3225806	0,33131	30	30,8		0,0645161	0,02321	6	2,2
0,1075269	0,04348	10	4,0		0,2903226	0,31737	27	29,5
0,0215054	0,17886	2	16,6		0,516129	0,51208	48	47,6
0,5913978	0,59132	55	55,0		0,2150538	0,22760	20	21,2
0,1935484	0,12307	18	11,4		0,0752688	0,10760	7	10,0
0,2150538	0,20358	20	18,9		0,0430108	0,05880	4	5,5
0,0537634	0,05967	5	5,5		0,0967742	0.09580	9	8,9
0,0967742	0,08909	9	8,3		0,0752688	0,14112	7	13,1
0,1182796	0,08993	11	8,4		0,8064516	0,80173	75	74,6
0,0430108	0,06187	4	5,8		0,2580645	0,24706	24	23,0
0,0537634	0,07881	5	7,3		0,5913978	0,58675	55	54,6
0,2580645	0,27915	24	26,0		0,1075269	0,03488	10	3,2
0,0967742	0,08341	9	7,8		0,1182796	0,16264	11	15,1
0,1827957	0,16866	17	15,7		0,0537634	0,01439	5	1,3
0,4731183	0,48063	44	44,7		0,2365591	0,21643	22	20,1
0,4731163	0,48063	4	6,9		0,2363391	0,21643	7	4,8
0,0430108	0,07400	7	9.0		0,0752666	0,05210	16	8,7
	0,09030	12	17,2		0,0537634	0,09318	5	1,5
0,1290323 0,6129032	0,63333	57	58.9		0,0337634	0,01630	54	51,6
0,6129032	0,65555	40	43,7		0,0215054	0,05606	2	5,2
- '	0,40991	17	16,0		0,0213034	0,06086	5	5,7
0,1827957	-	13	•		,	-	14	,
0,1397849	0,16954		15,8		0,1505376	0,16417	4	15,3
0,7311828	0,69365	68	64,5		0,0430108	0,05330		5,0
0,1505376	0,13768	14	12,8		0,1075269	0,12687	10	11,8
0,0967742	0,08688	9	8,1		0,1290323	0,10014	12	9,3
0,0967742	0,08007		7,4		0,1397849	0,04048	13	3,8
0,0967742	0,02266	9	2,1		0,172043	0,02316	16 12	2,2
0,0860215	0,12864	8	12,0		0,1290323	0,18612		17,3
0,1827957	0,19002	17	17,7		0,2150538	0,11664	20 6	10,8
0,4408602	0,50906	41	47,3		0,0645161	0,03468	_	3,2
0,1290323	0,14478	12 17	13,5		0,1827957	0,11572	17	10,8
0,1827957	0,15768		14,7		0,6129032	0,62856	57	58,5
0,1612903	0,17133	15	15,9		0,1182796	0,05748	11	5,3
0,0752688	0,08849	7	8,2		0,6236559	0,40683	58	37,8
0,2150538	0,22854	20	21,3		0,0967742	0,05274	9	4,9
0,483871	0,50199	45	46,7		0,0107527	0,01014		0,9
0,3548387	0,36178	33	33,6		0,1290323	0,06557	12	6,1
0,4408602	0,46471	41 73	43,2		0,1075269	0,11898	10	11,1
0,7849462	0,72238		67,2		0,1827957	0,08644	17	8,0
0,0215054	0,02475	2	2,3	-	0,3548387	0,41151	33	38,3
0,1182796	0,11052	11	10,3	-	0,9247312	0,68897	86	64,1
0,0215054	0,02255	2	2,1		0,1397849	0,14199	13	13,2
0,5806452	0,59138	54	55,0	-	0,3655914	0,37899	34	35,2
0,2580645	0,18109	24	16,8	-	0,1612903	0,10345	15	9,6
0,4193548	0,26518	39	24,7		0,1075269	0,17824	10	16,6
0,3763441	0,34382	35	32,0	-	0,172043	0,19892	16	18,5
0,7096774	0,72215	66	67,2		0,3225806	0,34755	30	32,3
0,7849462	0,79254	73	73,7		0,0752688	0,02222	7	2,1
0,1182796	0,11707	11	10,9		0,5806452	0,50750	54	47,2
0,5483871	0,51434	51	47,8		0,2795699	0,43938	26	40,9
1	0,89908	93	83,6		0,0967742	0,10906	9	10,1
0,0322581	0,04377	3	4,1	-	0,1182796	0,39685	11	36,9
0,0430108	0,10780	4	10,0		0,311828	0,39943	29	37,1

APÊNDICE IX

QUADRO A.6 – VALORES REAIS X PREDITOS – TESTE I.1

Processo	Valores Reais	Preditos	Resíduos	Erro Quadrático
1	0,311827957	0,101117	0,210711	0,044399126
2	0,322580645	0,316791	0,00578992	3,35232E-05
3	0,107526882	0,0307541	0,0767728	0,005894063
4	0,021505376	0,177988	-0,156483	0,024486929
5	0,591397849	0,571058	0,0203398	0,000413707
6	0,193548387	0,180116	0,0134327	0,000180437
7	0,215053763	0,211592	0,00346213	1,19863E-05
8	0,053763441	0,10115	-0,0473863	0,002245461
9	0,096774194	0,0549469	0,0418273	0,001749523
10	0,11827957	0,155259	-0,036979	0,001367446
11	0,043010753	0,0710057	-0,027995	0,00078372
12	0,053763441	0,137601	-0,0838377	0,00702876
13	0,258064516	0,431897	-0,173832	0,030217564
14	0,096774194	0,137344	-0,0405702	0,001645941
15	0,182795699	0,166156	0,0166401	0,000276893
16	0,47311828	0,396619	0,0764991	0,005852112
17	0,043010753	0,0163362	0,0266745	0,000711529
18	0,075268817	0,0322336	0,0430352	0,001852028
19	0,129032258	0,23294	-0,103908	0,010796872
20	0,612903226	0,691489	-0,0785862	0,006175791
21	0,430107527	0,530072	-0,0999644	0,009992881
22	0,182795699	0,300118	-0,117323	0,013764686
23	0,139784946	0,128432	0,0113529	0,000128888
24	0,731182796	0,47166	0,259522	0,067351668
25	0,150537634	0,162842	-0,0123048	0,000151408
26	0,096774194	0,0690544	0,0277198	0,000768387
27	0,096774194	0,10061	-0,00383604	1,47152E-05
28	0,096774194	0,0582331	0,0385411	0,001485416
29	0,086021505	0,138424	-0,0524029	0,002746064
30	0,182795699	0,276504	-0,0937083	0,008781245
31	0,440860215	0,514967	-0,0741066	0,005491788
32	0,129032258	0,158196	-0,0291637	0,000850521
33	0,182795699	0,17138	0,0114152	0,000130307
34	0,161290323	0,183298	-0,0220072	0,000484317
35	0,075268817	0,22635	-0,151081	0,022825469
36	0,215053763	0,439542	-0,224488	0,050394862
37	0,483870968	0,501984	-0,0181132	0,000328088
38	0,35483871	0,411287	-0,056448	0,003186377
39	0,440860215	0,556433	-0,115573	0,013357118
40	0,784946237	0,57287	0,212076	0,04497623
41	0,021505376	0,0956647	-0,0741593	0,005499602
108	0,311827957	0,367083	-0,0552546	0,003053071
	Média do E	rro Quadrático		0,011971263

APÊNDICE X

QUADRO A.7 – VALORES REAIS X PREDITOS – TESTE I.2

Processo	Valores Reais	Preditos	Resíduos	Erro Quadrático
1	0,311827957	0,149055	0,162773	0,02649505
2				
	0,322580645	0,35191	-0,0293298	0,000860237
3	0,107526882	0,133212	-0,0256854	0,00065974
4	0,021505376	0,236883	-0,215378	0,046387683
5	0,591397849	0,552759	0,0386389	0,001492965
6	0,193548387	0,0745912	0,118957	0,014150768
7	0,215053763	0,149055	0,0659985	0,004355802
8	0,053763441	0,0926488	-0,0388853	0,001512067
9	0,096774194	0,0745912	0,022183	0,000492085
10	0,11827957	0,189619	-0,0713392	0,005089281
11	0,043010753	0,149055	-0,106045	0,011245542
12	0,053763441	0,121855	-0,0680919	0,004636507
13	0,258064516	0,304646	-0,0465818	0,002169864
14	0,096774194	0,133212	-0,0364381	0,001327735
15	0,182795699	0,149055	0,0337404	0,001138415
16	0,47311828	0,408317	0,0648013	0,004199208
17	0,043010753	0,00169766	0,0447084	0,001998841
18	0,075268817	0,0745912	0,000677594	4,59134E-07
19	0,129032258	0,149055	-0,020023	0,000400921
20	0,612903226	0,696993	-0,0840899	0,007071111
21	0,430107527	0,478295	-0,0481874	0,002322026
22	0,182795699	0,252726	-0,0699302	0,004890233
23	0,139784946	0,121855	0,0179296	0,000321471
24	0,731182796	0,363267	0,367915	0,135361447
25	0,150537634	0,189619	-0,0390811	0,001527332
26	0,096774194	0,0745912	0,022183	0,000492085
27	0,096774194	0,0745912	0,022183	0,000492085
28	0,096774194	0,0745912	0,022183	0,000492085
29	0,086021505	0,149055	-0,0630338	0,00397326
30	0,182795699	0,281623	-0,0988277	0,009766914
31	0,440860215	0,581966	-0,141105	0,019910621
32	0,129032258	0,201158	-0,0721253	0,005202059
33	0,182795699	0,149055	0,0337404	0,001138415
34	0,161290323	0,149055	0,0122351	0,000149698
35	0,075268817	0,24824	-0,172971	0,029918967
36	0,215053763	0,534701	-0,319648	0,102174844
37	0,483870968	0,523345	-0,0394736	0,001558165
38	0,35483871	0,419674	-0,0648352	0,004203603
39	0,440860215	0,593322	-0,152462	0,023244661
40	0,784946237	0,581966	0,202981	0,041201286
41	0,021505376	0,0181847	0,00332065	1,10267E-05
42	0,11827957	0	0,11828	0,013990158
108	0,311827957	0,35191	-0,0400825	0,001606607
100	Média do Erro		-0,0400020	
	IVICUIA UU LIIU	Quadralico		0,0144593

APÊNDICE XI

## QUADRO A.8 – VALORES REAIS X PREDITOS – TESTE II.1

Processo	Valores Reais	Preditos	Resíduos	Erro Quadrático
1	0,311827957	0,108618	0,20321	0,041294
2	0,322580645	0,311131	0,01145	0,000131
3	0,107526882	0,013576	0,093951	0,008827
4	0,021505376	0,17901	-0,1575	0,024808
5	0,591397849	0,5895	0,001898	3,6E-06
6	0,193548387	0,160619	0,032929	0,001084
7	0,215053763	0,264364	-0,04931	0,002431
8	0,053763441	0,157239	-0,10348	0,010707
9	0,096774194	0,073206	0,023568	0,000555
10	0,11827957	0,156211	-0,03793	0,001439
11	0,043010753	0,054506	-0,0115	0,000132
12	0,053763441	0,156263	-0,1025	0,010506
13	0,258064516	0,428868	-0,1708	0,029174
14	0,096774194	0,095219	0,001555	2,42E-06
15	0,182795699	0,156218	0,026578	0,000706
16	0,47311828	0,399862	0,073256	0,005367
17	0,043010753	0,01358	0,029431	0,000866
18	0,075268817	0,016527	0,058742	0,003451
19	0,129032258	0,191489	-0,06246	0,003901
20	0,612903226	0,684612	-0,07171	0,005142
21	0,430107527	0,495332	-0,06522	0,004254
22	0,182795699	0,320906	-0,13811	0,019074
23	0,139784946	0,127191	0,012594	0,000159
24	0,731182796	0,479562	0,25162	0,063313
25	0,150537634	0,176777	-0,02624	0,000688
26	0,096774194	0,109545	-0,01277	0,000163
27	0,096774194	0,111091	-0,01432	0,000205
28	0,096774194	0,001477	0,095297	0,009081
29	0,086021505	0,107901	-0,02188	0,000479
30	0,182795699	0,28586	-0,10306	0,010622
31	0,440860215	0,544455	-0,1036	0,010732
32	0,129032258	0,186793	-0,05776	0,003336
33	0,182795699	0,173855	0,00894	7,99E-05
34	0,161290323	0,150687	0,010603	0,000112
35	0,075268817	0,202532	-0,12726	0,016196
36	0,215053763	0,423112	-0,20806	0,043288
37	0,483870968	0,455807	0,028064	0,000788
38	0,35483871	0,405251	-0,05041	0,002541
39	0,440860215	0,536782	-0,09592	0,009201
40	0,784946237	0,543325	0,241622	0,058381
41	0,021505376	0,030894	-0,00939	8,81E-05
42	0,11827957	0,05296	0,06532	0,004267
108	0,311827957	0,351972	-0,04014	0,001612
	Média do Erro C	uadrático		0,011215

APÊNDICE XII

## QUADRO A.9 – VALORES REAIS X PREDITOS – TESTE II.2

Processo	Valores Reais	Preditos	Resíduos	Erro Quadrático
1	0,311827957	0,024867	0,286961	0,082347
2	0,322580645	0,303998	0,018582	0,000345
3	0,107526882	0,002431	0,105096	0,011045
4	0,021505376	0,13646	-0,11495	0,013214
5	0,591397849	0,475449	0,115949	0,013444
6	0,193548387	0,190757	0,002792	7,79E-06
7	0,215053763	0,215435	-0,00038	1,45E-07
8	0,053763441	0,124383	-0,07062	0,004987
9	0,096774194	0,141509	-0,04473	0,002001
10	0,11827957	0,101935	0,016345	0,000267
11	0,043010753	0,003138	0,039873	0,00159
12	0,053763441	0,248214	-0,19445	0,037811
13	0,258064516	0,484023	-0,22596	0,051057
14	0,096774194	0,086119	0,010655	0,000114
15	0,182795699	0,127764	0,055031	0,003028
16	0,47311828	0,333627	0,139491	0,019458
17	0,043010753	0,030033	0,012977	0,000168
18	0,075268817	0,123495	-0,04823	0,002326
19	0,129032258	0,225668	-0,09664	0,009338
20	0,612903226	0,723608	-0,11071	0,012256
21	0,430107527	0,433619	-0,00351	1,23E-05
22	0,182795699	0,347129	-0,16433	0,027005
23	0,139784946	0,128856	0,010929	0,000119
24	0,731182796	0,477094	0,254088	0,064561
25	0,150537634	0,303222	-0,15269	0,023313
26	0,096774194	0,12013	-0,02336	0,000545
27	0,096774194	0,055902	0,040872	0,001671
28	0,096774194	-0,03449	0,131266	0,017231
29	0,086021505	0,068261	0,01776	0,000315
30	0,182795699	0,314153	-0,13136	0,017255
31	0,440860215	0,426475	0,014385	0,000207
32	0,129032258	0,190896	-0,06186	0,003827
33	0,182795699	0,067673	0,115123	0,013253
34	0,161290323	0,223531	-0,06224	0,003874
35	0,075268817	0,217162	-0,14189	0,020134
36	0,215053763	0,347229	-0,13218	0,01747
37	0,483870968	0,460824	0,023047	0,000531
38	0,35483871	0,405227	-0,05039	0,002539
39	0,440860215	0,498696	-0,05784	0,003345
40	0,784946237	0,524399	0,260547	0,067885
41	0,021505376	0,158377	-0,13687	0,018734
42	0,11827957	0,220517	-0,10224	0,010452
	•••			
108	0,311827957	0,356927	-0,0451	0,002034
ı	Média do Erro C	· ·	, -	0,01582

**APÊNDICE XIII** 

## QUADRO A.10 - VALORES REAIS X PREDITOS - TESTE III.1

Processo	Valores Reais	Preditos	Resíduos	Erro Quadrático
1	0,311827957	-0,13416	0,445985	0,1989026
2	0,322580645	0,175531	0,14705	0,0216237
3	0,107526882	0,001531	0,14703	0,0112352
4	0,021505376	0,16458	-0,14308	0,0204705
5	0,591397849	0,587862	0,003536	1,25E-05
6	0,193548387	0,053413	0,140135	0,0196378
7	0,215053763	0,207715	0,007338	5,385E-05
8	0,053763441	0,008625	0,007338	0,0020374
9	0,096774194	-0,14458	0,241356	0,0582527
10	0,11827957	-0,07225	0,190533	0,0363028
11	0,043010753	0,071848	-0,02884	0,0008316
12	0,053763441	0,347173	-0,29341	0,0860888
13	0,258064516	0,347173	-0,23541	0,0210441
14	0,096774194	-0,12181	0,218583	0,0477785
15	0,182795699	0,084992	0,210303	0,0095655
16	0,47311828	0,004992	0,097604	0,0780817
17	0,043010753	-0,2051	0,279431	0,0780817
18	0,075268817	-0,2031	0,246108	0,0564006
19	,	0,14522		0,000262
20	0,129032258 0,612903226	0,14322	-0,01619 0,072604	0,0052714
21	0,430107527	0,340299	0,072004	0,0032714
22	0,182795699	0,30423	0,06482	0,0138402
23	0,139784946	-0,05677	0,00462	0,038635
24	0,731182796	0,483195	0,190338	0,038833
25	0,150537634	0,483193	-0,01951	0,0003806
26	0,096774194	-0,01166	0,108435	0,0003808
27	0,096774194	-0,01166		
28	0,096774194	-0,18003	0,277426	0,0769652 0,01502
29	0,086021505	-0,02378	0,122556	0,009535
30	0,182795699	0,117026	0,097647 0,06577	0,009333
31	0,440860215	0,117020	0,00577	0,0553002
32		0,2037	-0,02868	
33	0,129032258 0,182795699	0,063186	0,11961	0,0008227 0,0143066
34	0,161290323	-0,13619	0,11901	0,0884926
35	0,075268817	0,199443	-0,12417	0,0154192
36	0,215053763	0,199443	-0,12417	0,0134192
37	0,483870968	0,377838	0,004341	1,884E-05
38	0,463670966	0,47955	0,004341	0,0008317
39	0,440860215	0,326	-0,27522	0,0008317
40	0,784946237	0,716062	0,243026	0,0737471
41	0,021505376	0,068038	-0,04653	0,0021652
42	0,021303376	0,066036	0,046715	0,0021823
	0,1102/93/	0,071303	0,040715	0,0021023
108	0,311827957	0.223460	 0 08636	0,0078076
108	•	0,223468	0,08836	0,0078076
	Média do Erro	Quadratico		0,0410004

**APÊNDICE XIV** 

## QUADRO A.11 - VALORES REAIS X PREDITOS - TESTE III.2

Drocesse	Valores Basis	Preditos	Pocíduos	Erro Ouadrática
Processo	Valores Reais	-	Resíduos	Erro Quadrático
1	0,311827957	-0,11121	0,423038	0,178961
2	0,322580645	0,177984	0,144597	0,020908
3	0,107526882	0,003105	0,104422	0,010904
4	0,021505376	0,167365	-0,14586	0,021275
5	0,591397849	0,598172	-0,00677	4,59E-05
6	0,193548387	0,038288	0,15526	0,024106
7	0,215053763	0,163377	0,051676	0,00267
8	0,053763441	0,000645	0,053119	0,002822
9	0,096774194	-0,13947	0,23624	0,055809
10	0,11827957	-0,08378	0,202059	0,040828
11	0,043010753	0,088415	-0,0454	0,002062
12	0,053763441	0,318329	-0,26457	0,069995
13	0,258064516	0,404349	-0,14628	0,021399
14	0,096774194	-0,08562	0,182398	0,033269
15	0,182795699	0,074549	0,108247	0,011717
16	0,47311828	0,17603	0,297088	0,088261
17	0,043010753	-0,17316	0,216175	0,046732
18	0,075268817	-0,16157	0,236841	0,056094
19	0,129032258	0,187717	-0,05868	0,003444
20	0,612903226	0,540929	0,071974	0,00518
21	0,430107527	0,281582	0,148525	0,02206
22	0,182795699	0,133722	0,049074	0,002408
23	0,139784946	-0,02747	0,167258	0,027975
24	0,731182796	0,488205	0,242978	0,059038
25	0,150537634	0,173228	-0,02269	0,000515
26	0,096774194	-0,00341	0,100185	0,010037
27	0,096774194	-0,18551	0,282288	0,079687
28	0,096774194	-0,0379	0,134675	0,018137
29	0,086021505	-0,00187	0,087893	0,007725
30	0,182795699	0,097693	0,085103	0,007242
31	0,440860215	0,194845	0,246015	0,060523
32	0,129032258	0,176182	-0,04715	0,002223
33	0,182795699	0,084371	0,098424	0,009687
34	0,161290323	-0,10461	0,265899	0,070702
35	0,075268817	0,218717	-0,14345	0,020577
36	0,215053763	0,587677	-0,37262	0,138848
37	0,483870968	0,484904	-0,00103	1,07E-06
38	0,35483871	0,332001	0,022838	0,000522
39	0,440860215	0,724052	-0,28319	0,080198
40	0,784946237	0,594108	0,190838	0,036419
41	0,021505376	0,091481	-0,06998	0,004897
42	0,11827957	0,054607	0,063673	0,004054
				•••
108	0,311827957	0,255618	0,05621	0,00316
	Média do Erro C		, ,	0,042497

**APÊNDICE XV**QUADRO A.12 – RESULTADO PRÁTICO DO TESTE II de REGRESSÃO LINEAR

RL	_M	Tempo de	Processo		RL	_M	Tempo de	Processo
Desejada	Obtida	Desejado	Obtido		Desejada	Obtida	Desejado	Obtido
0,311828	0,108618	29	10,1		0,1397849	0,104788	13	9,7
0,3225806	0,311131	30	28,9		0,0645161	0,004321	6	0,4
0,1075269	0,013576	10	1,3		0,2903226	0,47728	27	44,4
0,0215054	0,17901	2	16,6		0,516129	0.636825	48	59,2
0,5913978	0,5895	 55	54,8		0,2150538	0,14592	20	13,6
0,1935484	0,160619	18	14,9		0,0752688	0,157408	7	14,6
0,2150538	0,264364	20	24,6		0,0430108	0,058332	4	5,4
0,0537634	0,157239	5	14,6		0,0967742	0,096774	9	9,0
0,0967742	0,073206	9	6,8		0,0752688	0,268006	7	24,9
0,0307742	0,073200	11	14,5		0,8064516	0,556175	75	51,7
0,0430108	0,054506	4	5,1		0,2580645	0,265788	24	24,7
0,0537634	0,054300	5	14,5		0,5913978	0,203788	55	-
	0,136263	24	39,9			0,053227	10	35,9 5,0
0,2580645					0,1075269			·
0,0967742	0,095219	9	8,9		0,1182796	0,292183	11	27,2
0,1827957	0,156218	17	14,5	-	0,0537634	0,020257	5	1,9
0,4731183	0,399862	44	37,2	}	0,2365591	0,19141	22	17,8
0,0430108	0,01358	4	1,3	-	0,0752688	0,062327	7	5,8
0,0752688	0,016527	7	1,5	-	0,172043	0,249452	16	23,2
0,1290323	0,191489	12	17,8	<b> </b>	0,0537634	0,069994	5	6,5
0,6129032	0,684612	57	63,7		0,5806452	0,629414	54	58,5
0,4301075	0,495332	40	46,1		0,0215054	0,042044	2	3,9
0,1827957	0,320906	17	29,8		0,0537634	0,0275	5	2,6
0,1397849	0,127191	13	11,8		0,1505376	0,249608	14	23,2
0,7311828	0,479562	68	44,6		0,0430108	0,081587	4	7,6
0,1505376	0,176777	14	16,4		0,1075269	0,105539	10	9,8
0,0967742	0,109545	9	10,2		0,1290323	0,110041	12	10,2
0,0967742	0,111091	9	10,3		0,1397849	0,094972	13	8,8
0,0967742	0,001477	9	0,1		0,172043	0,102349	16	9,5
0,0860215	0,107901	8	10,0		0,1290323	0,141795	12	13,2
0,1827957	0,28586	17	26,6		0,2150538	0,177476	20	16,5
0,4408602	0,544455	41	50,6		0,0645161	0,107267	6	10,0
0,1290323	0,186793	12	17,4		0,1827957	0,082327	17	7,7
0,1827957	0,173855	17	16,2		0,6129032	0,58984	57	54,9
0,1612903	0,150687	15	14,0		0,1182796	0,103598	11	9,6
0,0752688	0,202532	7	18,8		0,6236559	0,525294	58	48,9
0,2150538	0,423112	20	39,3		0,0967742	0,049098	9	4,6
0,483871	0,455807	45	42,4		0,0107527	-0,05344	1	-5,0
0,3548387	0,405251	33	37,7		0,1290323	0,021147	12	2,0
0,4408602	0,536782	41	49,9		0,1075269	0.031209	10	2,9
0,7849462	0,543325	73	50,5		0,1827957	0,270086	17	25,1
0,0215054	0,030894	2	2,9		0,3548387	0,387714	33	36,1
0,1182796	0,05296	11	4,9	<b>†</b>	0,9247312	0,622225	86	57,9
0,0215054	0,021819	2	2,0	<b>†</b>	0,1397849	0,159646	13	14,8
0,5806452	0,44626	54	41,5		0,3655914	0,52941	34	49,2
0,3500432	0,350474	24	32,6		0,1612903	0,036466	15	3,4
0,4193548	0,330474	39	27,6		0,1075269	0,030400	10	29,7
0,4193348	0,36435	35	33,9	1	0,1073209	0,31933	16	26,3
0,3763441	0,36433		62,5		0,172043	0,262413		·
,		66		-	,		30	31,8
0,7849462	0,605847	73	56,3	-	0,0752688	-0,06129	7	-5,7
0,1182796	0,104022	11	9,7	-	0,5806452	0,543737	54	50,6
0,5483871	0,361631	51	33,6	1	0,2795699	0,409964	26	38,1
1	0,739204	93	68,7	-	0,0967742	0,184436	9	17,2
0,0322581	0,086432	3	8,0	<b></b>	0,1182796	0,297751	11	27,7
0,0430108	0,193564	4	18,0		0,311828	0,351972	29	32,7